

## Examen de Statistique Descriptive

Session principale

Janvier 2012

Cours de Mme Ouaili-Mallek

Durée 1h30

(2 pages)

**Exercice 1** *On dispose d'une série d'observations sur les variables  $x$  et  $y$ .*

$x$	3.5	5.82	4.92	6.16	6.29	7.14	9.21
$y$	1.5	2.2	3.17	5.26	5.97	7.06	8.33

1. On envisage un ajustement linéaire de  $y$  sur  $x$ . Calculer le coefficient de corrélation empirique.
2. Déterminer la droite des moindres carrés.
3. Evaluer l'ajustement obtenu.

**Exercice 2** Un importateur d'automobiles désire augmenter sa part de marché. Il étudie alors la répartition des 500 modèles commercialisés par ses concurrents en fonction du prix  $y$ , exprimé en milliers de dinars, et de la puissance fiscale  $x$ , exprimée en chevaux :

$\begin{matrix} y \\ x \end{matrix}$	[15, 30[	[30, 35[	[35, 40[	[40, 45[	[45, 50[	[50, 55[	total
<b>3-4</b>	22	8					30
<b>5-6</b>	36	41	20	13			110
<b>7-8</b>	12	36	68	50	22	22	210
<b>9-10</b>			12	26	32	30	100
<b>11-12</b>				6	14	20	40
<b>13-15</b>					2	8	10
<b>total</b>	70	85	100	95	70	80	500

Les deux parties sont indépendantes.

**1ère partie :**

On sait préalablement que  $\bar{y} = 39.3$ ,  $\bar{x} = 7.67$  et  $s_Y^2 = 87.26$ .

1. Calculer le moment simple d'ordre 2 de la puissance fiscale de l'ensemble des voitures étudiées. En déduire la variance de la variable  $x$ .
2. Calculer la covariance du prix et de la puissance fiscale.
3. Calculer la distance du khi 2. Interpréter.

$$(\text{Indication : } \sum_{i=1}^6 \sum_{j=1}^6 n_{ij} x_i y_j = 157\,992.5 \quad \sum_{i=1}^6 \sum_{j=1}^6 \frac{n_{ij}^2}{n_{i.} n_{.j}} = 2.319).$$

**2ème partie :**

L'importateur décide d'axer son action sur les véhicules de 7 à 8 chevaux.

1. Tracer l'histogramme de la distribution des prix des voitures de 7 à 8 chevaux.
2. Déterminer le mode et la médiane. Sachant que la distribution est unimodale, déduire la moyenne. Peut-on conclure la symétrie de la distribution?
3. On s'intéresse maintenant à l'inégalité de la répartition des prix. Représenter la courbe de Lorenz.
4. Calculer l'indice de Gini. Conclure.

**Corrigé de l'exercice 1 :**

$x$	3.5	5.82	4.92	6.16	6.29	7.14	9.21
$y$	1.5	2.2	3.17	5.26	5.97	7.06	8.33

$$1. r_{xy} = \frac{s_{xy}}{s_x s_y}$$

$$s_x^2 = \frac{1}{7} \sum x_i^2 - \bar{x}^2 \quad \sum x_i^2 = 283.642 \quad \bar{x} = 6.149$$

$$s_x^2 = \frac{1}{7} * 283.642 - 6.149^2 = 2.710 = (1.6462)^2$$

$$s_y^2 = \frac{1}{7} \sum y_i^2 - \bar{y}^2 \quad \sum y_i^2 = 199.68 \quad \bar{y} = 4.784$$

$$s_y^2 = \frac{1}{7} * 199.68 - 4.784^2 = 5.639 = (2.3747)^2$$

$$s_{xy} = \frac{1}{7} \sum x_i y_i - \bar{x} \bar{y} \quad \sum x_i y_i = 230.731$$

$$s_{xy} = \frac{1}{7} * 230.731 - 6.149 * 4.784 = 3.545$$

$$r_{xy} = \frac{3.5448}{1.6462 * 2.3747} = 0.907$$

$$2. \hat{y} = \hat{\alpha}x + \hat{\beta}$$

$$\hat{\alpha} = \frac{s_{xy}}{s_x^2} = \frac{3.545}{2.710} = 1.308$$

$$\hat{\beta} = \bar{y} - \hat{\alpha}\bar{x} = 4.784 - 1.308 * 6.149 = -3.259$$

$$3. \frac{s_Y^2}{s_y^2} = \frac{\hat{\alpha}^2 s_x^2}{s_y^2} = \frac{1.308^2 * 2.710}{5.639} = 0.822$$

La variance expliquée par la régression constitue une forte proportion de la variance totale.

L'ajustement est donc de bonne qualité.

**Corrigé de l'exercice 2 :**

**1ère partie**

$$1. m_{x^2} = \frac{1}{n} \sum n_i \cdot c_i^2$$

$$m_{x^2} = \frac{1}{500} (3.5^2 * 30 + 5.5^2 * 110 + 7.5^2 * 210 + 9.5^2 * 100 + 11.5^2 * 40 + 14^2 * 10)$$

$$m_{x^2} = 63.565$$

$$s_x^2 = m_{x^2} - \bar{x}^2 = 63.565 - 7.67^2 = 4.7361$$

$$2. s_{xy} = \frac{1}{n} \sum_{i=1}^6 \sum_{j=1}^6 n_{ij} x_i y_j - \bar{x} \bar{y} = \frac{1}{500} * 157992.5 - 7.67 * 39.3 = 14.554$$

$$3. D^2 = n \left( \sum_{i=1}^6 \sum_{j=1}^6 \frac{n_{ij}^2}{n_i \cdot n_j} - 1 \right) = 500 * 1.319 = 659.5 \gg 0. \text{ On peut donc conclure}$$

avec très peu de risques que les variables puissance fiscale et prix des voitures ne sont pas indépendantes. On a  $D^2 \leq \min(n(k-1), n(p-1)) = 400 * 5 = 2000 \gg D^2$ . On ne peut donc pas envisager de liaison fonctionnelle

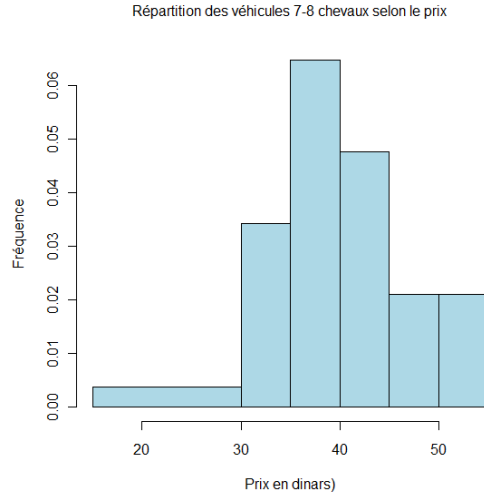


Figure 1:

## 2ème partie

### 1. Distribution des prix des voitures de 7 à 8 chevaux.

$x$	$[15, 30[$	$[30, 35[$	$[35, 40[$	$[40, 45[$	$[45, 50[$	$[50, 55[$	$total$
$n$	12	36	68	50	22	22	210
$n_i^c$	4	36	68	50	22	22	—
$f_i$	0.057	0.171	0.324	0.238	0.105	0.105	1
$F(e_i)$	0.057	0.228	0.552	0.79	0.895	1	
$f_i c_i$	1.283	5.558	12.15	10.115	4.988	5.513	39.607
$q(e_i)$	0.032	0.173	0.479	0.735	0.861	1	

Histogramme :

### 2. Classe modale : $[35, 40[$

$$M_O = 35 + 5 * \frac{68 - 36}{(68 - 36) + (68 - 50)} = 38.2 \text{ K DT}$$

Classe médiane :  $[35, 40[$

$$M_e = 35 + 5 * \frac{0.5 - 0.228}{0.552 - 0.228} = 39.2 \text{ K DT}$$

$$\bar{x} \simeq \frac{3M_e - M_O}{2} = \frac{3 * 39.2 - 38.2}{2} = 39.7 \text{ K DT}$$

On a  $M_O < M_e < \bar{x}$ . Il s'agit donc d'une distribution asymétrique conformément à l'histogramme.

### 3. Courbe de Lorenz:

$x$	$[15, 30[$	$[30, 35[$	$[35, 40[$	$[40, 45[$	$[45, 50[$	$[50, 55[$	$total$
$F(e_i)$	0.057	0.228	0.552	0.79	0.895	1	
$q(e_i)$	0.032	0.173	0.479	0.735	0.861	1	




Figure 2:

$$4. \quad G = 1 - \sum_{i=1}^6 (p(e_i) - p(e_i - 1)) (q(e_i) + q(e_{i-1}))$$

$$\begin{aligned} G = & 1 - [(0.057 * 0.032) + (0.228 - 0.057) * (0.173 + 0.032) \\ & + (0.552 - 0.228) * (0.479 + 0.173) + (0.79 - 0.552) * (0.735 + 0.479) \\ & + (0.895 - 0.79) * (0.861 + 0.735) + (1 - 0.895) * (1 + 0.861)] \end{aligned}$$

$$G = 0.1 < 0.2$$

*La distribution est peu inégalitaire*