

Optimisation Différentiable
Théorie et Algorithmes

J.Ch. GILBERT

Résumé du cours

4 septembre 2009

Informations pratiques

- Objectif du cours : l'optimisation
 - aspects théor. : convexité, CO, dualité, ...
 - aspects pratiques : algorithmes.
- Organisation :
 - 14 séances, dont 1 pour l'examen.
 - CM : 12 séances d'1h15++,
 - TD + TP : 9+5 séances d'1h45--,
 - TP : projet d'optimisation (Matlab/Scilab),
 - travail personnel.
- Supports de cours
 - syllabus : ne pas voir les sections avec \ominus ,
 - transparents : points importants du cours,
 - exercices : en TD, dans le syllabus.
- Contrôle des connaissances
 - TP : contrôle continu
 - Séance 14 : résolution de problèmes (3h).

Plan du cours

1. Rappels, différentiabilité, convexité
2. Conditions d'optimalité I : méthode et outils
3. Conditions d'optimalité II : égalités
4. Conditions d'optimalité III : inégalités
5. Méthodes de descente : RL et RC
6. Méthodes newtoniennes : N et qN
7. Pénalisation
8. Programmation quadratique successive (SQP)
9. Dualité
10. Séance de consolidation (TD)
11. Optimisation linéaire : simplexe et PI
12. Conjugaison
13. Sous-différentiabilité

I Rappels

Existence de solution (§ 1.2)

Le problème à résoudre ($f : X \rightarrow \mathbb{R} \cup \{+\infty\}$):

$$(P_X) \quad \begin{cases} \min f(x) \\ x \in X. \end{cases}$$

On dit que f est **fermée** si $(\text{epi } f)$ est fermé.

Si · f est fermée sur X ,
 · X est compact et non vide,
alors (P_X) a (au moins) une solution.

En dimension finie (c'est notre cas):

- X compact $\iff X$ fermé borné.
- On peut remplacer l'hypothèse

X compact

par

$$X \text{ fermé} \quad \text{et} \quad \lim_{\substack{x \in X \\ \|x\| \rightarrow \infty}} f(x) = +\infty.$$

Unicité de solution (§ 3.1)

- Soient X un convexe de \mathbb{E} et $f : X \rightarrow \mathbb{R}$.

Définitions : f est **convexe** sur X si pour tout $x, y \in X$, $x \neq y$, et $t \in]0, 1[$:

$$f((1-t)x + ty) \leq (1-t)f(x) + tf(y).$$

f est **strictement convexe** si on a inégalité stricte ci-dessus.

- Le problème à résoudre :

$$(P_X) \quad \begin{cases} \min f(x) \\ x \in X. \end{cases}$$

Si · X est convexe,
 · f est strictement convexe sur X ,
alors (P_X) a au plus une solution.

Différentiabilité première (§§ C.1, C.2, C.3)

Soient \mathbb{E} et \mathbb{F} deux espaces normés, Ω un ouvert de \mathbb{E} et $f : \Omega \rightarrow \mathbb{F}$.

1. **Différentiabilité directionnelle** suivant $h \in \mathbb{E}$:

$$f'(x; h) := \lim_{t \rightarrow 0+} \frac{1}{t} (f(x + th) - f(x)) \text{ existe.}$$

2. **Différentiabilité au sens de Gâteaux** :

- $f'(x; h)$ existe pour tout $h \in \mathbb{E}$ et
- $h \mapsto f'(x; h)$ est linéaire (continue).

On note $f'(x)$ l'application linéaire (continue).

3. **Différentiabilité au sens de Fréchet** : il existe

$L : \mathbb{E} \rightarrow \mathbb{F}$, linéaire (continue) :

$$f(x + h) = f(x) + Lh + o(\|h\|).$$

On note $f'(x) := L$ (même opérateur qu'en 2).

Soit $\langle \cdot, \cdot \rangle$ un produit scalaire sur \mathbb{E} et $\mathbb{F} = \mathbb{R}$. On définit le **gradient** de f en x comme l'unique vecteur $\nabla f(x) \in \mathbb{E}$:

$$\langle \nabla f(x), h \rangle = f'(x) \cdot h, \quad \forall h \in \mathbb{E}.$$

Différentiabilité seconde (§§ C.4, C.5)

Supposons que $f : \Omega \rightarrow \mathbb{F}$ soit 2 fois différentiable (pour une définition rigoureuse, voir le syllabus).

Propriétés :

- $f''(x) \cdot (h, k)$ est la dérivée directionnelle de $x \mapsto f'(x) \cdot h$ dans la direction k :

$$f''(x) \cdot (h, k) = \lim_{t \rightarrow 0+} \frac{1}{t} (f'(x + tk) \cdot h - f'(x) \cdot h)$$

- l'application

$$(h, k) \mapsto f''(x) \cdot (h, k)$$

est bilinéaire symétrique.

Soit $\langle \cdot, \cdot \rangle$ un produit scalaire sur \mathbb{E} et $\mathbb{F} = \mathbb{R}$. On définit le **hessien** de f en x comme l'unique opérateur linéaire symétrique $\nabla^2 f(x)$ sur \mathbb{E} tel que

$$\langle \nabla^2 f(x)h, k \rangle = f''(x) \cdot (h, k), \quad \forall (h, k) \in \mathbb{E}^2.$$


II Analyse convexe

- **Dfn.** Soient $x, y \in \mathbb{E}$. Un **segment** de \mathbb{E} :


$$[x, y] := \{(1-t)x + ty : t \in [0, 1]\}.$$

- **Dfn.** Un ensemble $C \subset \mathbb{E}$ est **convexe** si

$$x, y \in C \implies [x, y] \subset C.$$




convexe



non convexe



convexe



non convexe

Polyèdre convexe (§ 2.4)

Soit \mathbb{E} un espace vectoriel ($\mathbb{E} = \mathbb{R}^n$ parfois).

- **Dfn.** Description primale d'un polyèdre conv. :

$$P := \text{co}\{x_1, \dots, x_p\} + \text{cone}\{y_1, \dots, y_q\}.$$

Description duale d'un polyèdre convexe :

$$P := \{x \in \mathbb{E} : Ax \leq b\}.$$

- **Dfn** : \hat{x} est un **sommet** de P si

$$x_1, x_2 \in P, \hat{x} = \frac{x_1 + x_2}{2} \implies \hat{x} = x_1 = x_2.$$

L'ensemble des sommets est noté **ext** P .

- **Prop.**

Soit $P := \{x : Ax = b, x \geq 0\}$, $\hat{x} \in P$.

- 1) $\hat{x} \in \text{ext } P \iff A_B$ est injective,
où $B = \{i : x_i > 0\}$ et A_B formée des colonnes $i \in B$ de A .
- 2) P a au moins un sommet et au plus 2^n .

Projection sur un convexe fermé (§ 2.5.2)

\mathbb{E} muni d'un produit scalaire $\langle \cdot, \cdot \rangle = \| \cdot \|^2$.

Si $C \subset \mathbb{E}$ convexe fermé non vide et $x \in \mathbb{E}$,
alors le problème

$$\min \{ \|y - x\| : y \in C \} \quad (1)$$

a une unique solution.

- **Dfn** : l'unique solution de (1) est appelée la projection de x sur C et est notée $P_C x$.
- **Prop** : Soit $\bar{x} \in C$. Alors^a

$$\begin{aligned} \bar{x} = P_C x &\iff \forall y \in C, \quad \langle y - \bar{x}, \bar{x} - x \rangle \geq 0 \\ &\iff \forall y \in C, \quad \langle y - \bar{x}, y - x \rangle \geq 0 \\ &\implies \forall y \in C, \quad \langle y - x, \bar{x} - x \rangle \geq 0. \end{aligned}$$

^aLa réciproque de la dernière implication est fausse.

Séparation des convexes (§ 2.5.3)

\mathbb{E} muni d'un produit scalaire $\langle \cdot, \cdot \rangle$.

- **Dfn** : On peut séparer $C_1, C_2 \subset \mathbb{E}$ s'il existe $\xi \in \mathbb{E}$ non nul tel que

$$\sup_{x_1 \in C_1} \langle \xi, x_1 \rangle \leq \inf_{x_2 \in C_2} \langle \xi, x_2 \rangle.$$

La séparation est stricte si l'inégalité ci-dessus est stricte.

- **Théor (Hahn-Banach)** :

Si · C_1 et C_2 convexes, non vides, disjoints,
· $\dim \mathbb{E} < \infty$,
alors on peut séparer C_1 et C_2 .

Si · C_1 et C_2 convexes, non vides, disjoints,
· C_1 ou C_2 est d'intérieur non vide,
alors on peut séparer C_1 et C_2 .

Si · C_1 et C_2 convexes, non vides, disjoints,
· l'un est fermé, l'autre est compact,
alors on peut séparer C_1 et C_2 strictement.

Enveloppe convexe fermée (§ 2.5.4)

Soient \mathbb{E} un e.v. avec $\langle \cdot, \cdot \rangle$ et $P \subset \mathbb{E}$.

- **Dfn.** L'**enveloppe convexe** de P , $\text{co } P$, est le plus petit convexe contenant P .

$$P \text{ fermé} \not\Rightarrow \text{co } P \text{ fermé.}$$

- **Dfn.** L'**enveloppe convexe fermée** de P , $\overline{\text{co } P}$, est le plus petit convexe fermé contenant P .
- **Dfn.** Un **demi-espace fermé** de \mathbb{E} :

$$H^-(\xi, \alpha) := \{x \in \mathbb{E} : \langle \xi, x \rangle \leq \alpha\},$$

où $\xi \in \mathbb{E}$ est *non nul* et $\alpha \in \mathbb{R}$.

- **Prop.**

$\overline{\text{co } P}$ est l'intersection de tous les demi-espaces fermés contenant P .

Cône dual (§ 2.5.6)

\mathbb{E} muni d'un produit scalaire $\langle \cdot, \cdot \rangle$.

- **Dfn :** Le **cône dual** de $P \subset \mathbb{E}$ est défini par

$$P^+ := \{x \in \mathbb{E} : \langle x, y \rangle \geq 0, \forall y \in P\}.$$

C'est un cône, convexe, fermé, non vide.

- **Lemme de Farkas (généralisé)**

Si $\cdot : \mathbb{E}$ et \mathbb{F} deux espaces euclidiens,
 $\cdot K$ un cône convexe fermé $\neq \emptyset$ de \mathbb{E} ,
 $\cdot A : \mathbb{E} \rightarrow \mathbb{F}$ linéaire,
alors $\{y \in \mathbb{F} : A^*y \in K^+\}^+ = \overline{A(K)}$.

- **Cas particulier :** Soit A une matrice. Alors

$$\{Ax : x \geq 0\} = \text{cône, convexe, fermé, } \neq \emptyset$$

et

$$\{x : Ax \geq 0\}^+ = \{A^\top y : y \geq 0\}.$$

$(\cdot)^+ = \text{dual pour le produit scalaire euclidien.}$
 [c'est une généralisation de $N(A)^\perp = R(A^\top)$]

Reconnaître une fonction convexe par ses dérivées (§ 3.3.3)

Enveloppe supérieure (§ 3.4.2)

- **Enveloppe supérieure** d'une famille de $f_i : \mathbb{E} \rightarrow \overline{\mathbb{R}}, i \in I$ (quelconque) :

$$\left(\sup_{i \in I} f_i \right) (x) := \sup_{i \in I} \left(f_i(x) \right).$$

- $\text{epi} \left(\sup_{i \in I} f_i \right) = \bigcap_{i \in I} (\text{epi } f_i).$
- f_i convexes $\implies \sup_{i \in I} f_i$ convexe.
- f_i fermées $\implies \sup_{i \in I} f_i$ fermée.

Soient X un convexe de \mathbb{E} et $f : X \rightarrow \mathbb{R}$.

- Si f est 1 fois dérivable et X ouvert

Les propriétés suivantes sont équivalentes :

- f est convexe sur X
[resp. strictement convexe],

- $\forall x, y \in X, x \neq y :$

$$f(y) \geq f(x) + f'(x) \cdot (y - x)$$

[resp. $>$],

- $\forall x, y \in X, x \neq y :$

$$(f'(y) - f'(x)) \cdot (y - x) \geq 0$$

[resp. $>$].

Fonction conjuguée (§ 3.4.9)

- Si f est 2 fois dérivable et X ouvert :

- f est convexe sur $X \iff \forall x \in X, \forall h \in \mathbb{E}, f''(x) \cdot h^2 \geq 0,$
- f est strictement convexe sur $X \iff \forall x \in X, \forall h \in \mathbb{E}$ non nul, $f''(x) \cdot h^2 > 0.$

Contre-exemple: $f(x) = x^4$.

Soient \mathbb{E} un espace vectoriel, muni de $\langle \cdot, \cdot \rangle$ et $f : \mathbb{E} \rightarrow \mathbb{R} \cup \{+\infty\}$ **propre avec minorante affine**.

- **Dfn. Conjuguée** $f^* : \mathbb{E} \rightarrow \mathbb{R} \cup \{+\infty\}$ de f :

$$f^*(x^*) := \sup_{x \in \mathbb{E}} (\langle x^*, x \rangle - f(x)).$$



Biconjuguée $f^{**} : \mathbb{E} \rightarrow \mathbb{R} \cup \{+\infty\}$ de f :

$$f^{**}(x) := \sup_{x^* \in \mathbb{E}} (\langle x^*, x \rangle - f^*(x^*)).$$

- **Prop.** On suppose que f est propre et a une minorante affine.

- 1) $f^* \in \overline{\text{Conv}}(\mathbb{E})$ et $f^{**} \in \overline{\text{Conv}}(\mathbb{E})$.
- 2) f^{**} est l'enveloppe supérieure des minorantes affines de f .
- 3) $f^{**} \leq f$.
- 4) $f^{**} = f \iff f \in \overline{\text{Conv}}(\mathbb{E})$.

Interprétation de $f^*(x^*)$ et f^{**}



Sous-différentiel des fonctions convexes (§ 3.5)

\mathbb{E} un e.v. muni de $\langle \cdot, \cdot \rangle$.

Différentiabilité directionnelle

$f \in \text{Conv}(\mathbb{E})$, $x \in \text{dom } f$ et $d \in \mathbb{E}$.

- 1) $t \in]0, +\infty[\mapsto \frac{f(x+td)-f(x)}{t}$ est croissante;
- 2) $f'(x; d)$ existe dans $\overline{\mathbb{R}}$;
- 3) $f'(x; \cdot)$ est convexe;
- 4) $x \in (\text{dom } f)^\circ \implies f'(x; \cdot)$ Lipschitz
 $f'(x; \cdot) \in \overline{\text{Conv}}(\mathbb{E})$.

Sous-différentiel

- **Dfn.** Le sous-différentiel $\partial f(x)$ de $f \in \text{Conv}(\mathbb{E})$ en $x \in \text{dom } f$ est l'ensemble des $x^* \in \mathbb{E}$ vérifiant les propriétés équivalentes :

- (S₁) $\forall d \in \mathbb{E} : f'(x; d) \geq \langle x^*, d \rangle$,
- (S₂) $\forall y \in \mathbb{E} : f(y) \geq f(x) + \langle x^*, y - x \rangle$,
- (S₃) $f(x) + f^*(x^*) = \langle x^*, x \rangle$ [ou \leq].

- **Prop.**

- 1) $\hat{x} \in \arg \min f \iff 0 \in \partial f(\hat{x})$.
- 2) $\partial f(x)$ est un convexe fermé.
- 3) $x \in (\text{dom } f)^\circ \implies$
 - $\partial f(x)$ compact non vide,
 - $f'(x; d) = \max_{x^* \in \partial f(x)} \langle x^*, d \rangle$.
- 5) f G-diff. en $x \iff \partial f(x) = \{\nabla f(x)\}$.

- **Calcul.**

Si $f_1, \dots, f_m : \mathbb{E} \rightarrow \mathbb{R}$ convexes et $\alpha_i \geq 0$

$$\partial \left(\sum_{i=1}^m \alpha_i f_i \right) (x) = \sum_{i=1}^m \alpha_i \partial f_i(x).$$

Exemple 1D





Figure 1: $f(x) = \max(x, x^2)$ et $\partial f(x)$ (en bas)

Exemple 2D




Figure 2: $f = \sup(q_1, q_2, q_3)$ et ∂f

III

Conditions d'optimalité (CO)

Le problème à résoudre :

$$(P_X) \quad \begin{cases} \min f(x) \\ x \in X, \end{cases}$$

où $X \subset E$ (espace euclidien, prod. scal. $\langle \cdot, \cdot \rangle$).

- Ce sont des $=$ et \leq décrivant les solutions de (P_X) .
- Utilité des CO :
 - Donner des renseignements sur (P_X) (calculer la solution analytiquement ?).
 - Vérifier qu'un point est solution.
 - Définir des algorithmes de résolution.
- Il y a des CO nécessaires (CN) et des CO suffisantes (CS).
- Il y a des CO du 1^{er} ordre (CN1, CS1) et des CO du 2^{ième} ordre (CN2, CS2).

CO sans contrainte (rappel, § 4.2)

Le problème à résoudre :

$$\begin{cases} \min f(x) \\ x \in \mathbb{E}. \end{cases}$$

On note $\nabla f(x)$ et $\nabla^2 f(x)$ les gradient et hessien de f en x pour $\langle \cdot, \cdot \rangle$.

- **CN1 :**

$$\nabla f(x_*) = 0.$$

(Si f est convexe, c'est une **CS1** globale.)

- **CN2 :**

$$\begin{cases} \nabla f(x_*) = 0 \\ \nabla^2 f(x_*) \succcurlyeq 0. \end{cases}$$

- **CS2** pour un minimum local strict :


$$\begin{cases} \nabla f(x_*) = 0 \\ \nabla^2 f(x_*) \succ 0. \end{cases}$$

CN1 générale (§ 4.1)

Le problème à résoudre :

$$(P_X) \quad \begin{cases} \min f(x) \\ x \in X. \end{cases}$$

Dfn : Cône tangent.



- **CN1.** On exprime plus ou moins le fait que f croît si on se déplace vers l'intérieur de X :

$$f'(x_*) \cdot d \geq 0, \quad \forall d \in T_{x_*} X, \quad (2)$$

où $T_{x_*} X$ est le cône tangent à X en x_* .

- **CN1.** Lorsque X est convexe, la relation (2) se simplifie en :

$$f'(x_*) \cdot (x - x_*) \geq 0, \quad \forall x \in X.$$

(Si f est convexe, c'est une **CS1** globale.)

CO avec contraintes d' = (§ 4.3)

Le problème à résoudre :

$$(P_E) \quad \begin{cases} \min f(x) \\ c(x) = 0 \in \mathbb{F}. \end{cases}$$

Le **lagrangien** du problème :

$$\ell(x, \lambda) = f(x) + \langle \lambda, c(x) \rangle.$$

- **CN1** : si $A_* := c'(x_*)$ est surjective, il existe $\lambda_* \in \mathbb{F}$, unique, tel que

$$\begin{cases} \nabla_x \ell(x_*, \lambda_*) = 0 \\ c(x_*) = 0. \end{cases} \quad (3)$$

(Si c affine, λ_* existe, pas néc. unique.)

(Si f est convexe et c est affine, ce sont des

CS1 globales.)

Si $\mathbb{F} = \mathbb{R}^m$, la première condition de (3) s'écrit

$$\nabla f(x_*) + \sum_{i=1}^m (\lambda_*)_i \nabla c_i(x_*) = 0.$$

- **CN2** : si $A_* := c'(x_*)$ est surjective, on a

$$\begin{cases} \nabla_x \ell(x_*, \lambda_*) = 0 \\ c(x_*) = 0 \\ \nabla_{xx}^2 \ell(x_*, \lambda_*) \succcurlyeq 0 \text{ sur } N(A_*). \end{cases}$$

- **CS2** pour un minimum local strict :

$$\begin{cases} \nabla_x \ell(x_*, \lambda_*) = 0 \\ c(x_*) = 0 \\ \nabla_{xx}^2 \ell(x_*, \lambda_*) \succ 0 \text{ sur } N(A_*). \end{cases}$$

CO avec contraintes $d' =$ et $d' \leq$ (§ 4.4)

Le problème à résoudre en $x \in \mathbb{E}$:

$$(P_{EI}) \quad \begin{cases} \min f(x) \\ c_E(x) = 0 \in \mathbb{R}^{m_E} \\ c_I(x) \leq 0 \in \mathbb{R}^{m_I}. \end{cases}$$

Le **lagrangien** du problème ($c := (c_E, c_I)$) :

$$\ell(x, \lambda) = f(x) + \lambda^\top c(x).$$

On note $I^0(x) := \{i \in I : c_i(x) = 0\}$.

- **CN1** : si les contraintes sont **qualifiées** en x_* , il existe $\lambda_* \in \mathbb{R}^m$ tel que

$$(KKT) \quad \begin{cases} \nabla_x \ell(x_*, \lambda_*) = 0 \\ c_E(x_*) = 0 \\ c_I(x_*) \leq 0 \\ (\lambda_*)_I \geq 0 \\ (\lambda_*)_I^\top c_I(x_*) = 0. \end{cases}$$

(Si f et c_I sont convexes et c_E est affine, ce sont des **CS1** globales.)

Qualification des contraintes (§ 4.4.2)

- **Dfn** : on dit que les contraintes de (P_{EI}) sont **qualifiées** en x si

$$T_x X = T'_x X, \quad (4)$$

où

$$T'_x X := \{d : c'_E(x) \cdot d = 0, c'_{I^0(x)}(x) \cdot d \leq 0\}.$$

On a toujours : $T_x X \subset T'_x X$.

- **Conditions suffisantes** de qualification des contraintes.
Régularité + l'une des conditions suivantes :

(QC-A) $c_{E \cup I^0(x)}$ est affine dans un voisinage de x .

(QC-S) c_E est affine avec c'_E surjective,
les composantes de $c_{I^0(x)}$ sont convexes,
 $\exists \hat{x} \in X$ tel que $c_{I^0(x)}(\hat{x}) < 0$.

(QC-IL) les gradients $\{\nabla c_i(x)\}_{i \in E \cup I^0(x)}$
sont linéairement indépendants.

(QC-MF) $\sum_{i \in E \cup I^0(x)} \alpha_i \nabla c_i(x) = 0$ et $\alpha_{I^0(x)} \geq 0$
 $\implies \alpha_{E \cup I^0(x)} = 0$.

Démarche suivie pour obtenir (KKT)

- On part de (2)
[i.e., f croît de x_* vers l'intérieur de X].
- On suppose que les contraintes sont qualifiées en x_* (on a (4) avec $x = x_*$). Dès lors

$$\nabla f(x_*) \in (T'_{x_*} X)^+. \quad (5)$$

- Lemme de Farkas :

$$\{d : Ad \geq 0\}^+ = \{A^\top \lambda : \lambda \geq 0\}.$$

C'est une généralisation de $N(A)^\perp = R(A^\top)$.

- Le lemme de Farkas permet d'exprimer (5) autrement : $\exists \lambda_* \in \mathbb{R}^m$ tel que l'on ait (KKT).

Signification des multiplicateurs optimaux (§ 4.7.1)

- Problème perturbé : pour $p \in \mathbb{R}^m$, on définit

$$(P_{EI}^p) \quad \begin{cases} \min f(x) \\ c_E(x) + p_E = 0 \\ c_I(x) + p_I \leq 0. \end{cases}$$

- **Dfn.** La **fonction valeur** associée à (P_{EI}^p) est $v : p \in \mathbb{R}^m \rightarrow \overline{\mathbb{R}}$ définie par

$$v(p) = \inf_{x \in X^p} f(x),$$

où X^p est l'ensemble admissible de (P_{EI}^p) .

$$(P_{EI}) \text{ convexe} \implies v \text{ convexe.}$$

- Cas différentiable régulier.

Si · (x_*, λ_*) solution PD de (P_{EI}) ,
 · $(\bar{x}(p), \bar{\lambda}(p))$ solution PD de (P_{EI}^p) ,
 · $p \mapsto \bar{x}(p)$ différentiable en 0, $\bar{x}(0) = x_*$,
 · $p \mapsto \bar{\lambda}(p)$ continue en 0, $\bar{\lambda}(0) = \lambda_*$,
alors $\lambda_* = \nabla v(0) = \nabla(f \circ \bar{x})(0)$.

- **Dfn.** (x_*, λ_*) est une **solution primale-duale globale** si

$$\begin{cases} x_* \in \arg \min \ell(\cdot, \lambda_*) \\ c_E(x_*) = 0, \quad c_I(x_*) \leq 0 \\ (\lambda_*)_I \geq 0, \quad (\lambda_*)_I^\top c_I(x_*) = 0. \end{cases}$$

- Cas convexe non différentiable.

Si · x_* est solution de (P_{EI}) ,

- v est convexe,
- $\partial v(0) \neq \emptyset$,

alors $\partial v(0) = \{\lambda_* : (x_*, \lambda_*) \text{ solution PD globale}\}.$

Remarque : Ci-dessus, $\partial v(0)$ peut être vide !
Avec qualification de Slater : $\partial v(0) \neq \emptyset$.

- CN et CS d'existence de solution PD globale.

CN d'optimalité (cas convexe non diff.).

Si · (P_{EI}) convexe (avec f et c finies),

- (Slater) : c'_E surjective, $\exists \hat{x} \in X$ t.q. $c_I(\hat{x}) < 0$
- x_* solution de (P_{EI}) ,

alors 1) v est loc. lipschitzienne dans un vois. de 0
2) $\partial v(0) \neq \emptyset$.

CS d'optimalité globale.

Peu de chance d'être applicable si (P_{EI}) non convexe.

Si (x_*, λ_*) solution PD globale,
alors x_* solution de (P_{EI}) .

IV Méthodes à directions de descente


Schéma des algorithmes (§ 6.1)

- Dfn : d est direction de descente de f en x si

$$f'(x) \cdot d < 0.$$

$\Rightarrow f$ décroît en x le long de d .

- **Algorithme à directions de descente** : il génère une suite $\{x_k\} \subset \mathbb{E}$ comme suit
 - Calcul d'une direction de descente d_k ;
 - Recherche linéaire : on détermine un pas $\alpha_k > 0$ le long de d_k ;
 - Nouvel itéré : $x_{k+1} := x_k + \alpha_k d_k$.



Exemples d'algorithmes à DD (§ 6.2)

On note $g_k := \nabla f(x_k)$.

- **Algorithme du gradient.**

$$d_k = -g_k.$$

- **Algorithme du gradient conjugué.**

$$d_k = \begin{cases} -g_1 & \text{si } k = 1 \\ -g_k + \beta_k d_{k-1} & \text{si } k \geq 2. \end{cases}$$

- **Algorithme de Newton.**

$$d_k = -\nabla^2 f(x_k)^{-1} g_k.$$

- **Algorithme de quasi-Newton.**

$$d_k = -M_k^{-1} g_k.$$

- **Algorithme de Gauss-Newton**

pour $f(x) = \frac{1}{2} \|r(x)\|_2^2$ et $J(x) := r'(x)$ injective :

$$d_k = -(J(x_k)^* J(x_k))^{-1} J(x_k)^* r(x_k).$$

La recherche linéaire (§ 6.3)

Deux techniques souvent utilisées : RL d'Armijo et RL de Wolfe.


Soient d_k une direction de descente et

$$h_k(\alpha) := f(x_k + \alpha d_k).$$

- **RL d'Armijo** ($0 < \omega_1 < \frac{1}{2}$, $0 < \tau < 1$)

$$h_k(\alpha_k) \leq h(0) + \omega_1 \alpha_k h'_k(0), \quad \alpha_k = \tau^{i_k},$$

où i_k est le plus petit dans $\{0, 1, 2, \dots\}$.




Valeurs typiques : $\omega_1 = 10^{-4}$ et $\tau = \frac{1}{2}$.

- **RL de Wolfe** ($0 < \omega_1 < \frac{1}{2}$, $\omega_1 < \omega_2 < 1$)

$$h_k(\alpha_k) \leq h(0) + \omega_1 \alpha_k h'_k(0),$$

$$h'_k(\alpha_k) \geq \omega_2 h'_k(0).$$



Valeurs typiques : $\omega_1 = 10^{-4}$ et $\omega_2 = 0.99$.

V

Méthodes à régions de confiance

Principe de l'algorithme (§ 8.1.1)

- Le problème :

$$\min_{x \in \mathbb{E}} f(x).$$

- **Modèle quadratique** de f autour d'un itéré x_k :
 $f(x_k + s) \simeq f(x_k) + \psi(s)$, où

$$\psi_k(s) := \langle g_k, s \rangle + \frac{1}{2} \langle M_k s, s \rangle.$$

- **Région de confiance** : région dans laquelle ce modèle est considéré comme bon. Le plus souvent

$$B(0, \Delta_k) := \{s \in \mathbb{E} : \|s\| \leq \Delta_k\}.$$

$\Delta_k > 0$ est le **rayon de confiance** du modèle.

- **Schéma d'un algorithme à RC** :

il génère une suite $\{x_k\}$ par

1. *Déplacement* :

$$s_k \simeq \arg \min_{\|s\| \leq \Delta_k} \psi_k(s);$$

2. *Appréciation du déplacement* :

si la **concordance**

$$\rho_k := \frac{f(x_k + s_k) - f(x_k)}{\psi(s_k)}$$

n'est pas bonne ($\rho_k \leq \omega_1$), diminuer Δ_k et retour en 1.

3. *Nouvel itéré* :

$$x_{k+1} = x_k + s_k.$$

4. *Nouveau modèle* :

– nouveau rayon de confiance

$$\Delta_{k+1} \in \begin{cases} [\tau_2 \Delta_k, \Delta_k] & \text{si } \rho_k \leq \omega_2 \\ [\Delta_k, \tau_3 \Delta_k] & \text{sinon.} \end{cases}$$

– calculer $g_{k+1} := \nabla f(x_{k+1})$, M_{k+1} .

Itérés générés par RC dans le contre-exemple de Powell

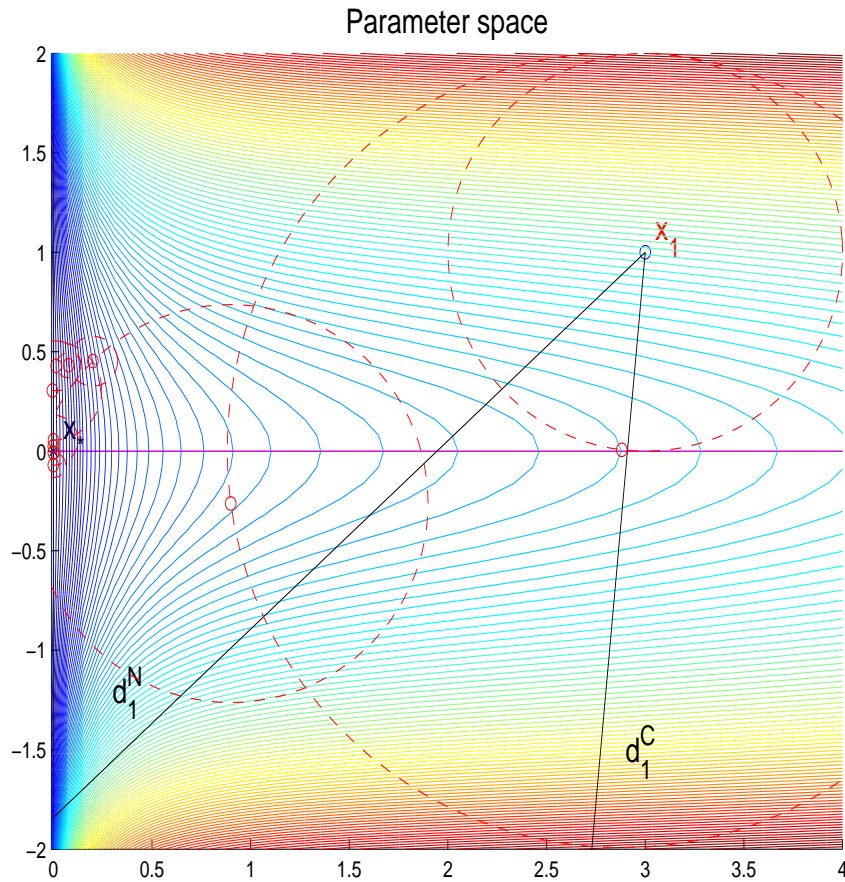


Figure 3: RC dans le contre-exemple de Powell

Résolution du problème quadratique (§§ 8.3.1, 8.4)

- **Le problème :**

$$\begin{cases} \min \langle g, s \rangle + \frac{1}{2} \langle Ms, s \rangle \\ \|s\| \leq \Delta. \end{cases}$$

- **CNS d'optimalité :** $\exists \hat{\lambda} \in \mathbb{R}$ tel que

$$\begin{cases} (M + \hat{\lambda}I)\hat{s} = -g \\ \|\hat{s}\| \leq \Delta, \quad \hat{\lambda} \geq 0 \\ \hat{\lambda}(\Delta - \|\hat{s}\|) = 0 \\ (M + \hat{\lambda}I) \succcurlyeq 0. \end{cases}$$

- *Résolution approchée :*

- algorithme dogleg de Powell
- algorithme du GC tronqué.

Résolution fine :

- algorithme de Moré-Sorensen.

VI Méthodes newtoniennes pour équations

Vitesse de convergence des suites (§ 5.1.1)

Soit $\{x_k\}$ une suite convergeant vers $x_* \in \mathbb{E}$.

On suppose que $x_k \neq x_*$, pour tout $k \geq 1$.

- **Convergence linéaire** : il existe une norme $\|\cdot\|$, un indice k_0 et $r \in [0, 1[$ tels que $\forall k \geq k_0$:

$$\frac{\|x_{k+1} - x_*\|}{\|x_k - x_*\|} \leq r.$$

- **Convergence superlinéaire** :

$$\frac{\|x_{k+1} - x_*\|}{\|x_k - x_*\|} \rightarrow 0.$$

- **Convergence quadratique** : il existe une constante $C > 0$ telle que $\forall k \geq 1$:

$$\frac{\|x_{k+1} - x_*\|}{\|x_k - x_*\|^2} \leq C.$$

$\chi_k =$ nombre de chiffres significatifs corrects.

k	superlinéaire		quadratique	
	x_k	χ_k	x_k	χ_k
1	2.000000000000000	0	2.000000000000000	0
2	1.500000000000000	0	0.866666666666667	1
3	0.61224489795918	1	-0.32323745064862	1
4	-0.16202797536640	1	-0.92578663808031	1
5	-0.92209500449059	1	-0.82332584261905	2
6	-0.78540447895661	1	-0.81774699537697	5
7	-0.81609056319699	3	-0.81773167400186	9
8	-0.81775774021392	5	-0.81773167388682	15
9	-0.81773165292101	8		
10	-0.81773167388656	13		
11	-0.81773167388682	15		

$$\begin{aligned}
 \text{Linéaire} &\implies \begin{cases} \exists \underline{\chi} > 0, \forall k \text{ grand} : \\ \chi_{k+1} - \chi_k \geq \underline{\chi}. \end{cases} \\
 \text{Superlinéaire} &\implies \chi_{k+1} - \chi_k \rightarrow \infty. \\
 \text{Quadratique} &\implies \liminf_{k \rightarrow \infty} \frac{\chi_{k+1}}{\chi_k} \geq 2.
 \end{aligned}$$

Algorithme de Newton pour systèmes non linéaires (§ 9.1.1)

Soit $F : \mathbb{E} \rightarrow \mathbb{F}$, avec $\dim \mathbb{E} = \dim \mathbb{F}$. On cherche à résoudre en x :

$$F(x) = 0.$$

- **Algorithme de Newton.** De x_k à x_{k+1} :


– Résoudre en d_k l'équation de Newton :

$$F'(x_k) d_k = -F(x_k). \quad (6)$$

– Nouvel itéré :

$$x_{k+1} = x_k + d_k.$$

- **Exemple 1D.**



- **Propriétés de l'algorithme de Newton.**

⊕⊕ Convergence quadratique *locale* :

Si · x_* vérifie $F(x_*) = 0$,

- F est $C^{1,1}$ dans un voisinage de x_* ,
- $F'(x_*)$ est inversible,

alors il existe un voisinage V de x_* tel que si $x_1 \in V$, l'algorithme de Newton (6) est bien défini et génère une suite $\{x_k\} \subset V$ qui converge *quadratiquement* vers x_* .

- ⊖ En général ne converge pas si x_1 n'est pas proche d'une solution.
- ⊖ Il faut calculer les dérivées premières de F .

Globalisation de l'algorithme de Newton par recherche linéaire (§ 9.3.1)

- **Dfn** : “globaliser” = forcer la convergence lorsque x_1 n’est pas voisin d’une solution.

- Une solution miracle ?

Si $F(x) \neq 0$, la direction de Newton en x ,

$$d^N = -F'(x)^{-1} F(x),$$

est une direction de descente de

$$f(x) = \frac{1}{2} \|F(x)\|_2^2.$$

On a $f'(x) \cdot d^N = -\|F(x)\|_2^2 < 0$.

- RL sur f le long de d^N : $x_+ := x + \alpha d^N$, avec $\alpha > 0$ tel que (ici $\omega_1 \in]0, \frac{1}{2}[$)

$$f(x_+) \leq f(x) + \alpha \omega_1 f'(x) \cdot d^N.$$

- Un résultat de convergence :

Si $\{F'(x_k)\}$ et $\{F'(x_k)^{-1}\}$ sont *bornées*,
alors l’algorithme de Newton avec une RL “convenable” converge vers un point stationnaire de f : $\nabla f(x_k) \rightarrow 0$.

- Cette approche ne converge pas toujours ... !

Globalisation de l'algorithme de Newton par régions de confiance (§ 9.3.2)

- **Principes :**

1. On ne s'intéresse plus qu'aux points stationnaires de

$$f(x) = \frac{1}{2} \|F(x)\|_2^2.$$

Remarque : la RL n'est pas toujours capable d'en trouver.

2. On prend comme modèle quadratique de f en x_k :

$$\varphi_k(s) := \frac{1}{2} \|F(x_k) + F'(x_k)s\|_2^2. \quad (7)$$

Avantage : minimiseur s_k est défini même si $F'(x_k)$ n'est pas inversible (c'est l'origine de l'affaiblissement des hypothèses).

3. On minimise φ_k sur une région de confiance :

$$\begin{cases} \min_s \varphi_k(s) \\ \|s\|_2 \leq \Delta_k. \end{cases} \quad (8)$$

- **Résultat de convergence :**

Si $\{F'(x_k)\}$ est *bornée*,
alors l'algorithme de Newton avec RC converge
vers un point stationnaire de $f : \nabla f(x_k) \rightarrow 0$.

Remarque : on n'a plus besoin d'hypothèse sur $F'(x)^{-1}$!

VII

Méthodes newtoniennes en optimisation (§ 9.1.2)

Soit le problème

$$\min_{x \in \mathbb{E}} f(x).$$

- On se déclare satisfait avec x_* vérifiant

$$\nabla f(x_*) = 0.$$

La relation $F = \nabla f$ permet d'adapter l'algorithme de Newton ($F'(x) = \nabla^2 f(x)$ est symétrique).

- **Algorithme de Newton.** De x_k à x_{k+1} :

- Résoudre en d_k l'équation de Newton :

$$\nabla^2 f(x_k) d_k = -\nabla f(x_k). \quad (9)$$


- Nouvel itéré :

$$x_{k+1} = x_k + d_k.$$

- Le **problème quadratique tangent**.

Le pas de Newton d_k est aussi un point stationnaire du problème quadratique

$$\min_{d \in \mathbb{E}} \left(f(x_k) + \nabla f(x_k)^\top d + \frac{1}{2} d^\top \nabla^2 f(x_k) d \right).$$



- **Propriétés de l'algorithme de Newton.**

⊕⊕ Convergence quadratique *locale* :

Si :

- x_* vérifie $\nabla f(x_*) = 0$,
- f est $C^{2,1}$ dans un voisinage de x_* ,
- $\nabla^2 f(x_*)$ est inversible,

alors il existe un voisinage V de x_* tel que si $x_1 \in V$, l'algorithme de Newton est bien défini et génère une suite $\{x_k\} \subset V$ qui converge *quadratiquement* vers x_* .

- ⊖ En général ne converge pas si x_1 n'est pas proche d'un point stationnaire.
- ⊖ Pas de distinction entre min, max, point stationnaire.
- ⊖ Les directions ne sont pas nécessairement de descente.
- ⊖ Il faut calculer les dérivées secondes de f .

Algorithmes de quasi-Newton (§ 10)

Soit le problème

$$\min_{x \in \mathbb{R}^n} f(x).$$

- Les **algorithmes de qN** génèrent 2 suites : $\{x_k\} \subset \mathbb{R}^n$ et $\{M_k\} \subset \mathbb{R}^{n \times n}$ sym. dfn. pos.

- 1) $d_k := M_k^{-1} g_k$;
- 2) $\alpha_k > 0$ par recherche linéaire;
- 3) $x_{k+1} := x_k + \alpha_k d_k$;
- 4) $M_{k+1} := U(M_k, y_k, s_k)$,
où $y_k := g_{k+1} - g_k$ et $s_k := x_{k+1} - x_k$.

- **Mise à jour de M_k .** On cherche à ce que M_{k+1} soit proche de M_k (stabilité), tout en vérifiant :
 - l'équation de qN : $y_k = M_{k+1} s_k$;
 - la symétrie : $M_{k+1}^\top = M_{k+1}$;
 - la définie positivité : M_{k+1} dfn. pos.

Cela conduit à la **formule de BFGS**.

$$M_{k+1} = M_k + \frac{y_k y_k^\top}{y_k^\top s_k} - \frac{M_k s_k s_k^\top M_k}{s_k^\top M_k s_k}.$$


VIII Problèmes de moindres-carrés

- Ce sont des problèmes de la forme

$$\min_{x \in \mathbb{R}^n} \|F(x)\|,$$

où $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$. En général $m \gg n$.

- **Exemple :** la **régression linéaire**.



Moindres-carrés linéaires (§ 16.1)

- **Problème :** on cherche une solution de

$$\min_{x \in \mathbb{R}^n} \|Ax - b\|_2, \quad (10)$$

où A est $m \times n$ et $b \in \mathbb{R}^m$.

- **Équation normale :**

$$A^T Ax = A^T b. \quad (11)$$

- **Existence de solution :**

- Le problème (10) a toujours une solution.
- Solution unique $\iff A$ est injective.
- Ensemble des solutions $= x_p + N(A)$.

- **Méthodes numériques :**

- Factorisation de Choleski de $A^T A$.
- GC sur (11).
- Factorisation QR de A .
- Factorisation SVD de A .

Moindres-carrés non linéaires (§ 16.2)

- **Problème** : on cherche une solution de

$$\min_{x \in \mathbb{R}^n} \left(f(x) := \frac{1}{2} \|r(x)\|_2^2 \right), \quad (12)$$

où $r : \mathbb{R}^n \rightarrow \mathbb{R}^m$ est non linéaire (les **résidus**).
Jacobienne $J \equiv J(x) \equiv r'(x)$, qui est $m \times n$.

- **Algorithme de Gauss-Newton** : RL le long de

$$d_k^{\text{GN}} \in \arg \min_{d \in \mathbb{R}^n} \frac{1}{2} \|r(x_k) + J(x_k)d\|_2^2.$$

On a $f'(x_k) \cdot d_k^{\text{GN}} \leq 0$ (< 0 si $\nabla f(x_k) \neq 0$).

Résultat de convergence :

Si $\{J(x_k)\}$ est bornée et unif. injective, i.e.,

$$\exists C > 0, \forall k \geq 1, \forall v \in \mathbb{R}^n :$$

$$C\|v\|_2 \leq \|J(x_k)v\|_2 \leq C^{-1}\|v\|_2,$$

alors l'algorithme de Gauss-Newton avec
RL converge vers un point stationnaire
de f (c'est-à-dire $J(x_k)^\top r(x_k) \rightarrow 0$).

- **Algorithme de Levenberg-Marquardt**
(révisé) : RC avec le modèle quadratique

$$\varphi_k(s) := \frac{1}{2} \|r(x_k) + J(x_k)s\|_2^2.$$

Résultat de convergence :

Si $\{J(x_k)\}$ est bornée,

alors l'algorithme de Levenberg-Marquardt avec
RC converge vers un point stationnaire de f
(c'est-à-dire $J(x_k)^\top r(x_k) \rightarrow 0$).

IX Pénalisation (§ 12)

- À quoi ça sert ?

En optimisation avec contraintes :

- pour la théorie: obtenir des propriétés à partir de problèmes approchés sans contrainte,
- pour l’algorithmique: résoudre un problème avec contraintes “sans trop en faire”.

- **Exemple.** On veut résoudre

$$(P) \quad \begin{cases} \min f(x) \\ c(x) \leq 0. \end{cases}$$

On *approche* ce problème par ($r > 0$)

$$(P_r) \quad \min f(x) + \frac{r}{2} \|c(x)^+\|_2^2,$$

que l’on résout par un algorithme de descente,
pour une suite de $r \rightarrow \infty$.

- Pénalisation ℓ_2 en 1D




Figure 4: Pénalisation quadratique

- **Pénalisation extérieure (§ 12.2).**

Plus généralement, si $X \subset \mathbb{E}$, on approche

$$(P_X) \quad \begin{cases} \min f(x) \\ x \in X \end{cases}$$

par une suite de problèmes sans contrainte

$$(P_r) \quad \min f(x) + rp(x),$$

où la fonction p vérifie

$$(H_p) \quad \begin{cases} p \text{ est continue sur } \mathbb{E} \\ p(x) \geq 0, \forall x \in \mathbb{E} \\ p(x) = 0 \iff x \in X. \end{cases}$$

Résultat d'approximation.

- Si · f continue et $f(x) \rightarrow +\infty$ lorsque $\|x\| \rightarrow \infty$,
 · X est fermé et non vide,
 · $p : \mathbb{E} \rightarrow \mathbb{R}$ vérifie (H_p) ,

- alors 1) $\forall r > 0$, (P_r) a au moins 1 solution \bar{x}_r ,
 2) $\{\bar{x}_r\}_{r \uparrow \infty}$ est bornée,
 3) tout point d'adhérence de la suite $\{\bar{x}_r\}_{r \uparrow \infty}$ est solution de (P_X) .

- \oplus et \ominus de l'approche par pénalisation

- \oplus Facile à mettre en œuvre (avec algo. sans contrainte).
- \ominus Suite de problèmes non linéaires (bon r inconnu, premier r très grand ne convient pas).
- \ominus Le mauvais conditionnement augmente avec r (i.e., les courbes de niveau s'allongent).


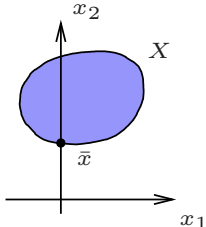


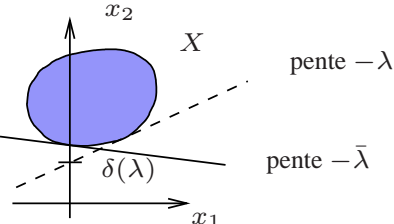
Figure 5: Chemin des minimiseurs

X Dualité (§ 13)

• Un premier problème :

$$(P) \quad \begin{cases} \inf x_2 \\ x \in X \\ x_1 = 0. \end{cases}$$


• Un second problème :

$$(D) \quad \sup_{\lambda \in \mathbb{R}} \delta(\lambda)$$


• (P) et (D) sont duaux l'un de l'autre.

• Intérêts de la dualité :

- obtenir des propriétés sur un problème à partir des propriétés d'un pbl dual (e.g., une borne sur la valeur optimale);
- construire des pbls duaux équivalents au pbl primal, mais plus faciles à résoudre;
- algorithmique : recherche de point-selle, du multiplicateur optimal.

Dualité min-max (§ 13.1)

Soient X un ensemble, $f : X \rightarrow \overline{\mathbb{R}}$ et

$$(P) \quad \inf_{x \in X} f(x).$$

• Réécriture du problème primal.

On suppose que

$$f(x) = \sup_{y \in Y} \varphi(x, y),$$

où $\varphi : X \times Y \rightarrow \overline{\mathbb{R}}$. Donc

$$(P) \quad \inf_{x \in X} \sup_{y \in Y} \varphi(x, y) = \text{val}(P).$$

• Le problème dual : on inverse l'inf et le sup

$$(D) \quad \sup_{y \in Y} \inf_{x \in X} \varphi(x, y) = \text{val}(D).$$

On peut aussi l'écrire $\inf_{y \in Y} \delta(y)$, où

$$\delta(y) := - \inf_{x \in X} \varphi(x, y). \quad (13)$$

- $\delta \equiv$ fonction duale,
- (13) \equiv problème interne en $y \in Y$.

Liens entre (P) et (D)

- **Dualité faible :**

$$\sup_{y \in Y} \inf_{x \in X} \varphi(x, y) \leq \inf_{x \in X} \sup_{y \in Y} \varphi(x, y).$$

$$\text{Saut de dualité} = \text{val}(D) - \text{val}(P) \geq 0.$$

- **Dfn :** On dit que (\bar{x}, \bar{y}) est un **point-selle** de φ sur $X \times Y$, si $\forall x \in X$ et $\forall y \in Y$

$$\varphi(\bar{x}, y) \leq \varphi(\bar{x}, \bar{y}) \leq \varphi(x, \bar{y}).$$

- **Théor :** (\bar{x}, \bar{y}) est un point-selle de φ sur $X \times Y$ SSI

- 1) \bar{x} est solution de (P) ,
- 2) \bar{y} est solution de (D) ,
- 3) il n'y a pas de saut de dualité.

- **Coroll :** Si φ a un point-selle (\bar{x}, \bar{y}) , alors les solutions de (P) sont solutions du pbl interne en $y = \bar{y}$.

Dualisation de contraintes fonctionnelles (§ 13.4)

On cherche à écrire un problème dual du problème d'optimisation avec contraintes :

$$(P_{X, EI}) \left\{ \begin{array}{l} \min f(x) \\ x \in X \\ c_E(x) = 0 \\ c_I(x) \leq 0. \end{array} \right.$$

où $X \subset \mathbb{E}$, sans qu'il y ait de saut de dualité.

Dualité lagrangienne (§ 13.4.1)

(problèmes convexes)

On prend pour φ , le lagrangien (ici $y \equiv \lambda$)

$$\ell(x, \lambda) = f(x) + \lambda^\top c(x).$$

- **Problème primal** : $Y := \mathbb{R}^{m_E} \times \mathbb{R}_+^{m_I}$ et

$$(P_{X,EI}) \equiv \inf_{x \in X} \sup_{\lambda: \lambda_I \geq 0} \ell(x, \lambda).$$

- **Problème dual** :

$$\sup_{\lambda: \lambda_I \geq 0} \inf_{x \in X} \ell(x, \lambda).$$

- **Résultat de dualisation** :

Si · $X = \mathbb{E}$,
 · $(P_{X,EI})$ est “convexe”
 (i.e., f et c_I convexes et c_E affine),
 · $(\bar{x}, \bar{\lambda})$ vérifie (KKT),
alors $(\bar{x}, \bar{\lambda})$ est point-selle de ℓ sur $\mathbb{E} \times Y$.

- **Relaxation lagrangienne (Uzawa)**

On passe de λ_k à λ_{k+1} par :

1. $x_k \in \arg \min_{x \in \mathbb{E}} \ell(x, \lambda_k)$,
2. arrêt si (x_k, λ_k) est satisfaisant,
3. $\lambda_{k+1} = P_Y [\lambda_k + \alpha_k c(x_k)]$.

Explications de la formule de mise à jour de λ_k
 (algorithme du gradient avec projection) :

- P_Y est le projecteur orthogonal sur Y
 (permet de maintenir les λ_k dans Y),
- $\alpha_k > 0$ est déterminé de manière à faire
 croître δ ,
- $-c(x_k)$ est un sous-gradient de δ .

Résultat de convergence :

Si · f fortement convexe, c_E affine et c_I convexe,
 · $(\bar{x}, \bar{\lambda})$ vérifie (KKT),
 · $\alpha_k > 0$ “petit”,
alors $x_k \rightarrow \bar{x}$.

Dualité lagrangienne augmentée (§ 13.4.2)

(problèmes non convexes)

On prend pour φ , le **lagrangien augmenté**

$$\begin{aligned} \ell_r(x, \lambda) = & f(x) + \sum_{i \in E} \left[\lambda_i c_i(x) + \frac{r}{2} c_i(x)^2 \right] \\ & + \sum_{i \in I} \left[\lambda_i \max \left(\frac{-\lambda_i}{r}, c_i(x) \right) + \right. \\ & \left. \frac{r}{2} \left(\max \left(\frac{-\lambda_i}{r}, c_i(x) \right) \right)^2 \right]. \end{aligned}$$

- **Problème primal :**

$$\inf_{x \in X} \sup_{\lambda \in \mathbb{R}^m} \ell_r(x, \lambda).$$

- **Problème dual :**

$$\sup_{\lambda \in \mathbb{R}^m} \inf_{x \in X} \ell_r(x, \lambda).$$

- **Résultat de dualisation :**

Si $\cdot X = \mathbb{E}$,

$\cdot (\bar{x}, \bar{\lambda})$ vérifie les CS2,

alors il existe un *voisinage* V de \bar{x} et un seuil $r_0 > 0$ tels que, pour tout $r \geq r_0$, $(\bar{x}, \bar{\lambda})$ est point-selle de ℓ_r sur $V \times \mathbb{R}^m$.

- **Relaxation lagrangienne augmentée (méthode des multiplicateurs)**

On passe de (λ_k, r_k) à (λ_{k+1}, r_{k+1}) par :

1. $x_k \in \arg \min_{x \in \mathbb{E}} \ell_{r_k}(x, \lambda_k)$,
2. arrêt si (x_k, λ_k) est satisfaisant,
3. $\lambda_{k+1} = P_Y [\lambda_k + r_k c(x_k)]$
(pas besoin de RL !),
4. adapter $r_k \rightsquigarrow r_{k+1}$ (heuristique).

XI Optimisation linéaire : simplexe

- On considère le problème d'optimisation linéaire sur \mathbb{R}^n (forme standard)

$$(P_L) \quad \begin{cases} \min c^\top x \\ Ax = b \\ x \geq 0, \end{cases}$$

où

- $c \in \mathbb{R}^n$,
- A est $m \times n$ surjective ($m \leq n$),
- $b \in \mathbb{R}^m$.

- On note

$$X := \{x \in \mathbb{R}^n : Ax = b, x \geq 0\}$$

l'ensemble admissible.

- Pour $x \in X$, on note

$$\begin{aligned} I^+(x) &:= \{i : x_i > 0\} \\ I^0(x) &:= \{i : x_i = 0\}. \end{aligned}$$

Structure de l'ensemble admissible (§ 17.2.1)

- On appelle **sommet** de X , un point $x \in X$ tel que

$$\begin{aligned} x_1, x_2 &\in X, \\ x &= (1-t)x_1 + tx_2, \quad t \in]0, 1[\\ \implies x &= x_1 = x_2. \end{aligned}$$

- Théor** (reconnaître un sommet) :

$x \in X$ est un sommet de X

\iff les colonnes $\{A^j : x_j > 0\}$ sont LI.

- Un sommet $x \in X$ est dit **non dégénéré**, si $|I^+(x)| = m$ (donc $A_{I^+(x)}$ est inversible)

- Théor** (existence de sommet) :

$$X \neq \emptyset$$

$\implies X$ a (au moins) un sommet.

Existence de solution (§ 17.2.2)

- **Théor** (existence de solution) :

(P_L) a une solution

$\iff (P_L)$ est réalisable et borné.

- **Théor** (existence de solution-sommet) :

(P_L) a une solution

$\implies (P_L)$ a une solution-sommet.

Conditions d'optimalité (§ 17.2.2)

- **Théor** :

(P_L) a une solution

$\iff \exists y \in \mathbb{R}^m, \exists s \in \mathbb{R}^n :$

$$\begin{cases} A^\top y + s = c, & s \geq 0, \\ Ax = b, & x \geq 0, \\ x^\top s = 0. \end{cases}$$

Algorithme du simplexe (§ 17.4)

(description géométrique)

- **Hypothèse** : A est $m \times n$ surjective.
- **Phase I** : trouver $\hat{x} \in X$, un sommet de X .

On prend $B \supset I^+(\hat{x})$ avec $|B| = m$ et
 $N = B^c \subset I^0(\hat{x})$.

- **Phase II** : on itère de sommet en sommet.

Voici une itération.

– Coût réduit : $r := c_N - A_N^\top A_B^{-\top} c_B$.

– Optimalité :

si $r \geq 0$, \hat{x} est solution (arrêt);

sinon $\exists j$ t.q. $r_j < 0$.

– Direction de déplacement d :

$d_N = e_N^j$ et $d_B = -A_B^{-1} A_N e_N^j$.

– Si $d_B \geq 0$, (P_L) est non borné (arrêt).

– Nouveau sommet \hat{x}^+ :

prendre le plus grand $\alpha \geq 0$ tel que

$$\hat{x}^+ := \hat{x} + \alpha d \in X$$

($\alpha > 0$ si \hat{x} est non dégénéré).

XII **Optimisation linéaire : points intérieurs**

La une du New York Times
(19 novembre 1984)

Voici comment l’algorithme de Karmarkar (le premier algorithme de points intérieurs) était “révélé” au grand public :

“The discovery, which is to be formally published next month, is already circulating rapidly through the mathematics world. It has also set off a deluge of inquiries from brokerage houses, oil companies and airlines, industries with millions of dollars at stake in problems known as linear programming.”

Notations

Le problème et son dual

$$(P) \quad \begin{cases} \inf c^\top x \\ Ax = b \\ x \geq 0, \end{cases} \quad (D) \quad \begin{cases} \sup b^\top y \\ A^\top y + s = c \\ s \geq 0. \end{cases}$$

Ensembles admissibles

$$\mathcal{F}_P := \{x \in \mathbb{R}^n : Ax = b, x \geq 0\}$$

$$\mathcal{F}_D := \{(y, s) \in \mathbb{R}^{m+n} : A^\top y + s = c, s \geq 0\}.$$

Intérieurs relatifs

$$\mathcal{F}_P^o := \{x \in \mathbb{R}^n : Ax = b, x > 0\}$$

$$\mathcal{F}_D^o := \{(y, s) \in \mathbb{R}^{m+n} : A^\top y + s = c, s > 0\}.$$

Conditions d’optimalité

$$\begin{cases} Ax = b, & x \geq 0 \\ A^\top y + s = c, & s \geq 0 \\ x^\top s = 0. \end{cases}$$

Le chemin central primal-dual (§ 18.1)

- Conditions d'optimalité perturbées par $\mu > 0$:

$$(\text{KKT}_\mu) \begin{cases} Ax = b & (x > 0) \\ A^\top y + s = c & (s > 0) \\ Xs = \mu e. \end{cases}$$

- Existence et unicité :

Si $\mathcal{F}_p^o \neq \emptyset, \mathcal{F}_D^o \neq \emptyset$ et $\mu > 0$,
alors (KKT_μ) a une solution unique.

Si $\mu = 0$, il y a existence mais pas néc. unicité !

- Dfn : le **chemin central** est l'ensemble des solutions de (KKT_μ) :

$$\{(x_\mu, y_\mu, s_\mu) : \mu > 0\}.$$

Algorithme PD de suivi de chemin

(éléments constitutifs, § 18.2)

- On suppose A surjective.
- Soit $z = (x, y, s)$ l'itéré courant **admissible**.
- Choix de

$$\mu := \frac{x^\top s}{n}.$$

- Facteur de réduction $\sigma \in]0, 1[$ de μ .
- Direction de Newton $dz = (dx, dy, ds)$

$$\begin{pmatrix} 0 & A^\top & I \\ A & 0 & 0 \\ S & 0 & X \end{pmatrix} \begin{pmatrix} dx \\ dy \\ dz \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \sigma \mu e - Xs \end{pmatrix}.$$

où $X = \text{diag}(x_i)$, $S = \text{diag}(s_i)$,
 $e = (1 \cdots 1)^\top$.

$$(x, s) > 0 \implies \text{SL inversible.}$$

- Nouvel itéré $z^+ = z + \alpha dz$.
- Contrôle du pas α pour que $(\gamma \simeq 10^{-3})$

$$z^+ \in V_{-\infty}(\gamma) := \{z \in \mathcal{F}^o : Xs \geq \gamma \mu e\}.$$

Algorithme PD de suivi de chemin

(algorithme des grands déplacements, § 18.3.3)

- **Paramètres :**

$0 < \sigma_{\min} < \sigma_{\max} < 1$ et $\gamma \in]0, 1[$.

- **Donnée :**

$z = (x, y, s) \in V_{-\infty}(\gamma)$ primal-dual
admissible (i.e., $Ax = b$ et $A^\top y + s = c$).

- **Une itération :**

- Choix de $\sigma \in]0, 1[$.
- Calcul de la direction de Newton dz .
- Choisir $\alpha \in [0, 1]$ le plus grand possible pour que $z + \alpha dz \in V_{-\infty}(\gamma)$.
- Nouvel itéré $z^+ := z + \alpha dz$.