

Méthodes d'Estimation : Examen Session Principale

Enseignants : Mme Mallek et Mr Malouche

Durée : 1h30

Exercice 1.

Pour modéliser la durée du phénomène du chômage X , on utilise généralement la distribution de Weibull dont la densité de probabilité a pour expression :

$$f(x, \theta) = \lambda \alpha x^{\alpha-1} \exp(-\lambda x^\alpha) \mathbb{1}_{\{x>0\}} \quad (\alpha, \lambda) \in \mathbb{R}_+^* \times \mathbb{R}_+^*$$

où α représente le coefficient de forme et l'inverse de λ désigne l'échelle du temps.

1. Soit $\underline{X} = (X_1, \dots, X_n)$ un n -échantillon de la variable aléatoire X .
 - (a) Ecrire la vraisemblance du modèle.
 - (b) En déduire une condition sur le coefficient de forme pour que le modèle appartienne à la famille exponentielle à un paramètre.

On suppose maintenant $\alpha = 2$.

- (a) Après avoir donné une statistique exhaustive pour le modèle, calculer son espérance et sa variance.
 - (b) Calculer l'information de Fisher et la borne de Cramer-Rao. conclure.
 - (c) Pouvait-on s'attendre à ce résultat.
2. On s'intéresse à l'estimation de λ
 - (a) Montrer que $\hat{\lambda} = \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right)^{-1}$ est l'unique estimateur du maximum de vraisemblance de λ .
 - (b) En admettant que $\sum_{i=1}^n X_i^2 \rightsquigarrow \gamma(n, \lambda)$, démontrer que $\hat{\lambda}$ est un estimateur biaisé de λ .
 - (c) Dédurre de $\hat{\lambda}$ un estimateur sans biais $\tilde{\lambda}$ de λ .
 - (d) Montrer que $\tilde{\lambda}$ est l'unique estimateur uvmb de λ .
 - (e) Est-il efficace de λ ? Est-il asymptotiquement efficace?
3. On considère la variable aléatoire $Q = 2\lambda X^2$.
 - (a) Sachant que $Q \rightsquigarrow \chi_2^2 = \gamma(1, \frac{1}{2})$, trouver une statistique pivotale.
 - (b) Donner un intervalle de confiance de niveau 0.95 Pour λ .

Exercice 2.

On dispose d'un n -échantillon d'une variable aléatoire X désignant le séquençage de l'ADN. X peut présenter 4 séquences possibles avec des probabilités respectives : $p_1 = 1 - \theta$; $p_2 = \theta - \theta^2$; $p_3 = \theta^2 - \theta^3$ et $p_4 = \theta^3$ où $0 \leq \theta \leq 1$.

Soient N_1, N_2, N_3 et N_4 les variables aléatoires "nombre d'occurences pour chacune des séquences $\left(\sum_{i=1}^4 N_i = n \right)$.

1. Donner l'expression de $P_\theta [X = x]$.
2. Ecrire la vraisemblance associée à l'échantillon.
3. Déterminer $\hat{\theta}$ l'estimateur par substitution de fréquence de θ et donner sa loi asymptotique.

Corrigé de l'exercice 1 :

$$1. f(x, \theta) = \lambda \alpha x^{\alpha-1} \exp(-\lambda x^\alpha) \mathbb{1}_{\{x>0\}} \quad \theta = (\alpha, \lambda) \in \mathbb{R}_+^* \times \mathbb{R}_+^*$$

$$(a) \mathcal{L}(x_1, \dots, x_n, \theta) = \lambda^n \alpha^n \prod_{i=1}^n x_i^{\alpha-1} \exp\left(-\lambda \sum_{i=1}^n x_i^\alpha\right) \mathbb{1}_{\{\underline{x} \in (\mathbb{R}_+^*)^n\}}$$

$$(b) \mathcal{L}(x_1, \dots, x_n, \theta) = \exp\left(-\lambda \sum_{i=1}^n x_i^\alpha + n \ln \lambda + n \ln \alpha + (\alpha - 1) \sum_{i=1}^n \ln x_i\right) \mathbb{1}_{\{\underline{x} \in (\mathbb{R}_+^*)^n\}}$$

Pour que le modèle appartienne à la famille exponentielle, il faudrait que α soit constante. Dans ce cas, on aura

$$T(\underline{x}) = -\sum_{i=1}^n x_i^\alpha \quad c(\lambda) = \lambda \quad d(\lambda) = n \ln \lambda \quad S(\underline{x}) = (\alpha - 1) \sum_{i=1}^n \ln x_i$$

$A = (\mathbb{R}_+^*)^n$ indépendante de λ .

On suppose maintenant $\alpha = 2$.

$$2. \mathcal{L}(x_1, \dots, x_n, \lambda) = \exp\left(-\lambda \sum_{i=1}^n x_i^2 + n \ln \lambda + n \ln 2 + \sum_{i=1}^n \ln x_i\right) \mathbb{1}_{\{\underline{x} \in (\mathbb{R}_+^*)^n\}}.$$

$$(a) T(\underline{X}) = -\sum_{i=1}^n X_i^2 \text{ est la statistique exhaustive complète pour le modèle}$$

La famille exponentielle est sous forme canonique. On a alors,

$$E_\lambda(T(\underline{X})) = -d'(\lambda) = -\frac{n}{\lambda}$$

$$Var(T(\underline{X})) = -d''(\lambda) = \frac{n}{\lambda^2}$$

$$(b) I_n(\lambda) = -E_\lambda \left[\frac{\partial^2}{\partial \lambda^2} \left(-\lambda \sum_{i=1}^n x_i^2 + n \ln \lambda + n \ln 2 + \sum_{i=1}^n \ln x_i \right) \right]$$

$$I_n(\lambda) = -E_\lambda \left[\left(-\frac{n}{\lambda^2} \right) \right] = \frac{n}{\lambda^2}.$$

$$BCR\left(-\frac{n}{\lambda}\right) = \frac{\left(\frac{\partial}{\partial \lambda} \left(-\frac{n}{\lambda}\right)\right)^2}{I_n(\lambda)} = \frac{\left(\frac{n}{\lambda^2}\right)^2}{\frac{n}{\lambda^2}} = \frac{n}{\lambda^2} = Var(T(\underline{X})).$$

$$T(\underline{X}) = -\sum_{i=1}^n X_i^2 \text{ est donc efficace pour son espérance.}$$

(c) Ce résultat était prévisible car il s'agit d'une famille exponentielle à un paramètre sous forme canonique où $d \mapsto n \ln \lambda$ est deux fois dérivable. $T(\underline{X})$ est donc efficace pour son espérance.

3. .

(a) La famille est exponentielle à un paramètre. L'application c est l'identité, elle est donc injective et de classe \mathcal{C}^2 ; d est aussi de classe \mathcal{C}^2 . Comme l'ensemble des valeurs de λ est un ouvert, alors si l'équation $E_\lambda(T(\underline{X})) = T(\underline{x})$ possède une solution, celle-ci correspondra à l'unique estimateur du maximum de vraisemblance.

$$E_\lambda(T(\underline{X})) = T(\underline{x}) \iff E_\lambda\left(-\sum_{i=1}^n X_i^2\right) = -\sum_{i=1}^n x_i^2 \iff -\frac{n}{\lambda} = -\sum_{i=1}^n x_i^2 \quad (\lambda > 0)$$

$$\iff \frac{n}{\sum_{i=1}^n x_i^2} = \lambda. \quad (x_i > 0, 1 \leq i \leq n).$$

L'estimateur du maximum de vraisemblance est donc $\hat{\lambda} = \left(\frac{1}{n} \sum_{i=1}^n X_i^2 \right)^{-1}$.

$$(b) \sum_{i=1}^n X_i^2 \rightsquigarrow \gamma(n, \lambda)$$

$$E_{\lambda}(\hat{\lambda}) = \int_0^{+\infty} \frac{n}{t} \frac{\lambda^n}{\Gamma(n)} t^{n-1} \exp -\lambda t \, dt = \frac{n\lambda\Gamma(n-1)}{\Gamma(n)} \int_0^{+\infty} \frac{\lambda^{n-1}}{\Gamma(n-1)} t^{n-2} \exp -\lambda t \, dt$$

$$E_{\lambda}(\hat{\lambda}) = \frac{n\lambda\Gamma(n-1)}{\Gamma(n)} = \frac{n}{n-1}\lambda \neq \lambda.$$

$$(c) \tilde{\lambda} = \frac{n-1}{n}\hat{\lambda} \quad E_{\lambda}(\tilde{\lambda}) = \lambda. \quad \tilde{\lambda} \text{ est sans biais.}$$

$$(d) \tilde{\lambda} = \frac{n-1}{\sum_{i=1}^n X_i^2} = -\frac{n-1}{T(\underline{X})}.$$

$\tilde{\lambda}$ est un estimateur sans biais de λ et fonction d'une statistique exhaustive complète. Il est donc uvmb ($T(\underline{X})$ est la statistique exhaustive complète associée à la famille exponentielle). Comme $\text{Var}(T(\underline{X})) = \frac{n}{\lambda^2} < \infty$, alors $\text{Var}(\tilde{\lambda}) < \infty$ et $\tilde{\lambda}$ est l'unique estimateur uvmb.

(e) $\tilde{\lambda}$ ne peut être efficace car l'estimateur du maximum de vraisemblance est biaisé et donc il n'existe pas d'estimateur efficace.

L'estimateur du maximum de vraisemblance $\hat{\lambda}$ est asymptotiquement efficace et comme $\tilde{\lambda} = \frac{n-1}{n}\hat{\lambda}$ avec $\lim_{n \rightarrow \infty} \frac{n-1}{n} = 1$, alors $\tilde{\lambda}$ est asymptotiquement efficace.

$$4. Q = 2\lambda X^2.$$

$$(a) Q \rightsquigarrow \chi_2^2 = \gamma\left(1, \frac{1}{2}\right)$$

$$2\lambda \sum_{i=1}^n X_i^2 \rightsquigarrow \chi_{2n}^2 \text{ (somme de } n \text{ variables aléatoires indépendantes de même loi } \chi_2^2)$$

$$(b) P_{\lambda} \left[F_{\chi_{2n}^2}^{-1}(\beta) \leq 2\lambda \sum_{i=1}^n X_i^2 \leq F_{\chi_{2n}^2}^{-1}(0.95 + \beta) \right] = 0.95$$

La distribution étant unimodale, on supposera $0.05 \leq 2 \min(F(x^*), 1 - F(x^*))$, où x^* désigne le mode. De ce fait, l'intervalle optimal est associé à $\beta = \frac{\alpha}{2}$.

$$P_{\lambda} \left[F_{\chi_{2n}^2}^{-1}(0.025) \leq 2\lambda \sum_{i=1}^n X_i^2 \leq F_{\chi_{2n}^2}^{-1}(0.975) \right] = 0.95$$

D'où l'intervalle de confiance pour λ :

$$IC_{0.95}(\lambda) = \left[\frac{F_{\chi_{2n}^2}^{-1}(0.025)}{2 \sum_{i=1}^n X_i^2}; \frac{F_{\chi_{2n}^2}^{-1}(0.975)}{2 \sum_{i=1}^n X_i^2} \right]$$

Corrigé de l'exercice 2 $p_1 = 1 - \theta$; $p_2 = \theta - \theta^2$; $p_3 = \theta^2 - \theta^3$ et $p_4 = \theta^3$ où $0 \leq \theta \leq 1$.

$$1. P[X = x] = (1 - \theta)^{\mathbb{1}_{\{x=1\}}} (\theta - \theta^2)^{\mathbb{1}_{\{x=2\}}} (\theta^2 - \theta^3)^{\mathbb{1}_{\{x=3\}}} \theta^3 \mathbb{1}_{\{x=4\}} \mathbb{1}(x)_{\{1,2,3,4\}}$$

$$2. \mathcal{L}(\underline{x}, \theta) = (1 - \theta)^{\sum_{i=1}^n \mathbb{1}_{\{x_i=1\}}} (\theta - \theta^2)^{\sum_{i=1}^n \mathbb{1}_{\{x_i=2\}}} (\theta^2 - \theta^3)^{\sum_{i=1}^n \mathbb{1}_{\{x_i=3\}}} \theta^3 \sum_{i=1}^n \mathbb{1}_{\{x_i=4\}} \mathbb{1}(\underline{x})_{\{1,2,3,4\}^n}$$

$$\mathcal{L}(\underline{x}, \theta) = (1 - \theta)^{N_1} (\theta - \theta^2)^{N_2} (\theta^2 - \theta^3)^{N_3} \theta^{3N_4} \mathbb{1}(\underline{x})_{\{1,2,3,4\}^n}$$

3. On a

$$\begin{cases} p_1 = 1 - \theta \\ p_2 = \theta - \theta^2 \\ p_3 = \theta^2 - \theta^3 \\ p_4 = \theta^3 \end{cases} \implies \theta = p_2 + p_3 + p_4 = h(p_2, p_3, p_4)$$

$$\widehat{\theta} = \widehat{p}_2 + \widehat{p}_3 + \widehat{p}_4 = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{x_i=2\}} + \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{x_i=3\}} + \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{x_i=4\}}$$

$$\widehat{\theta} = N_2 + N_3 + N_4$$

$$\sqrt{n} \left(\widehat{\theta} - \theta \right) \text{ converge en loi vers la loi normale } \mathcal{N}(0, \sigma^2)$$

$$\text{avec } \sigma^2 = \sum_{i=2}^4 p_i \left(\frac{\partial h}{\partial p_i} \right)^2 - \left(\sum_{i=2}^4 p_i \frac{\partial h}{\partial p_i} \right)^2$$

$$\sigma^2 = p_2 + p_3 + p_4 - (p_2 + p_3 + p_4)^2$$