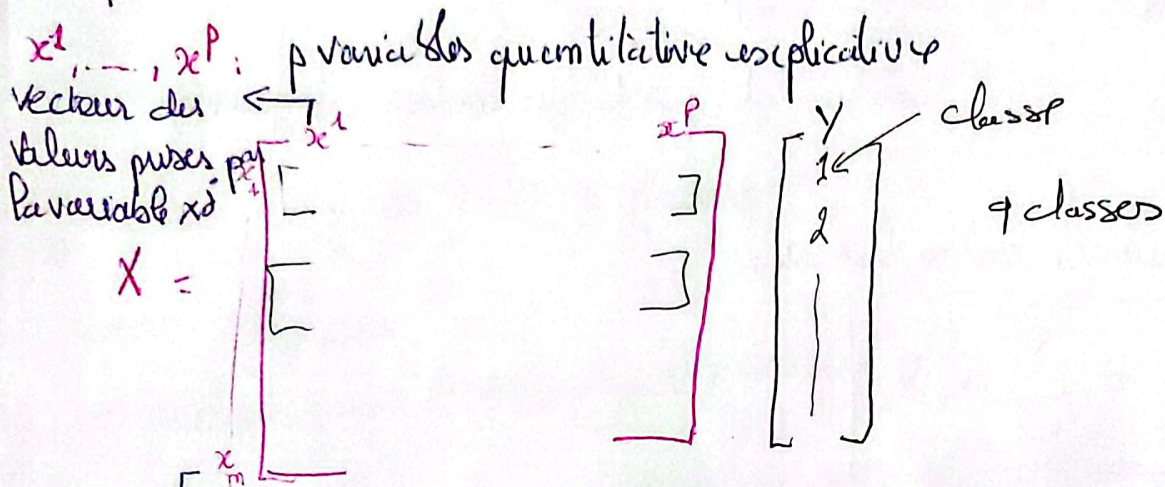


Analyse Factorielle Discriminante

Y qualitative : variable à expliquer



→ vecteur des valeurs prises par p individus i pour les p variables expl.

* p_i : masse de l'individu i avec $\sum_i p_i = 1$

* $D_p = \text{Diag}(p_i)$

* $\Pi_x =$ nuage des x_i

* $g =$ centre de gravité de $\Pi_x = \sum_{i \in I} p_i x_i$

* $V = X^T D_p X$

* I_K : l'ensemble des individus ayant adopté la modalité K
 ↳ classe K

$$n \left[m_K = |I_K| \right], \left[m_K = \sum_{i \in I_K} p_i \right], \left[g_K = \frac{1}{m_K} \sum_{i \in I_K} p_i x_i \right]$$

↓
 centre de gravité
 du nuage des indiv
 de I_K

centre de gravité

$$\sum_{K=1}^q m_K g_K = 0$$

⇒ Matrice centrée

* V_K : matrice de variance associée

tableau centré

$$G = \begin{bmatrix} g_1 \\ \vdots \\ g_q \end{bmatrix} \quad (q, p)$$

* Matrice de variance de G : B

$$B = G' D_m G \quad \begin{matrix} \nearrow \text{centres} \\ \downarrow \text{diag}(m_k) \end{matrix} \begin{pmatrix} g_1 - g \\ g_2 - g \end{pmatrix}$$

matrice de var interclasses

matrice des poids des centres de gravité

* Matrice variance intraclasses:

$$W = \sum_{k=1}^q m_k V_k$$

Relation fondamentale:

$$V = B + W$$

↳ matrice variance totale

* Problème:

$$\text{score } z = b_1 x^1 + b_2 x^2 + \dots + b_p x^p \quad t_g$$

1 Les classes sont séparées de façon optimale
 \Rightarrow variance de z entre les classes (interclasses) est max

2 Variance intra minimale

$$\text{Var}(z) = \text{cov}(z, z) = b' V b \quad b' = (b_1, \dots, b_p)$$

$$V = B + W$$

$$\text{Var}(z) = \underbrace{b' B b}_{\text{variance interclasses de } z} + \underbrace{b' W b}_{\text{variance intraclasses}} = \sum_k m_k \left(\frac{1}{m_k} \sum_{i \in I_k} p_i (z_i - \bar{z}^k)^2 \right)$$

$$\Rightarrow \text{on cherche à maximiser } \boxed{\eta^2 = \frac{b' B b}{b' V b}}$$

$$\begin{cases} V^{-1} B b = \lambda b \Rightarrow b \text{ est un vecteur propre de } V^{-1} B \\ b' V b = 1 \end{cases}$$

$$\lambda = \frac{b' B b}{\underbrace{b' V b}} : \lambda \in [0, 1] \text{ solution du problème obtenue}$$

↓ $\text{var}(z)$

* λ_1 : la plus grande valeur propre

* $z_{(1)}$: score solution

* $b_{(1)}$ le vecteur propre (normé pour V) associé à λ_1

→ On cherchera ensuite un second score $z_{(2)} = \sum_j b_{2j} x_j$ centre de la m^{ème} manière non corrélée à $z_{(1)}$.

$$z_{(\alpha)} = \sum_j b_{\alpha j} x_j$$

* r : rang de $V^{-1} B = \text{rg}(g^1, \dots, g^q)$

$$r \leq \min(p, q-1)$$

* $b_{(1)}, \dots, b_{(r)}$: facteurs discriminants

* $\lambda_1, \dots, \lambda_r$: pouvoirs discriminants

Axes factoriels discriminants \bar{L} :

$$\boxed{u^\alpha = V b_{\alpha}} \rightarrow \text{vecteurs associés factoriels du nuage } \Pi_G$$

$B V^{-1} u^\alpha = \lambda_\alpha u^\alpha \rightarrow \text{analyse en composante principale sur les nuages des points.}$

L'objectif de l'analyse discriminante est de produire un nouvel espace de représentation qui permet de distinguer le mieux les q classes.

Pourquoi l'ACP sur la matrice G : ^{car} En travail sur des groupes / classes

- La démarche consiste à produire une suite de variables discriminantes Z_k , non-corrélés deux à deux,

tel que les individus du même groupe projetés sur ces axes soient le plus proches possibles les uns des autres var intra B

• Les individus de groupes différents soient le plus éloignés possibles. var inter B

$$W = m_A V_A + m_B V_B$$

• vecteur axial factuel discriminant

$$u = \frac{g_A - g_B}{\|g_A - g_B\|_{V^{-1}}}$$

$$\|g_A - g_B\|_{V^{-1}}$$

facteur discriminant b est donné par :

$$b = V^{-1} u = \frac{1}{\lambda b}$$

• valeur propre discriminante

$$\lambda = m_A m_B \|g_A - g_B\|_{V^{-1}}^2$$

$$\lambda = \ln(B V^{-1})$$

- AFD descriptive \rightarrow déterminer des nouvelles variables qui sont des combinaisons linéaires des anciennes

$$Z(x_i) = \sum_j b_j x_{ij}$$

\rightarrow qui séparent le mieux possible les classes

\rightarrow pour cela on effectue l'ACP sur le tableau G des centres de gravités des classes

Ceci g^1 et g^2 c.d. g des classes $\{x_1, x_2\}$ avec la méthode V^{-1}

\rightarrow les nouvelles variables z_k appelées scores, sont les coord de tous les ind x_i projetés après centrage sur les axes de cette AC

\rightarrow il n'y a que 2 centres de g.

\rightarrow un seul axe factoriel

\downarrow
axe factoriel discriminant