

I - Présentation du modèle:

un modèle de régression simple s'écrit: $y_t = a + b x_t + u_t$, $t = 1, \dots, T$

avec:

- y désigne la variable endogène à expliquer
- x désigne la variable exogène à expliquer
- u la variable aléatoire ou terme d'erreur
- a et b : les paramètres à estimer du modèle

* H_1 : La série x_t n'est pas constante $\forall t \neq s \Rightarrow$ c'est l'hypothèse d'identifiabilité

* H_2 : $E(u_t) = 0$

* H_3 : $V(u_t) = \sigma^2$ (constant) $\forall t \Rightarrow$ c'est l'hypothèse d'homoscedasticité des erreurs

* H_4 : $\text{cov}(u_t, u_s) = 0 \forall t \neq s \Rightarrow$ c'est l'hypothèse d'absence d'autocorrélation des erreurs.

* H_5 : $u_t \sim N(0, \sigma^2) \Rightarrow$ c'est l'hypothèse de normalité des erreurs.

II - Estimation des paramètres du modèle:

1) Estimation par la méthode des moindres carrés ordinaires (MCO): a) Prop:

On appelle estimateurs des MCO noté \hat{a} et \hat{b} respectivement de a et b la solution du programme suivant: $\text{Min}_{a,b} \sum_{t=1}^T u_t^2 = \text{Min}_{a,b} \sum_{t=1}^T (y_t - a - b x_t)^2 = \text{Min}_{a,b} Q(a,b)$

b) Résolution du programme: $Q(a,b) = \sum_{t=1}^T (y_t - a - b x_t)^2$

$$\begin{cases} \frac{\partial Q}{\partial a} = 0 \\ \frac{\partial Q}{\partial b} = 0 \end{cases} \Rightarrow \begin{cases} -2 \sum_{t=1}^T (y_t - a - b x_t) = 0 \\ -2 \sum_{t=1}^T x_t (y_t - a - b x_t) = 0 \end{cases} \Rightarrow \begin{cases} \sum_{t=1}^T (y_t - a - b x_t) = 0 \quad (1) \\ \sum_{t=1}^T x_t (y_t - a - b x_t) = 0 \quad (2) \end{cases}$$

\Rightarrow système d'équation normales

$$\Rightarrow \begin{cases} \sum y_t - T a - b \sum x_t = 0 \\ \sum x_t y_t - a \sum x_t - b \sum x_t^2 = 0 \end{cases} \Rightarrow \begin{cases} \sum y_t = T a + b \sum x_t \\ \sum x_t y_t = a \sum x_t + b \sum x_t^2 \end{cases}$$

$$\Rightarrow \begin{cases} \bar{y} = a + b \bar{x} \quad (1) \\ \sum x_t y_t = a \sum x_t + b \sum x_t^2 \quad (2) \end{cases}$$

$$(1) \Rightarrow a = \bar{y} - b \bar{x}$$

$$\text{dans } (2) \Rightarrow \sum x_t y_t = (\bar{y} - b \bar{x}) T \bar{x} + b \sum x_t^2 \\ = T \bar{x} \bar{y} - T b \bar{x}^2 + b \sum x_t^2$$

$$(2) \Rightarrow \sum x_t y_t - T \bar{x} \bar{y} = b (\sum x_t^2 - T \bar{x}^2)$$

$$\Rightarrow \hat{b} = \frac{\sum x_i y_i - T \bar{x} \bar{y}}{\sum x_i^2 - T \bar{x}^2}, a$$

$$\Rightarrow \hat{a} = \bar{y} - \hat{b} \bar{x}$$

on montre que : $\hat{b} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\text{cov}(x, y)}{v(x)}$

La droite d'équation: $\hat{y}_t = \hat{a} + \hat{b} x_t$ est appelée **droite de régression de y_t sur x_t** ou **droite d'ajustement linéaire**.

Le point moyen de coordonnées $(\bar{x}, \bar{y}) \in \bar{a}$ cette droite.

Par ailleurs les points de coordonnées (x_t, y_t) forment un graphique appelé **nuage de points**. Ces points peuvent être alignés au pas, la droite d'ajustement linéaire est la meilleure droite résumant la structure du nuage.

• $\hat{y}_t = \hat{a} + \hat{b} x_t$: c'est la valeur ajustée ou estimée de y_t

• $\hat{u}_t = y_t - \hat{y}_t$: c'est le résidu de l'estimation

Propriétés :

Montrer que : $\sum_{t=1}^T \hat{u}_t = 0$ ①

$\sum_{t=1}^T x_t \hat{u}_t = 0$ ②

$\sum_{t=1}^T y_t = \sum_{t=1}^T \hat{y}_t$ ③

① $\sum_{t=1}^T \hat{u}_t = \sum (y_t - \hat{y}_t) = \sum (y_t - \hat{a} - \hat{b} x_t)$

$$\begin{cases} \sum (y_t - \hat{a} - \hat{b} x_t) = 0 \\ \sum x_t (y_t - \hat{a} - \hat{b} x_t) = 0 \end{cases} \Rightarrow \begin{cases} \sum \hat{u}_t = 0 \Rightarrow \sum y_t - \sum \hat{y}_t = 0 \\ \sum x_t \hat{u}_t = 0 \Rightarrow \sum y_t = \sum \hat{y}_t \end{cases}$$

2) Estimation par la méthode du maximum de vraisemblance :

Cette méthode constitue une autre technique d'estimation d'un modèle de régression. On suppose que l'erreur u_t suit $\mathcal{N}(0, \sigma^2)$, du moment que y_t est une f.m. linéaire de terme d'erreur $[y_t = a + b x_t + u_t]$, il s'en suit que $y_t \sim \mathcal{N}(\cdot, \cdot)$

• $E(y_t) = E(a + b x_t + u_t)$
 $= E(a + b x_t) + \underbrace{E(u_t)}_{=0}$

$\Rightarrow E(y_t) = a + b x_t$

$$\cdot V(y_t) = E(y_t - E(y_t))^2 = E[a + b\alpha_t + u_t - a - b\alpha_t]^2 = E(u_t^2) = V(u_t) = \sigma^2 \quad (2)$$

$\Rightarrow y_t \sim N(a + b\alpha_t, \sigma^2)$ avec : $\{y_t\}$ sont indépendantes. $\text{cov}(y_t, y_s) = 0 \quad \forall t \neq s$

Appel: \Rightarrow Liens téléchargement : <https://bit.ly/3T0Y0i2> \Rightarrow table de distribution de l'étudiant \Rightarrow démonstration détaillée de la méthode de Mv

Si X une v.a $\sim N(\mu, \sigma^2)$ alors sa densité de probabilité (d.d.p)

s'écrit comme suit : $f(x) = \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{1}{2} \left(\frac{x-\mu}{\sigma}\right)^2\right)$

\Rightarrow la d.d.p de y_t : $f(y_t) = \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{1}{2} \left(\frac{y_t - a - b\alpha_t}{\sigma}\right)^2\right)$

On note $f(y_1, y_2, \dots, y_T | a + b\alpha_t, \sigma^2)$ la fonction de probabilité jointe de l'ensemble (y_1, y_2, \dots, y_T) . Puisque les y_t sont indépendantes on peut écrire cette d.d.p :

$$\begin{aligned} f(y_1, y_2, \dots, y_T | a + b\alpha_t, \sigma^2) &= f(y_1 | a + b\alpha_1, \sigma^2) \times f(y_2 | a + b\alpha_2, \sigma^2) \times \dots \times f(y_T | a + b\alpha_T, \sigma^2) \\ &= \prod_{t=1}^T f(y_t | a + b\alpha_t, \sigma^2) \\ &= \left(\frac{1}{\sigma \sqrt{2\pi}}\right)^T \exp\left(-\frac{1}{2} \frac{\sum (y_t - a - b\alpha_t)^2}{\sigma^2}\right) \\ &= L(a, b, \sigma^2) \end{aligned}$$

\Rightarrow Il s'agit de la fonction de vraisemblance.

Pour des raisons de simplification on détermine la fonction

Log-vraisemblance \rightarrow on calcule $\log L \Rightarrow \text{Max}_{a, b, \sigma^2} \log L$

$$\Rightarrow \log L = -\frac{T}{2} \log 2\pi - \frac{T}{2} \log \sigma^2 - \frac{1}{2} \sum \left[\frac{(y_t - a - b\alpha_t)^2}{\sigma^2} \right]$$

$$\Rightarrow \text{Max}_{a, b, \sigma^2} \log L \Leftrightarrow \begin{cases} \frac{\partial \log L}{\partial a} = 0 & (1) \\ \frac{\partial \log L}{\partial b} = 0 & (2) \\ \frac{\partial \log L}{\partial \sigma^2} = 0 & (3) \end{cases}$$

(1) et (2) permettent d'obtenir le système d'équation normales relatif à la méthode des MCO.

Conséquence : $\begin{cases} \hat{a}_{MV} = \hat{a}_{MCO} \\ \hat{b}_{MV} = \hat{b}_{MCO} \end{cases}$

$$(3) \Rightarrow \hat{\sigma}_{MV}^2 = \frac{\sum (y_t - \hat{a} - \hat{b}\alpha_t)^2}{T} = \frac{\sum \hat{u}_t^2}{T} \neq \hat{\sigma}_{MCO}^2 = \frac{\sum \hat{u}_t^2}{T-2}$$

III - Equation, tableau d'analyse de la variance et coefficient de détermination :

1) Equation d'analyse de la variance :

On note par • VT = variabilité totale = $\frac{1}{T} \sum_{t=1}^T (y_t - \bar{y})^2$ avec.

$\sum (y_t - \bar{y})^2 = SCT$: Somme des carrés totale

• VE = variabilité Expliquée = $\frac{1}{T} \sum_{t=1}^T (\hat{y}_t - \bar{y})^2$ avec :

$\sum (\hat{y}_t - \bar{y})^2 = SCE$: Somme des carrés expliqué

• VR = variabilité Résiduelle = $\frac{1}{T} \sum_{t=1}^T \hat{u}_t^2$ avec

$\sum \hat{u}_t^2 = SCR$: Somme des carrés des résidu.

Propriétés :

La propriété dit que l'équation de d'analyse de la variance s'écrit comme suit :

$$VT = VE + VR \Rightarrow SCT = SCE + SCR$$

Démonstration :

$$\begin{aligned} SCT = \sum (y_t - \bar{y})^2 &= \sum ((y_t - \hat{y}_t) + (\hat{y}_t - \bar{y}))^2 \\ &= \sum [(y_t - \hat{y}_t)^2 + (\hat{y}_t - \bar{y})^2 + 2(y_t - \hat{y}_t)(\hat{y}_t - \bar{y})] \\ &= \sum (y_t - \hat{y}_t)^2 + \sum (\hat{y}_t - \bar{y})^2 + 2 \sum (y_t - \hat{y}_t)(\hat{y}_t - \bar{y}) \end{aligned}$$

$$\Rightarrow SCT = SCR + SCE$$

$$\sum \hat{u}_t (\hat{y}_t - \bar{y}) = \sum (\hat{u}_t \hat{y}_t - \hat{u}_t \bar{y}) = \sum \hat{u}_t \hat{y}_t - \bar{y} \sum \hat{u}_t \stackrel{=0}{=} 0 \Rightarrow SCT = SCE + SCR$$

$$\sum \hat{u}_t (\hat{y}_t - \bar{y}) = \sum \hat{u}_t (\hat{y}_t - \bar{y}) = \sum \hat{u}_t (a + b x_t - \bar{y}) = (a - \bar{y}) \cdot \sum \hat{u}_t + b \sum \hat{u}_t x_t \stackrel{=0}{=} 0$$

$$\hookrightarrow \boxed{SCT = SCE + SCR}$$

2) Tableau d'analyse de la variance :

Source de variation	Somme des carrés	Degré de liberté (d.l.P)	Carrés moyens ($\frac{\text{Somme des carrés}}{\text{ddl}}$)
variable explicative du modèle	$\sum (\hat{y}_t - \bar{y})^2 = SCE$	$1(k-1)$ $a, b = 2$	SCE
Résidu	$\sum \hat{u}_t^2 = SCR$	$T - 2$	$\frac{SCR}{T-2} = \hat{\sigma}^2_{res}$
Total	$\sum (y_t - \bar{y})^2 = SCT$	$T - 1$	$\frac{SCT}{T-1} = \frac{\sum (y_t - \bar{y})^2}{T-1}$

variance empirique corrigée.

3) Coefficient de détermination:

Déf: Le coef. de détermination noté R^2 est défini tq $R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$

avec $0 \leq R^2 \leq 1$, plus $R^2 \rightarrow 1$, plus $\hat{y}_t \rightarrow y_t$.

Exemple: si $R^2 = 98\%$: on a une bonne qualité d'ajustement linéaire du modèle.
plus $R^2 \rightarrow 0$: l'ajustement est mauvais.

Propriétés:

- $SCE = \hat{b}^2 \sum (\alpha_t - \bar{\alpha})^2$

- $R^2 = \frac{\hat{b}^2 \sum (\alpha_t - \bar{\alpha})^2}{\sum (y_t - \bar{y})^2}$

Démonstration:

$$SCE = \sum (\hat{y}_t - \bar{y})^2 = \sum (\hat{\alpha} + \hat{b}\alpha_t - \hat{\alpha} - \hat{b}\bar{\alpha})^2 = \hat{b}^2 \sum (\alpha_t - \bar{\alpha})^2$$

$$R^2 = \frac{SCE}{SCT} = \frac{\hat{b}^2 \sum (\alpha_t - \bar{\alpha})^2}{\sum (y_t - \bar{y})^2}$$

Notation:

- $m_{\alpha\alpha} = \sum (\alpha_t - \bar{\alpha})^2 = \sum \alpha_t^2 - T\bar{\alpha}^2$

- $m_{yy} = \sum (y_t - \bar{y})^2 = \sum y_t^2 - T\bar{y}^2$

- $m_{\alpha y} = \sum (\alpha_t - \bar{\alpha})(y_t - \bar{y}) = \sum \alpha_t y_t - T\bar{\alpha}\bar{y}$

on montre que:

$$R^2 = \frac{m_{\alpha y}^2}{m_{\alpha\alpha} m_{yy}} = \rho_{\alpha y}^2$$

avec: $\rho_{\alpha y}$: le coefficient de corrélation entre α et y

$$\rho_{\alpha y} = \frac{\text{cov}(\alpha_t, y_t)}{\sqrt{V(\alpha_t) V(y_t)}} = \frac{\frac{1}{T} \sum (\alpha_t - \bar{\alpha})(y_t - \bar{y})}{\sqrt{\frac{1}{T} \sum (\alpha_t - \bar{\alpha})^2 \sum (y_t - \bar{y})^2}}$$

$$\Rightarrow \rho_{\alpha y} = \frac{m_{\alpha y}}{\sqrt{m_{\alpha\alpha} m_{yy}}} \Rightarrow \rho_{\alpha y}^2 = \frac{m_{\alpha y}^2}{m_{\alpha\alpha} m_{yy}}$$

$$R^2 = \hat{b}^2 \frac{\sum (\alpha_t - \bar{\alpha})^2}{\sum (y_t - \bar{y})^2} \Rightarrow \rho_{\alpha y}^2 = R^2$$

$$= \frac{m_{\alpha y}^2}{m_{\alpha\alpha}^2} \cdot \frac{m_{\alpha\alpha}}{m_{yy}} = \frac{m_{\alpha y}^2}{m_{\alpha\alpha} m_{yy}} = \rho_{\alpha y}^2$$

IV - Propriétés statistiques des estimateurs:

Préliminaire:

On pose $w_t = \frac{\alpha_t - \bar{\alpha}}{\sum (\alpha_t - \bar{\alpha})^2} = \frac{\alpha_t - \bar{\alpha}}{m_{\alpha\alpha}}$

Démonstration:

$$1) \sum w_t = \frac{\sum (\alpha_t - \bar{\alpha})}{m_{\alpha\alpha}} = \frac{\sum \alpha_t - \tau \bar{\alpha}}{m_{\alpha\alpha}} = \frac{\tau \bar{\alpha} - \tau \bar{\alpha}}{m_{\alpha\alpha}} = 0$$

Après on aura:

1) $\sum w_t = 0$

2) $\sum \alpha_t w_t = 1$

3) $\sum w_t^2 = \frac{1}{m_{\alpha\alpha}}$

$$2) \sum \alpha_t w_t = \frac{\sum \alpha_t (\alpha_t - \bar{\alpha})}{m_{\alpha\alpha}} = \frac{\sum \alpha_t^2 - \bar{\alpha} \sum \alpha_t}{m_{\alpha\alpha}} = \frac{\sum \alpha_t^2 - \tau \bar{\alpha}^2}{m_{\alpha\alpha}} = \frac{m_{\alpha\alpha}}{m_{\alpha\alpha}} = 1$$

$$3) \sum w_t^2 = \frac{\sum (\alpha_t - \bar{\alpha})^2}{m_{\alpha\alpha}^2} = \frac{m_{\alpha\alpha}}{m_{\alpha\alpha}^2} = \frac{1}{m_{\alpha\alpha}}$$

Propriétés:

P₁: \hat{a} et \hat{b} sont des estimateurs linéaires c-à-d. ils s'écrivent sous la forme d'une combinaison linéaire de y_t . ($1 = \sum c_t y_t$)

$$\bullet \hat{b} = \frac{\sum (\alpha_t - \bar{\alpha})(y_t - \bar{y})}{\sum (\alpha_t - \bar{\alpha})^2} = \frac{\sum [(\alpha_t - \bar{\alpha}) y_t - (\alpha_t - \bar{\alpha}) \bar{y}]}{\sum (\alpha_t - \bar{\alpha})^2} = \frac{\sum (\alpha_t - \bar{\alpha}) y_t - \bar{y} \sum (\alpha_t - \bar{\alpha})}{m_{\alpha\alpha}}$$

$$\Rightarrow \hat{b} = \frac{\sum (\alpha_t - \bar{\alpha}) y_t}{m_{\alpha\alpha}} = \sum w_t y_t$$

$\Rightarrow \hat{b}$ est un estimateur linéaire.

$$\bullet \hat{a} = \bar{y} - \hat{b} \bar{\alpha} = \frac{1}{\tau} \sum y_t - \sum w_t y_t \bar{\alpha} = \sum \left(\frac{1}{\tau} - w_t \bar{\alpha} \right) y_t$$

$$\Rightarrow \hat{a} = \sum \left(\frac{1}{\tau} - w_t \bar{\alpha} \right) y_t \Rightarrow \hat{a} = \sum A_t y_t \Rightarrow \hat{a} = \sum A_t y_t$$

$\Rightarrow \hat{a}$ est un estimateur linéaire.

P₂: \hat{a} est un estimateur sans biais $\Rightarrow E(\hat{a}) = a$

\hat{b} est un estimateur sans biais $\Rightarrow E(\hat{b}) = b$

Démonstration:

$$\hat{a} = \sum \left(\frac{1}{\tau} - w_t \bar{\alpha} \right) y_t$$

$$= \sum \left(\frac{1}{\tau} - w_t \bar{\alpha} \right) (a + b \alpha_t + u_t)$$

$$= a + b \bar{\alpha} - a \bar{\alpha} \underbrace{\sum w_t}_{=1} - b \bar{\alpha} \sum w_t \alpha_t + \sum \left(\frac{1}{\tau} - w_t \bar{\alpha} \right) u_t$$

$$\Rightarrow \hat{a} = a + \sum \left(\frac{1}{\tau} - w_t \bar{\alpha} \right) u_t$$

$$\Rightarrow E(\hat{a}) = a + \sum \underbrace{\left(\frac{1}{\tau} - w_t \bar{\alpha} \right)}_0 E(u_t) \Rightarrow E(\hat{a}) = a$$

$\Rightarrow \hat{a}$ est un estimateur sans biais de a .

$$\begin{aligned} \bullet \hat{b} &= \sum w_t y_t = \sum w_t (a + b x_t + u_t) = a \underbrace{\sum w_t}_0 + b \underbrace{\sum x_t w_t}_1 + \sum w_t u_t \\ &\Rightarrow \hat{b} = b + \sum w_t u_t \\ &\Rightarrow E(\hat{b}) = b + \sum w_t E(u_t) \Rightarrow E(\hat{b}) = b \\ &\Rightarrow \hat{b} \text{ est un estimateur sans biais de } b. \end{aligned}$$

$$\begin{aligned} P_3: \bullet V(\hat{a}) &= \sigma^2 \left(\frac{1}{T} + \frac{\bar{x}^2}{\sum (x_t - \bar{x})^2} \right) \\ \bullet V(\hat{b}) &= \frac{\sigma^2}{\sum (x_t - \bar{x})^2} \quad \sigma^2 = \text{Var}(u_t) \\ \bullet \text{Cov}(\hat{a}, \hat{b}) &= \frac{-\sigma^2 \bar{x}}{\sum (x_t - \bar{x})^2} \end{aligned}$$

$$\begin{aligned} \bullet V(\hat{a}) &\rightarrow 0 \text{ quand } T \rightarrow \infty \\ &\Rightarrow \hat{a} \text{ est un estimateur convergent} \\ \bullet V(\hat{b}) &\rightarrow 0 \text{ quand } T \rightarrow \infty \\ &\Rightarrow \hat{b} \text{ est un estimateur convergent} \end{aligned}$$

Théorème de Gauss-Markov

Si les hypothèses de la HCO sont toutes vérifiées Alors \hat{a} et \hat{b} sont des estimateurs B.L.U.E (Best Linear Unbiased Estimator)
C'est à dire les meilleurs estimateurs linéaires et sans biais de \hat{a} et \hat{b} respectivement

V - Construction des tests statistiques:

1) Estimation de σ^2 :

Théorème: $\sum_{t=1}^T \hat{u}_t^2$

$$\hat{\sigma}_{mco}^2 = \frac{\sum_{t=1}^T \hat{u}_t^2}{\text{Nombre d'observations totales} - \text{Nombre de paramètres à estimer}}$$

$$\Rightarrow \hat{\sigma}_{mco}^2 = \frac{SCR}{T-2} \text{ est un estimateur sans biais de } \sigma^2.$$

2) Notations et définitions:

$$\begin{aligned} \bullet \hat{V}(\hat{a}) &= \hat{\sigma}^2 \left(\frac{1}{T} + \frac{\bar{x}^2}{\sum (x_t - \bar{x})^2} \right) = \hat{\sigma}_{\hat{a}}^2 \Rightarrow \text{la variance estimée de } \hat{a} \\ \bullet \hat{V}(\hat{b}) &= \frac{\hat{\sigma}^2}{\sum (x_t - \bar{x})^2} = \hat{\sigma}_{\hat{b}}^2 \Rightarrow \text{la variance estimée de } \hat{b} \\ \bullet \hat{\text{Cov}}(\hat{a}, \hat{b}) &= \frac{-\hat{\sigma}^2 \bar{x}}{\sum (x_t - \bar{x})^2} \Rightarrow \text{la covariance estimée entre } \hat{a} \text{ et } \hat{b}. \end{aligned}$$

3) Hypothèse de normalité et intervalle de confiance:

L'hypothèse de normalité d'erreurs implique que l'estimateur:

$$\begin{cases} \hat{a} \sim N(a, \hat{\sigma}_a^2) \\ \hat{b} \sim N(b, \hat{\sigma}_b^2) \end{cases} \Leftrightarrow \begin{cases} \frac{\hat{a} - a}{\hat{\sigma}_a} \sim N(0,1) \\ \frac{\hat{b} - b}{\hat{\sigma}_b} \sim N(0,1) \end{cases}$$

Théorème de Fisher: (admis)

- $(T-2) \frac{\hat{\sigma}^2}{\sigma^2} \sim \chi^2(T-2)$
- \hat{a} et $\hat{\sigma}$ sont indépendants
- \hat{b} et $\hat{\sigma}$ sont indépendants



Rappel:

Soient U et K deux variables aléatoires indépendantes telles que:

$$U \sim N(0,1) \text{ et } K \sim \chi^2(m)$$

Alors, par définition on a:

$$T = \frac{U}{\sqrt{\frac{K}{m}}} \sim St(m)$$

Corollaire:

$$\begin{cases} \frac{\hat{a} - a}{\hat{\sigma}_a} \sim St(T-2) \\ \frac{\hat{b} - b}{\hat{\sigma}_b} \sim St(T-2) \end{cases}$$

démonstration: $\frac{\frac{\hat{b} - b}{\hat{\sigma}_b}}{\sqrt{\frac{(T-2) \frac{\hat{\sigma}^2}{\sigma^2}}{T-2}}} \sim St(T-2) \Leftrightarrow \frac{\hat{b} - b}{\hat{\sigma}_b / \sqrt{m_{res}}} = \frac{\hat{b} - b}{\hat{\sigma}_b} \sim St(T-2)$

Intervalle de confiance pour les paramètres a et b :

Soit α le risque d'erreur ou encore le seuil de significativité, il est généralement égal à 1%, 5% ou 10%, son complémentaire $1-\alpha$ est appelé le niveau de confiance, les étapes à suivre pour construire un intervalle de confiance sont les suivantes:

1^{ère} étape: Détermination de la statistique à utiliser et de sa loi de probabilité

$$\frac{\hat{b} - b}{\hat{\sigma}_b} \sim St(T-2)$$

2^{ème} étape: α étant fixé, on cherche dans la table de la loi de Student le réel noté $t_{\alpha/2}^{T-2}$ tq: $P\left[\left|\frac{\hat{b} - b}{\hat{\sigma}_b}\right| \leq t_{\alpha/2}^{T-2}\right] = 1 - \alpha$

valeur critique

3^{ème} étape: L'intervalle de confiance au niveau $1-\alpha$ pour le paramètre b

s'écrit comme suit: $IC_{1-\alpha}(b) = \left[\hat{b} \pm \left(\hat{\sigma}_b \cdot t_{\alpha/2}^{T-2} \right) \right]$ Précision de l'estimation

$$= \left[\hat{b} - \hat{\sigma}_b \cdot t_{\alpha/2}^{T-2}, \hat{b} + \hat{\sigma}_b \cdot t_{\alpha/2}^{T-2} \right]$$

Exemple :

$$T = 30 \text{ et } \alpha = 5\% \Rightarrow t_{\alpha/2}^{T-2} = t_{0.025}^{28} = 2.048.$$

(5)

4) Les Tests d'hypothèse:

Ces tests permettent d'apporter des réponses à des problèmes tq :

- 1) La comparaison d'un coefficient de régression γ à une valeur fixe.
- 2) La détermination d'un IC pour un coefficient

On distingue 2 types de tests :

- Le test unilatéral : (on travaille avec α)
- $H_0: b \leq b_0$ (donnée) contre $H_1: b > b_0$ (donnée).
- La statistique et la loi : $\frac{\hat{b} - b_0}{\hat{\sigma}_b} \sim St(T-2)$
- Règle de décision : si $t_{calculée} = \frac{\hat{b} - b_0}{\hat{\sigma}_b} \leq t_{\alpha}^{T-2}$ alors H_0 est vraie
- $\Rightarrow b \leq b_0$
- si $t_c > t_{\alpha}^{T-2}$ alors H_1 est vraie $\Rightarrow b > b_0$

• Le test bilatéral :

- $H_0: b = b_0$ (donnée) contre $H_1: b \neq b_0$
- Statistique et loi : $\frac{\hat{b} - b_0}{\hat{\sigma}_b} \sim St(T-2)$

Règles de décision :

- 1) Règle selon l'approche par les valeurs critiques :
- si $t_c = \left| \frac{\hat{b} - b_0}{\hat{\sigma}_b} \right| \leq t_{\alpha/2}^{T-2}$ alors H_0 est vraie $\Rightarrow b = b_0$
- si $t_c = \left| \frac{\hat{b} - b_0}{\hat{\sigma}_b} \right| > t_{\alpha/2}^{T-2}$ alors H_1 est vraie $\Rightarrow b \neq b_0$
- 2) Règle selon l'approche par l'IC (Règle de décision équivalente) :
- si $b_0 \in IC_{1-\alpha}(b)$ alors H_0 est vraie.
- si $b_0 \notin IC_{1-\alpha}(b)$ alors H_1 est vraie.

Cas particulier du test bilatéral : le test de significativité individuelle des paramètres :

Ce test permet d'étudier l'impact de la variable explicative x sur la variable à expliquer y . Il repose sur les hypothèses suivantes :

$$\underbrace{H_0: b = 0}_{\text{Si vrai}} \text{ contre } \underbrace{H_1: b \neq 0}_{\text{Si vraie}}$$

$\Rightarrow b$ est statistiquement significatif

$\Rightarrow b$ est statistiquement significatif

① la variable x a un impact non significatif sur y

la variable x est une variable neutre

Si on accepte l'hypothèse Null H_0 alors le paramètre b est statistiquement non significatif.

VI - La prévision:

1) Définition et notation:

Une fois que les coefficients du modèle sont estimés, il est possible de calculer une prévision à un horizon h c-à-d déterminer une valeur future de y à une période $(T+h)$ connaissant la valeur future $x_{T+h} \longrightarrow y_{T+h}?$

Exemple: $y_t = a + b x_t + u_t$

$\forall t = 2000, \dots, 2021 \Rightarrow y = y_{T+2} \Rightarrow h = 2 \text{ ans}$

Soient:

- y_{T+h} : la valeur réelle de y à l'instant futur $(T+h) + q$:

$$\Rightarrow y_{T+h} = a + b x_{T+h} + u_{T+h}$$

Avec: $E(u_{T+h}) = 0$

- $V(u_{T+h}) = \sigma^2$

- $\text{cov}(u_t, u_{T+h}) = 0, \forall t = 1, \dots, T$

- y_{T+h}^p : la valeur prévisionnelle de y à l'instant futur $(T+h) \Rightarrow$

la prévision ponctuelle de y .

- Prévision exposé (après réalisation)

$$\Rightarrow y_{T+h}^p = \hat{a} + \hat{b} x_T + h$$

- e_p : erreur de prévision $\Rightarrow e_p = y_{T+h} - y_{T+h}^p$

avec: on montre que:

- $E(e_p) = 0$

- $V(e_p) = \sigma_{e_p}^2 = \sigma^2 \left(1 + \frac{1}{T} + \frac{(x_{T+h} - \bar{x})^2}{\sum (x_t - \bar{x})^2} \right)$

$$\Rightarrow \hat{\sigma}_{e_p}^2 = \hat{\sigma}^2 \left[1 + \frac{1}{T} + \frac{(x_{T+h} - \bar{x})^2}{\sum (x_t - \bar{x})^2} \right]$$

variance estimée
de l'erreur de prévision

on note par $IP_{1-\alpha}(y_{T+h})$ l'intervalle de prévision pour y_{T+h} au niveau de confiance $(1-\alpha)$.

Théorème (admis) :

- $\frac{y_{T+h} - y_{T+h}^p}{\hat{G}_{ep}} \sim St(T-2)$
- $t_{\alpha/2}^{T-2} / P \left[\left| \frac{y_{T+h} - y_{T+h}^p}{\hat{G}_{ep}} \right| \leq t_{\alpha/2}^{T-2} \right] = 1 - \alpha$
- $IP_{1-\alpha}(y_{T+h}) = \left[y_{T+h}^p \pm \hat{G}_{ep} \times t_{\alpha/2}^{T-2} \right]$ avec: $\hat{G}_{ep} = \sqrt{\hat{G}_{ep}^2}$

Remarques Générales:

- ① Les tests d'hypothèse (uni et bi) peuvent aussi être appliqués pour la constante du modèle à savoir le paramètre a .
- ② Comme le coefficient de détermination R^2 on définit également le coefficient de détermination ajusté du corrigé noté \bar{R}^2 tq:

$$\bar{R}^2 = 1 - \frac{SCR / T-2}{SCT / T-1} \rightsquigarrow \bar{R}^2 = \frac{T-1}{T-2} \cdot \frac{SCR}{SCT}$$

③ Présentation des résultats d'estimation:

Après estimation des paramètres du modèle, les résultats peuvent se présenter comme suit :

- (1) $\hat{y}_t = \hat{a} + \hat{b} \alpha_t$
- (2) $\hat{y}_t = \hat{a} + \hat{b} \alpha_t$
 $\quad \quad \quad (\hat{\sigma}_{\hat{a}}) \quad (\hat{\sigma}_{\hat{b}})$
- (3) $\hat{y}_t = \hat{a} + \hat{b} \alpha_t$
 $\quad \quad \quad \left(\frac{\hat{a}}{\hat{\sigma}_{\hat{a}}} \right) \quad \left(\frac{\hat{b}}{\hat{\sigma}_{\hat{b}}} \right)$

Pour la présentation (2) les termes entre parenthèses désignent les écarts type estimés de l'estimateur.

Pour la présentation (3), ils représentent les t de Student.

④ Interprétation des paramètres du modèle:

On distingue 2 cas :

a) cas du modèle linéaire en niveau : $y_t = a + b \alpha_t + u_t$

$$b = \frac{\partial y_t}{\partial \alpha_t} = \frac{\Delta y_t}{\Delta \alpha_t} : \text{la variation marginale (effet marginal)}$$

de y_t par rapport à α_t : quand α varie d'une unité, y_t varie de b unités

$\Rightarrow \hat{b}$: variation marginale estimée.

b) cas de modèle Log- linéaire au double - logarithmique

$$\text{Log } y_t = a + b \text{Log } \alpha_t + u_t$$

$$b = \frac{\partial \text{Log } y_t}{\partial \text{Log } \alpha_t} = \frac{\partial y_t}{\partial \alpha_t} \cdot \frac{\alpha_t}{y_t} : \text{l'élasticité de } y_t \text{ par rapport à } \alpha_t.$$

\Rightarrow quand α_t varie de 1%, y_t varie de $b\%$.

$\Rightarrow \hat{b}$: c'est l'élasticité estimée de y_t par rapport à α_t .