

CH2: Le modèle de régression linéaire multiple

①

I) Présentation du modèle et hypothèses:

① Ecriture du modèle sous forme matricielle:

Le modèle de régression multiple comporte k variables explicatives et s'écrit comme suit:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + \varepsilon_t$$

Avec $t = 1, \dots, T$.

- * y_t : variable endogène ou à expliquer;
- * $x_{1t}, x_{2t}, \dots, x_{kt}$: variables exogènes ou explicatives;
- * ε_t : terme d'erreur ou variable aléatoire;
- * $\beta_0, \beta_1, \dots, \beta_k$: les paramètres à estimer ou coefficients de régression.

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \dots + \beta_k x_{kt} + \varepsilon_t$$

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_T \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & x_{21} & \dots & x_{k1} \\ 1 & x_{12} & x_{22} & & x_{k2} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{1T} & x_{2T} & & x_{kT} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_T \end{pmatrix}$$

$$\Rightarrow Y = X\beta + \varepsilon \rightarrow (T, 1)$$

$(T, 1)$
↓
 $\underbrace{\quad}_K$

$(T, k+1)$
↓
 $\underbrace{\quad}_K$

$(k+1, 1)$
↓
 $\underbrace{\quad}_K$

Avec:

- * Y : C'est le vecteur composé par les valeurs de la variable endogène.

- * X : C'est la matrice des variables explicatives y compris les constantes.
- * β : C'est le vecteur des paramètres à estimer.
- * E : C'est le vecteur relatif au terme d'erreur.

② Les hypothèses du modèle:
Le modèle de régression multiple repose sur les hypothèses suivantes:

② Les hypothèses du modèle :

Le modèle de régression multiple repose sur les hypothèses suivantes :

- * H_1 : la matrice X est non aléatoire .
- * H_2 : La matrice X est de plein rang $\Rightarrow \text{Rang}(X) = K = k+1$
~~des variables explicatives~~
~~composées des erreurs~~

\Rightarrow Absence de colinéarité entre les variables explicatives
(indépendance entre les variables explicatives)

$\Rightarrow (X'X)$ est symétrique et régulière et $(X'X)^{-1}$ existe .

Avec : X' = transposée de X .

* H_3 : $E(\varepsilon) = 0$.

* H_4 : hypothèses d'homoscedasticité et d'absence d'autocorrélation des erreurs .

$$\text{Var}(\varepsilon) = \Omega_{\varepsilon} = \sigma_{\varepsilon}^2 \cdot I \quad ; \quad I : \text{matrice identité}$$

avec : Ω_{ε} = la matrice de variances-covariances des erreurs .

$$\Rightarrow \text{Var}(\varepsilon) = \Omega_{\varepsilon} = \begin{pmatrix} V(\varepsilon_1) & \text{cov}(\varepsilon_1, \varepsilon_2) & \dots & \text{cov}(\varepsilon_1, \varepsilon_T) \\ \text{cov}(\varepsilon_2, \varepsilon_1) & & & \\ \vdots & & & \\ \text{cov}(\varepsilon_T, \varepsilon_1) & \dots & \dots & V(\varepsilon_T) \end{pmatrix}$$

$$\Rightarrow \Omega_{\varepsilon} = \begin{pmatrix} \sigma_{\varepsilon}^2 & & \\ & (0) & \\ & & \ddots \\ & & & (0) \\ & & & & \sigma_{\varepsilon}^2 \end{pmatrix} = \sigma_{\varepsilon}^2 \cdot I$$

$$\Rightarrow \text{Var}(\varepsilon) = \Omega_{\varepsilon} = \sigma_{\varepsilon}^2 \cdot I$$

* H_5 : Hypothèse de normalité des erreurs : $\varepsilon \sim \mathcal{N}(0, \sigma_{\varepsilon}^2 \cdot I)$

② C. ML

II] Estimation par la méthode des MCO :

1) Déf.

On considère ci-dessus le modèle de régression multiple sous sa forme matricielle avec k variables explicatives et T observations.

$$Y = X \cdot \beta + \varepsilon \Leftrightarrow \varepsilon = Y - X \cdot \beta$$

Pour estimer le vecteur β , on applique la méthode des MCO qui consiste à minimiser la somme des carrés des erreurs.

$$\Rightarrow \min_{\beta} \sum_{t=1}^T \varepsilon_t^2 = \min_{\beta} \varepsilon' \varepsilon$$

2) Résolution :

$$\begin{aligned} \min_{\beta} \sum_{t=1}^T \varepsilon_t^2 &= \min_{\beta} \varepsilon' \varepsilon = \min_{\beta} \underbrace{(Y - X\beta)' (Y - X\beta)}_{Q} \\ &= \min_{\beta} Q \end{aligned}$$

$$\text{Avec } Q = (Y - X\beta)' (Y - X\beta)$$

$$= (Y' - \cancel{\beta' X'}) (Y - X\beta)$$

$$= Y'Y - Y'X\beta - \cancel{\beta' X'}Y + \beta' X'X\beta$$

Π_q (mathématique).

$$Y'X\beta = (\beta'X'Y)' = \beta'X'Y$$

$$\Rightarrow Q = Y'Y - 2\beta'X'Y + \beta'X'X\beta$$

$$\Rightarrow \frac{\partial Q}{\partial \beta} = 0 \Leftrightarrow -2X'Y + 2X'X\beta = 0$$

$$\Leftrightarrow X'Y - X'X\beta = 0$$

$\Leftrightarrow X'Y = X'X\beta$: Equations normales puisque $(X'X)^{-1}$

existe d'après H_2 donc on obtient:

$$\boxed{\hat{\beta} = (X'X)^{-1}X'Y} = \begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_k \end{pmatrix}$$

Notations:

* $\hat{y} = X\hat{\beta}$: le vecteur des valeurs ajustées de la variable endogène.

* $\hat{e} = y - \hat{y}$: le ~~reste~~ vecteur résidu de l'estimation.

3) Equation d'analyse de la variance:

Comme dans le cas du modèle de régression simple l'équation d'analyse de la variance s'écrit comme suit: $SCT = SCE + SCR$

⑧ C.M.L

Avec:

$$\star SCT = \sum (y_t - \bar{y})^2 = \sum y_t^2 - T\bar{y}^2 = Y'Y - T\bar{y}^2$$

$$\star SCE = \sum (\hat{y}_t - \bar{y})^2 = \sum \hat{y}_t^2 - T\bar{y}^2 = \hat{Y}'\hat{Y} - T\bar{y}^2$$

$$\star SCR = \sum \hat{e}_t^2 = \hat{E}'\hat{E}$$

Théorème:

$$SCR = Y'Y - \hat{\beta}'X'Y$$

Démonstration:

$$SCR = SCT - SCE$$

$$= Y'Y - T\bar{y}^2 - \hat{Y}'\hat{Y} + T\bar{y}^2$$

$$\Rightarrow SCR = Y'Y - \hat{\beta}' \underbrace{X'X \hat{\beta}}_{= X'Y}$$

Equations normales:
 $X'Y = X'X \hat{\beta}$

$$\Rightarrow \boxed{SCR = Y'Y - \hat{\beta}'X'Y}$$