

Modèles Linéaires 2A

Période 1

Josephson Junior R.

July 9, 2024

Table des matières

- 1 Modèle de régression simple
 - Un peu de familiarité
 - Estimation des paramètres
 - Propriétés des estimateurs
 - Test de significativité
 - Analyse de la Variance
- 2 Modèle de régression multiple
 - Formulation
 - Estimation
 - Propriétés
 - Analyse de la Variance
 - Tests Statistiques

La fonction de consommation

Comme vue en micro et macroéconomie on peut définir la fonction de consommation par :

$$C = a_0 + a_1 Y$$

où :

- **C** : la consommation
- **a₀** : consommation autonome incompressible
- **a₁** : propension marginale à consommer
- **Y** : le revenu

En modèle linéaire on change juste d'appellation :

- **C** : variable à expliquer ou endogène
- **Y** : variable explicative ou exogène
- **a₀** et **a₁** : coefficients ou paramètres du modèle

La fonction de production

Pour rappel en microéconomie on a parlé des fonctions type **Cobb-Douglas** qui modèle le niveau de production :

$$Y = a \times K^{\alpha} \times L^{\beta}$$

Par une transformation logarithmique on peut revenir à un modèle de regression simple défini comme suit :

$$y = \ln(a) + \alpha \ln(K) + \beta \ln(L)$$

Plus simplement on pourra écrire :

$$y = \beta_0 + \beta_1 K^* + \beta_2 L^*$$

NB : l'interprétation des coefficients du modèle diffère selon les **transformations** appliquées pour avoir une régression.

Modèle de régression simple

Un modèle de régression simple se définit comme suit :

$$\mathbf{y_i} = \beta_0 + \beta_1 \mathbf{x_i} + \varepsilon_i \quad ; \quad \mathbf{i} \in [1, \mathbf{n}]$$

Ce modèle doit vérifier des hypothèses :

- **H1** : $\mathbf{E}(\varepsilon_i) = 0$
- **H2** : $\mathbf{V}(\varepsilon_i) = \sigma_\varepsilon^2$
- **H3** : $\mathbf{Cov}(\varepsilon_i, \varepsilon_{i'}) = 0$
- **H4** : $\mathbf{Cov}(\mathbf{x_i}, \varepsilon_i) = 0$

Les problèmes liés aux non-respects de ces hypothèses seront traités ultérieurement en **économétrie**.

Formulation des estimateurs

L'estimateur des paramètres de régression est obtenu par la MCO (**M**oindres **C**arrés **O**rdinaires) définie comme suite :

$$\text{Min}_{\beta_0, \beta_1} \sum_{i=1}^n \varepsilon_i^2 = \text{Min } E \quad \text{où} \quad \varepsilon_i = y_i - \beta_0 - \beta_1 x_i$$

Par la suite on calcule :

$$\frac{\partial E}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad (1)$$

$$\frac{\partial E}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad (2)$$

Tout calcul fait on aura :

$$\hat{\beta}_1 = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2} = \frac{\sum x_i y_i - n \bar{x} \bar{y}}{\sum x_i^2 - n \bar{x}^2} = \frac{\text{Cov}(x, y)}{V(x)}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Le modèle de prédiction s'écrit comme suit :

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$$

On introduit la notion de résidu d'estimation :

$$\hat{\varepsilon}_i = y_i - \hat{y}_i$$

- Les estimateurs sont-ils **sans biais** ?

On commence par réécrire $\hat{\beta}_1$ en remarquant que :

$$(y_i - \bar{y}) = \beta_1(x_i - \bar{x}) + (\varepsilon_i - \bar{\varepsilon}) \Rightarrow \hat{\beta}_1 = \beta_1 + \frac{\sum(\mathbf{x}_i - \bar{\mathbf{x}})(\varepsilon_i - \bar{\varepsilon})}{\sum(\mathbf{x}_i - \bar{\mathbf{x}})^2}$$

$$\mathbf{E}(\hat{\beta}_1) = \mathbf{E}(\beta_1) + \frac{\sum \mathbf{x}_i \mathbf{E}(\varepsilon_i) - n\bar{\mathbf{x}} \mathbf{E}(\bar{\varepsilon})}{\sum(\mathbf{x}_i - \bar{\mathbf{x}})^2} = \beta_1$$

$$E(\hat{\beta}_0) = E(\bar{y} - \hat{\beta}_1\bar{x}) = E(\beta_0 + \beta_1\bar{x} + \bar{\varepsilon} - \hat{\beta}_1\bar{x}) = \beta_0$$

Donc les estimateurs obtenus par MCO sont **sans biais**.

- Les estimateurs sont-ils **convergen**ts ?

$$\mathbf{V}(\hat{\beta}_1) = \frac{\sigma_\varepsilon^2}{\sum(\mathbf{x}_i - \bar{\mathbf{x}})^2} \quad \text{et} \quad \mathbf{V}(\hat{\beta}_0) = \sigma_\varepsilon^2 \left(\frac{1}{n} + \frac{\bar{\mathbf{x}}^2}{\sum(\mathbf{x}_i - \bar{\mathbf{x}})^2} \right)$$

En calculant la limite des variances des estimateurs on voit bien que **ça tend vers 0** donc les estimateurs obtenus par MCO sont **convergen**ts.

- Les estimateurs par MCO sont **BLUE** (**B**est **L**inear **U**nbiased **E**stimator).
- Comment estimer la variance des erreurs ?

Il faut partir de l'expression des résidus :

$$\hat{\varepsilon}_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i + \hat{\beta}_1 \bar{x} - \hat{\beta}_1 \bar{x} = y_i - \bar{y} - \hat{\beta}_1 (x_i - \bar{x})$$

$$\Rightarrow \hat{\varepsilon}_i = (\beta_1 - \hat{\beta}_1) (x_i - \bar{x}) + (\varepsilon_i - \bar{\varepsilon})$$

Après on fait $\sum \hat{\varepsilon}_i^2$ et on calcule son espérance pour arriver à une estimation de la variance des erreurs :

$$\hat{\sigma}_\varepsilon^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{\varepsilon}_i^2$$

Significativité individuelle

$$\begin{cases} H_0 & : \beta_1 = 0 \\ H_1 & : \beta_1 \neq 0 \end{cases}$$

Sous l'hypothèse de normalité des erreurs $\varepsilon_i \sim \mathcal{N}(\mathbf{0}, \sigma_\varepsilon^2)$; on a la statistique pivotale suivante :

$$T = \frac{\hat{\beta}_1 - \beta_1}{\sigma_{\hat{\beta}_1}} \sim \mathcal{N}(0, 1)$$

On distingue deux cas :

- σ_ε^2 connue :

$$T = \frac{\hat{\beta}_1 - \beta_1}{\sigma_{\hat{\beta}_1}} \sim \mathcal{N}(0, 1)$$

- σ_ε^2 inconnue :

$$T = \frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}_{\hat{\beta}_1}} \sim \mathcal{T}(n-2)$$

Sous H_0 la statistique du test est défini par :

$$\mathbf{T} = \frac{\hat{\beta}_1}{\hat{\sigma}_{\hat{\beta}_1}} \quad \text{où} \quad \hat{\sigma}_{\hat{\beta}_1} = \sqrt{\hat{\mathbf{V}}(\hat{\beta}_1)} = \sqrt{\frac{\hat{\sigma}_\varepsilon^2}{\sum(\mathbf{x}_i - \bar{\mathbf{x}})^2}}$$

Sa loi dépend des cas cités précédemment.

Règle de décision : .

si $|\mathbf{T}| < \mathbf{t}_{n-2}^{\alpha/2}$ **on accepte H_0**

Sous H_0 l'intervalle de confiance est défini comme suit :

$$IC_{\beta_1}^{\alpha} = \hat{\beta}_1 \pm t_{n-2}^{1-\alpha/2} \times \hat{\sigma}_{\hat{\beta}_1}$$

Règle de décision :

si $0 \in IC_{\beta_1}^{\alpha}$ **on accepte H_0**

NB : Le calcul des estimateurs peut aussi se faire par MV (**M**aximum **V**raisemblance) et donc :

$$\hat{\beta}_1 \sim \mathcal{N}(\beta_1, V(\hat{\beta}_1))$$

Equation d'analyse de la variance

La décomposition de la variance se fait par :

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n \hat{\epsilon}_i^2$$

$$\mathbf{SCT = SCE + SCR}$$

On peut ainsi définir le coefficient de détermination : la proportion de la variabilité de Y expliqué par la variable X.

$$R^2 = \frac{\mathbf{SCE}}{\mathbf{SCT}} = 1 - \frac{\mathbf{SCR}}{\mathbf{SCT}}$$

On peut aussi réécrire l'estimateur de la variance des erreurs comme suit :

$$\hat{\sigma}_{\epsilon}^2 = \frac{\mathbf{SCR}}{\mathbf{n} - 2}$$

Tableau d'analyse de la variance

Source de variation	Somme des carrés	ddl	Carré moyens
x	SCE	1	SCE/1
Résidu	SCR	n-2	SCR/n-2
Total	SCT	n-1	

Pourquoi avons nous besoin de ce tableau ?

En fait ce tableau nous permet d'avoir une autre statistique pour notre test de significativité. Dans le prochain nous allons plus entrer en détails.

$$\text{Sous } H_0 : F = \frac{SCE/1}{SCR/n-2} \sim \mathcal{F}(1, n-2)$$

Cette statistique n'a pas réellement de nouveauté car c'est juste un rearrangement :

$$F = T^2 = \left(\frac{\hat{\beta}_1}{\hat{\sigma}_{\hat{\beta}_1}} \right)^2 = \frac{\hat{\beta}_1^2 \sum (x_i - \bar{x})^2}{\hat{\sigma}_\epsilon^2} = \frac{SCE/1}{SCR/n-2}$$

En fonction du coefficient de détermination on aura :

$$F = \frac{R^2}{(1 - R^2)/(n - 2)}$$

Règle de décision :

si $F < F_{(1,n-2)}^{\alpha/2}$ **on accepte H0**

NB : La partie prévision est juste une application des estimations déjà vu ; en outre certaines formules d'intervalle de confiance doivent être apprises .

Soit le modèle suivant :

$$\mathbf{Y}_i = \beta_0 + \beta_1 \mathbf{X}_{1i} + \beta_2 \mathbf{X}_{2i} + \dots + \beta_k \mathbf{X}_{ki} + \varepsilon_i$$

Que l'on peut écrire sous forme matricielle :

$$\mathbf{Y} = \mathbf{X}\beta + \varepsilon \Rightarrow \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix} = \begin{pmatrix} 1 & X_{11} & X_{21} & \dots & X_{k1} \\ 1 & X_{12} & X_{22} & \dots & X_{k2} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & X_{1n} & X_{2n} & \dots & X_{kn} \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_k \end{pmatrix} + \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

Les dimensionnalités sont :

$$(\mathbf{n}, \mathbf{1}) = (\mathbf{n}, \mathbf{k} + \mathbf{1})(\mathbf{k} + \mathbf{1}, \mathbf{1}) + (\mathbf{n}, \mathbf{1})$$

Moindres Carrés Ordinaires

$$\text{Min } \varepsilon' \varepsilon \quad \text{où } \varepsilon = \mathbf{Y} - \mathbf{X}\beta \Rightarrow \text{Min } (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta)$$

Pour trouver l'estimateur :

$$\frac{\partial E}{\partial \beta} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta} = 0 \Rightarrow \hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{Y})$$

$$\begin{pmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_k \end{pmatrix} = \begin{pmatrix} n & \sum X_{1i} & \dots & \sum X_{ki} \\ \sum X_{1i} & \sum X_{1i}^2 & \dots & \sum X_{ki}X_{1i} \\ \vdots & \vdots & \vdots & \vdots \\ \sum X_{ki} & \sum X_{1i}X_{ki} & \dots & \sum X_{ki}^2 \end{pmatrix}^{-1} \begin{pmatrix} \sum Y_i \\ \sum Y_i X_{1i} \\ \vdots \\ \sum Y_i X_{ki} \end{pmatrix}$$

Cas particuliers : **Données centrées**

$$\begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \\ \vdots \\ \hat{\beta}_k \end{pmatrix} = \begin{pmatrix} V(x_1) & Cov(x_1, x_2) & \dots & Cov(x_1, x_k) \\ Cov(x_2, x_1) & V(x_1) & \dots & Cov(x_2, x_k) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(x_k, x_1) & cov(x_k, x_2) & \dots & V(x_k) \end{pmatrix}^{-1} \begin{pmatrix} Cov(y, x_1) \\ Cov(y, x_2) \\ \vdots \\ Cov(y, x_k) \end{pmatrix}$$

Avec :

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \hat{\beta}_2 \bar{X}_2 - \dots - \hat{\beta}_k \bar{X}_k$$

De plus on rajoute une hypothèse structurelle :

- **H5** : La matrice $(X'X)$ est de plein rang.

Les mêmes propriétés que celles mentionnées dans le chapitre précédent; juste un petit changement dans l'écriture.

- Variance des estimateurs :

$$\mathbf{V}(\hat{\beta}) = \sigma_{\varepsilon}^2 (\mathbf{X}'\mathbf{X})^{-1}$$

- Estimateur de la variance des erreurs :

$$\hat{\sigma}_{\varepsilon}^2 = \frac{\text{SCR}}{\mathbf{n} - \mathbf{k} - 1}$$

Dans certaines ouvrages on préfère directement noter : $\mathbf{K} = \mathbf{k} + 1$ donc la formule précédente devient :

$$\hat{\sigma}_{\varepsilon}^2 = \frac{\text{SCR}}{\mathbf{n} - \mathbf{K}}$$

En écriture matricielle on a :

$$\mathbf{Y}'\mathbf{Y} = \hat{\beta}'\mathbf{X}'\mathbf{X}\hat{\beta} + \hat{\varepsilon}'\hat{\varepsilon} \Rightarrow \mathbf{SCT} = \mathbf{SCE} + \mathbf{SCR}$$

Lorsque le degré de liberté est faible càd le nombre d'observation n'est pas assez grand il est préférable d'utiliser le R^2 ajusté :

$$R^2_{\text{adj}} = 1 - \frac{n-1}{n-K}(1 - R^2)$$

Source de variation	Somme des carrés	ddl	Carré moyens
X	SCE	k	SCE/k
Résidu	SCR	n-k-1	SCR/n-k-1
Total	SCT	n-1	

Statistique : $F = \frac{\text{SCE}/k}{\text{SCR}/n-k-1} \sim \mathcal{F}(k, n-k-1)$

Significativité individuelle

$$\begin{cases} H0 & : \beta_k = 0 \\ H1 & : \beta_k \neq 0 \end{cases}$$

Sous $H0$ la statistique de test est définie par :

$$T = \frac{\hat{\beta}_k}{\hat{\sigma}_{\hat{\beta}_k}} \sim \mathcal{T}(n - K)$$

Règle de décision :

$$\text{si } |T| < t_{n-K}^{\alpha/2} \text{ on accepte } H0$$

Intervalle de confiance :

$$IC_{\beta_k}^{\alpha} = \hat{\beta}_k \pm t_{n-K}^{1-\alpha/2} \times \hat{\sigma}_{\hat{\beta}_k}$$

Significativité globale

$$\begin{cases} H0 & : \beta_1 = \beta_2 = \dots = \beta_k = 0 \\ H1 & : \beta_j \neq 0 \quad \exists j \in [1, k] \end{cases}$$

Sous $H0$ la statistique pour le test est définie par :

$$F = \frac{\text{SCE}/k}{\text{SCR}/n - K} \sim \mathcal{F}(k, n - K)$$

Règle de décision :

$$\text{si } F < F_{(k, n-K)}^{\alpha/2} \quad \text{on accepte } H0$$