

Méthodes de simulation 2023-2024(P4) 2<sup>ème</sup> année

### Chapitre 4: Échantillonnage préférentiel (Importance Sampling)

Tasnime Hamdeni

April 18, 2024



tasnim.hamdeni@essai.ucar.tn

### Sommaire

- Introduction
- 2 Estimateur d'échantillonnage préférentiel
- 3 Efficacité relative d'un estimateur
- 4 Choix de la densité instrumentale
- 5 Application de la méthode

### 1- Introduction

### 1- Introduction

Nous avons vu au chapitre 1 que si nous calculons une quantité E(X) par la méthode de Monte-Carlo, c'est à dire si nous approchons E(X) par une moyenne empirique  $\frac{X_1+X_2+\ldots+X_n}{n}$ ,  $X_1,X_2,\ldots$  i.i.d. de même loi que X, alors l'erreur

$$E(X) - \frac{X_1 + X_2 + \ldots + X_n}{n}$$

est d'ordre  $\frac{\sigma}{\sqrt{n}}$ , où  $\sigma^2 = V(X)$ .

y Nous allons prés7enter ici des méthodes qui permettent d'écrire E(X) = E(Y) avec  $V(Y) \le V(X)$ . Ces méthodes sont dites **de réduction de variance**.

◆ロト ◆個ト ◆差ト ◆差ト を めへぐ

#### Définition

Nous cherchons à calculer  $\mathbb{E}[h(X)]$  avec X variable à valeurs dans  $\mathbb{R}^d$ , de densité f. Pour toute densité g>0, nous pouvons écrire pour  $Y\sim g$ 

$$\delta = \mathbb{E}_f[h(X)] \approx \mathbb{E}_g\left[\frac{h(Y)f(Y)}{g(Y)}\right].$$

Étant donnée  $(Y_n)_{n\geq 1}$  une suite de variables aléatoires i.i.d. suivant la densité g, on définit l'estimateur d'échantillonnage préférentiel par:

$$\hat{\delta}_n(g) = \frac{1}{n} \sum_{k=1}^n \frac{f(Y_k)}{g(Y_k)} h(Y_k).$$

La densité g est appelée loi instrumentale (ou loi d'importance).

→□▶→□▶→□▶→□▶
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□
□

### Définition (suite)

Le rapport

$$w_k = \frac{f(Y_k)}{g(Y_k)}$$

est appelé poids d'importance.

L'estimateur d'échantillonnage préférentiel est donc donnée par:

$$\hat{\delta}_n(g) = \frac{1}{n} \sum_{k=1}^n \frac{f(Y_k)}{g(Y_k)} h(Y_k) = \frac{1}{n} \sum_{k=1}^n w_k h(Y_k).$$

### Remarque:

Le coût de calcul de  $\hat{\delta}_n(g)$  peut être différent de celui de l'estimateur classique : le coût de simulation suivant g pouvant être différent du coût de simulation suivant f.





Limiter la comparaison des méthodes à la simple comparaison des variances  $\sigma^2$  et  $\sigma_1^2$  n'est néanmoins pas nécessairement judicieux si la méthode alternative n'est pas de complexité comparable (par exemple, coût de calcul et utilisation de la mémoire plus importants) à la méthode classique.



Limiter la comparaison des méthodes à la simple comparaison des variances  $\sigma^2$  et  $\sigma_1^2$  n'est néanmoins pas nécessairement judicieux si la méthode alternative n'est pas de complexité comparable (par exemple, coût de calcul et utilisation de la mémoire plus importants) à la méthode classique. Quel est le critère de comparaison ?

#### Définition

Supposons que le coût de la méthode classique pour simuler un n-échantillon  $X_1, \ldots, X_n$  et évaluer n fois h est

$$C \times n$$
.

Si le coût de calcul de  $\hat{\delta}_n$  est

$$C_1 \times n$$
,

alors pour obtenir la même précision  $\epsilon^2$ , l'efficacité relative (relative efficiency) de  $\hat{\delta}_n$  par rapport  $\overline{h_n}$ :

$$R(\overline{h_n}, \hat{\delta}_n) = \frac{C \times \sigma^2}{C_1 \times \sigma_1^2}.$$

### Remarque 1

Pour obtenir une erreur quadratique moyenne donnée, une méthode de réduction de variance est d'autant plus efficace que  $R(\overline{h_n}, \hat{\delta}_n)$  est grand devant 1.

### Remarque 1

Pour obtenir une erreur quadratique moyenne donnée, une méthode de réduction de variance est d'autant plus efficace que  $R(\overline{h_n}, \hat{\delta}_n)$  est grand devant 1.

### Remarque 2

Il n'est pas toujours facile de quantifier l'effet du rapport des coûts  $C/C_1$ , celui-ci pouvant dépendre du langage, de la façon de programmer les méthodes, des algorithmes de simulation utilisés, ... Dans le cours, on se concentrera sur la comparaison des variances.

La méthode d'échantillonnage préférentiel repose sur le fait qu'il n'y a pas unicité de la loi par rapport à laquelle on intègre pour calculer  $\delta$ . Cela laisse beaucoup de liberté quant au choix de g parmi les lois faciles à simuler.

La méthode d'échantillonnage préférentiel repose sur le fait qu'il n'y a pas unicité de la loi par rapport à laquelle on intègre pour calculer  $\delta$ . Cela laisse beaucoup de liberté quant au choix de g parmi les lois faciles à simuler.

### Proposition

L'estimateur d'échantillonnage préférentiel de variance minimale,  $\hat{\delta}_n(g^*)$ , est obtenu pour la densité instrumentale

$$g^*(y) = \frac{|h(y)| \cdot f(y)}{\int_{\mathsf{support}(f)} |h(x)| \cdot f(x) \, dx}, \quad y \in \mathbb{R}^d.$$

La méthode d'échantillonnage préférentiel repose sur le fait qu'il n'y a pas unicité de la loi par rapport à laquelle on intègre pour calculer  $\delta$ . Cela laisse beaucoup de liberté quant au choix de g parmi les lois faciles à simuler.

### Proposition

L'estimateur d'échantillonnage préférentiel de variance minimale,  $\hat{\delta}_n(g^*)$ , est obtenu pour la densité instrumentale

$$g^*(y) = \frac{|h(y)| \cdot f(y)}{\int_{\text{support}(f)} |h(x)| \cdot f(x) dx}, \quad y \in \mathbb{R}^d.$$

### Remarque

Ce résultat n'a qu'un intérêt limité en pratique.

Lorsque h > 0, la densité instrumentale optimale est

$$g^*(y) = \frac{h \cdot f}{\mathbb{E}_f[h(X)]},$$

- Vérifier la validité de g\*.
- ② Vérifier que  $\operatorname{Var}_{g^*}[\hat{\delta}_n(g^*)] = 0$

Nous avons donc ici une méthode de Monte-Carlo de variance nulle, ce qui semble n'avoir aucun sens.

Nous avons donc ici une méthode de Monte-Carlo de variance nulle, ce qui semble n'avoir aucun sens.

En fait, la variance de cette méthode n'a pas d'intérêt car cette méthode n'est pas implémentable.

Nous avons donc ici une méthode de Monte-Carlo de variance nulle, ce qui semble n'avoir aucun sens.

En fait, la variance de cette méthode n'a pas d'intérêt car cette méthode n'est pas implémentable.

En effet, il faudrait pour cela savoir simuler suivant la densité g, mais l'expression de g contient la constante  $E_f(h(X))$ , que nous ne connaissons pas.

Nous avons donc ici une méthode de Monte-Carlo de variance nulle, ce qui semble n'avoir aucun sens.

En fait, la variance de cette méthode n'a pas d'intérêt car cette méthode n'est pas implémentable.

En effet, il faudrait pour cela savoir simuler suivant la densité g, mais l'expression de g contient la constante  $E_f(h(X))$ , que nous ne connaissons pas.


un candidat pertinent est tel que  $\frac{|h|f}{g}$  soit quasi constant et de variance finie.

### Exercice:

1- Estimer la valeur de  $I=\int_0^1\cos(\pi x/2)\,dx$  par la méthode de Monte-Carlo et appliquer une amélioration de cette valeur à l'aide de la méthode de l'échantillonnage préférentiel.


### Exercice:

1- Estimer la valeur de  $I=\int_0^1\cos(\pi x/2)\,dx$  par la méthode de Monte-Carlo et appliquer une amélioration de cette valeur à l'aide de la méthode de l'échantillonnage préférentiel.



### Exercice:

1- Estimer la valeur de  $I=\int_0^1\cos(\pi x/2)\,dx$  par la méthode de Monte-Carlo et appliquer une amélioration de cette valeur à l'aide de la méthode de l'échantillonnage préférentiel.



2- Donner une implémenter avec Python en précisant les estimations de l'intégrale par Monte Carlo et par échantillonnage préférentiel ainsi que les variances de l'estimation.

```
import numpy as np
# Fonction à intégrer
def h(x):
    return np.cos(np.pi * x / 2)
# Instrumentale linéaire
def g(x):
    return 2 * (1 - x)
# Instrumentale quadratique
def g 2(x):
    return 3/2 * (1 - x**2)
# méthode 1: Estimation de l'intégrale par la méthode de Monte-Carlo
def monte carlo(n):
    x samples = np.random.uniform(0, 1, n)
    integral estimate = np.mean(h(x samples))
    return integral estimate
# méthode 2: échantillonnage préférentiel
def importance sampling(n):
    # Générer des échantillons aléatoires selon la distribution de densité g(x)
    x samples = 1 - np.sqrt(np.random.uniform(0, 1, n))
    # Calculer la moyenne de la fonction évaluée en ces échantillons, ajustée par la densité g(x)
    integral estimate = np.mean(h(x samples) / g(x samples))
    return integral estimate
```

April 18, 2024

```
n = 100000
# Estimation de l'intégrale par la méthode de Monte-Carlo
monte carlo estimate = monte carlo(n)
print("Estimation de l'intégrale par Monte-Carlo:", monte carlo estimate)
# Estimation de la variance par la méthode de Monte-Carlo
monte carlo samples = [monte carlo(n) for in range(10)] # On effectue plusieurs estimations pour calculer la variance
monte carlo variance = np.var(monte carlo samples)
print("Variance de l'estimation par Monte-Carlo:", monte carlo variance)
# Estimation de l'intégrale par la méthode de l'échantillonness préférentiel
                                                            Loading...
importance sampling estimate = importance sampling(n)
print("Estimation de l'intégrale par échantillonnage préférentiel:", importance sampling estimate)
# Estimation de la variance par la méthode de l'échantillonnage préférentiel
importance sampling samples = [importance sampling(n) for in range(10)]
importance sampling variance = np.var(importance sampling samples)
print("Variance de l'estimation par échantillonnage préférentiel:", importance sampling variance)
```

```
n = 100000
# Estimation de l'intégrale par la méthode de Monte-Carlo
monte carlo estimate = monte carlo(n)
print("Estimation de l'intégrale par Monte-Carlo:", monte carlo estimate)
# Estimation de la variance par la méthode de Monte-Carlo
monte carlo samples = [monte carlo(n) for in range(10)] # On effectue plusieurs estimations pour calculer la variance
monte carlo variance = np.var(monte carlo samples)
print("Variance de l'estimation par Monte-Carlo:", monte carlo variance)
# Estimation de l'intégrale par la méthode de l'échantillonnage préférentiel
                                                             Loading...
importance sampling estimate = importance sampling(n)
print("Estimation de l'intégrale par échantillonnage préférentiel:", importance sampling estimate)
# Estimation de la variance par la méthode de l'échantillonnage préférentiel
importance sampling samples = [importance sampling(n) for in range(10)]
importance sampling variance = np.var(importance sampling samples)
print("Variance de l'estimation par échantillonnage préférentiel:", importance sampling variance)
```

Estimation de l'intégrale par Monte-Carlo: 0.6370235728672002

Variance de l'estimation par Monte-Carlo: 1.445408233255845e-06

Estimation de l'intégrale par échantillonnage préférentiel: 0.6362394990834955

Variance de l'estimation par échantillonnage préférentiel: 6.092557968093681e-08