

Plans d'Expériences

Josephson Junior R.

April 25, 2024

Table des matières

- 1 ANOVA à un facteur de contrôle
 - Formulation du modèle
 - Analyse du modèle à effets fixes
 - Estimation du modèle
 - Méthode des Contrastes
 - Comparaison des contrastes
 - Comparaison de paires traitements-moyens

Considérons **a** traitements se présentant comme la modalité d'un **seul facteur**. Pour comparer entre ses **a** traitements on dispose de **n** unités expérimentales. La variable réponse de chacun de ses **a** traitements est une variable aléatoire **Y_{ij}** représentant le **$j^{\text{ème}}$** obs effectuée sur le traitement **i**.

Modèle 1

$$Y_{ij} = \mu_i + \varepsilon_{ij}$$

- μ_i : moyenne du **$i^{\text{ème}}$** niveau
- $\varepsilon_{ij} \sim \mathcal{N}(0, \sigma_\varepsilon^2)$

Modèle 2

$$Y_{ij} = \mu + \alpha_i + \varepsilon_{ij}$$

- α_i : facteur d'influence de la modalité **i** appelé **effet principal du $i^{\text{ème}}$ niveau**.

- Total des observations du **traitement i** :

$$Y_i = \sum_{j=1}^n Y_{ij}$$

- Moyenne des observation du **traitement i** :

$$\bar{Y}_i = \frac{1}{n} \sum_{j=1}^n Y_{ij}$$

- Total de toutes les observations :

$$Y = \sum_{i=1}^a \sum_{j=1}^n Y_{ij}$$

- Moyenne de toutes les observations :

$$\bar{Y} = \frac{Y}{N} \quad \text{où } N = n \times a$$

L'objectif du travail est d'effectuer un test d'égalité des moyennes des **a traitements** :

$$\begin{cases} H0 : \mu_i = \dots = \mu_a \\ H1 : \mu_i \neq \mu_j \end{cases}$$

Au niveau du modèle à effets fixes on définit la moyenne du traitement i :

$$\mu_i = \mu + \alpha_i \implies \mu = \frac{\sum_{i=1}^a \mu_i}{a} \implies \sum_{i=1}^a \alpha_i = 0$$

Alternativement on pourrait tester **l'hypothèse de nullité des effets traitements** :

$$\begin{cases} H_0 : \alpha_i = \dots = \alpha_a = 0 \\ H_1 : \alpha_i \neq 0 \end{cases}$$

Décomposition de la Variance

$$SS_T = \sum_{i=1}^a \sum_{j=1}^n (Y_{ij} - \bar{Y})^2 = n \sum_{i=1}^a (\bar{Y}_i - \bar{Y})^2 + \sum_{i=1}^a \sum_{j=1}^n (Y_{ij} - \bar{Y}_i)^2$$

$$SS_T = SS_{\text{Traitement}} + SS_E = \text{Between} + \text{Within}$$

Au sens de la distribution χ^2 de Pearson **les degrés de liberté sont additifs** :

$$(N - 1) = (a - 1) + (N - a)$$

Carrés Moyens

$$CM_{(SST)} = \frac{SS_T}{N - 1}$$

$$CM_{SS\text{Traitement}} = \frac{SS_{\text{Traitement}}}{a - 1}$$

$$CM_{SSE} = \frac{SS_E}{N - a}$$

Approche par Espérance

$$E(CM_{SSE}) = \sigma^2$$

$$E(CM_{SS\text{Traitement}}) = \sigma^2 + \frac{n \sum \alpha_i^2}{a - 1}$$

Test d'hypothèse : Equivalence des traitements

Sous H_0 vraie on définit la statistique suivante :

$$F_0 = \frac{CM_{SSTraitement}}{CM_{SSE}} \sim \mathcal{F}(a - 1, N - a)$$

Decision : Si $F_0 > F^c$ alors on rejette H_0 (il y a bien des différences dans les traitements moyens).

Loi Standard et Loi non-centré

- Loi non-centré :

$$Y \sim \mathcal{N}(\mu, I) \Rightarrow Y^2 \sim \chi^2(n, \lambda) ; \quad \lambda = \sum \mu_i^2$$

- Loi standard :

$$Y^2 \sim \chi^2(n) ; \quad \lambda = 0$$

Rejet de H_0 : Conséquence

Sous H_1 vraie, qu'est ce qu'on aurait ? (Se souvenir de $E(\text{CMSSTraitement})$)

$$\frac{SS_{\text{Traitement}}}{\sigma^2} \sim \chi^2(a-1, \lambda) ; \quad \lambda = \frac{n \sum \alpha_i^2}{\sigma^2}$$

En fait sous H_1 vraie la loi de la statistique va changer :

$$F_0 = \frac{CM_{SS\text{Traitement}}}{CM_{SSE}} \sim \mathcal{F}(a-1, N-a, \lambda)$$

L'utilité de ce changement est dans le calcul de la puissance du test :

$$\eta = P(\text{rejet } H_0 / H_1 \text{ vraie}) = 1 - \beta = P(F > F_{a-1, N-a})$$

Sachant que $F \sim \mathcal{F}(a-1, N-a, \lambda)$.

Par MCO nous avons les résultats suivants pour le modèle 2 :

$$\hat{\mu} = \bar{\mathbf{Y}} \sim \mathcal{N}\left(\mu, \frac{\sigma^2}{\mathbf{N}}\right) \quad ; \quad \hat{\alpha}_i = \bar{\mathbf{Y}}_i - \bar{\mathbf{Y}} \sim \mathcal{N}\left(\mu, \sigma^2 \left(\frac{1}{\mathbf{n}} - \frac{1}{\mathbf{N}}\right)\right)$$

Pour estimer σ^2 on a :

$$\hat{\sigma}^2 = \frac{1}{\mathbf{N} - \mathbf{a}} \sum_{i=1}^{\mathbf{a}} \sum_{j=1}^{\mathbf{n}} (\mathbf{Y}_{ij} - \bar{\mathbf{Y}}_i)^2 = \frac{\mathbf{SS}_E}{\mathbf{N} - \mathbf{a}}$$

Pour le ième traitement moyen on a l'IC suivant :

$$IC_{\mu_i} = \left[\bar{Y}_i \pm t_{\alpha/2, N-a} \times \frac{\hat{\sigma}}{\sqrt{n}} \right]$$

Pour la différence de deux traitements moyens :

$$IC_{\mu_i - \mu_{i'}} = \left[\bar{Y}_i - \bar{Y}_{i'} \pm t_{\alpha/2, N-a} \times \sqrt{\frac{2\hat{\sigma}^2}{n}} \right]$$

Nécessité

Quand le test d'ANOVA arrive à rejeter H_0 il est préférable de savoir où se situent les différences. On a recours à la méthode des contrastes.

En général, un contraste est formulée comme suite :

$$\Gamma = \sum_{i=1}^a c_i \mu_i = \sum_{i=1}^a c_i \alpha_i \quad ; \quad \sum_{i=1}^a c_i = 0$$

En termes de contraste on teste les hypothèses suivantes :

$$\begin{cases} \mathbf{H_0 : } & \Gamma = 0 \\ \mathbf{H_a : } & \Gamma \neq 0 \end{cases}$$

Approche du **t-test**

On définit le contraste d'intérêt en terme de total traitements :

$$C = \sum_{i=1}^a c_i Y_i \quad ; \quad V(C) = n\sigma^2 \sum_{i=1}^a c_i^2 \quad ; \quad E(C) = n \sum_{i=1}^a c_i \mu_i$$

Sous H_0 vraie on définit la statistique comme suite :

$$T = \frac{\sum c_i Y_i}{\sqrt{n \times \sigma^2 \times \sum c_i^2}} \sim \mathcal{N}(0, 1)$$

Si σ^2 inconnue alors :

$$T = \frac{\sum c_i Y_i}{\sqrt{n \times \hat{\sigma}^2 \times \sum c_i^2}} \sim \mathcal{T}(N - a)$$

Approche du **F-test**

On retrouve la loi de Fisher pour un Student au carré :

$$F = T^2 = \left(\frac{\sum c_i Y_i}{\sqrt{n \times \hat{\sigma}^2 \times \sum c_i^2}} \right)^2 = \frac{\left(\frac{\sum c_i Y_i}{\sqrt{n \sum c_i^2}} \right)^2}{CM_{SSE}} = \frac{CM_{SSC}}{CM_{SSE}} \sim F(1, N - a)$$

Il suffit de remarquer :

$$SS_C = \left(\frac{\sum c_i Y_i}{\sqrt{n \times \sum c_i^2}} \right)^2 \sim \chi^2(1)$$

Intervalle de Confiance d'un contraste

Comme tester tester par l'hypothèse on va chercher l'IC de Γ :

$$IC_{\Gamma} = \left[\sum_{i=1}^a c_i \bar{Y}_i \pm t_{\alpha/2, N-a} \times \sqrt{\frac{\sigma^2}{n} \times \sum_{i=1}^a c_i^2} \right]$$

Contrastes Standardisés

Lorsqu'il y a plus qu'un contraste d'intérêt il est utile de les évaluer tous sur la même échelle. On définit alors le contraste standardisé par :

$$c_i^* = \frac{c_i}{\sqrt{n \times \sum c_i^2}} \Rightarrow C = \sum_{i=1}^a c_i^* Y_i$$

Remarques

- Sous échantillon de **tailles inégales** :

$$\sum_{i=1}^a n_i c_i = 0$$

- Contrastes orthogonaux c_i et d_i :

$$\sum_{i=1}^a c_i d_i = 0$$

Méthode de **Scheffé**

Elle définit une comparaison de tous types possibles de contrastes entre traitements moyens. On suppose un ensemble de m contrastes dans les traitements moyens d'intérêts déterminés par :

$$\Gamma = \sum_{i=1}^a c_{iu} \mu_i \quad \text{avec } u \in [1, m]$$

Le contraste correspondant dans les moyennes traitements est :

$$C_u = \sum_{i=1}^a c_{iu} \bar{Y}_i$$

L'erreur standard est définie par :

$$S_{C_u} = \sqrt{CM_{SSE} \sum_{i=1}^n \frac{c_i^2}{n_i}}$$

La valeur critique est :

$$S_{a,u} = S_{C_u} \sqrt{(a-1)F_{a-1, N-a}^{\alpha}}$$

Si $|C_u| > S_{a,u}$: on rejette H_0 ($\Gamma_u = 0$).

$$IC_{\Gamma_u} = [C_u \pm S_{a,u}]$$

Test de Tukey (1953)

$$\begin{cases} \mathbf{H_0} : \mu_i = \mu_j \\ \mathbf{H_a} : \mu_i \neq \mu_j \end{cases}$$

La procédure utilise une distribution statistique de rang **studentisé** :

$$\mathbf{q} = \frac{\bar{\mathbf{Y}}_{\max} - \bar{\mathbf{Y}}_{\min}}{\sqrt{\frac{\mathbf{CM}_{\text{SSE}}}{\mathbf{n}}}} \Rightarrow \begin{cases} \bar{\mathbf{Y}}_{\max} : \max \bar{\mathbf{Y}}_i \text{ de l'échantillon} \\ \bar{\mathbf{Y}}_{\min} : \min \bar{\mathbf{Y}}_i \text{ de l'échantillon} \end{cases}$$

Pour rejeter $\mathbf{H_0}$ il faut que :

$$|\bar{\mathbf{Y}}_i - \bar{\mathbf{Y}}_j| > \mathbf{q}_{\alpha}(\mathbf{a}, \mathbf{f}) \times \sqrt{\frac{\mathbf{CM}_{\text{SSE}}}{\mathbf{n}}} ; \mathbf{f} = \mathbf{ddl}(\mathbf{CM}_{\text{SSE}})$$

Pour des tailles d'échantillon déséquilibré :

$$\mathbf{IC}_{\mu_i - \mu_j} = \left[\bar{\mathbf{Y}}_i - \bar{\mathbf{Y}}_j \pm \frac{\mathbf{q}_{\alpha}(\mathbf{a}, \mathbf{f})}{\sqrt{2}} \times \sqrt{\mathbf{CM}_{\text{SSE}} \times \left(\frac{1}{\mathbf{n}_i} + \frac{1}{\mathbf{n}_j} \right)} \right]$$

LSD - Fisher

C'est l'approche des différences les moins significatives de Fisher. La paire moyenne est déclarée significativement différente si :

$$|\bar{Y}_i - \bar{Y}_j| > t_{\alpha/2, N-a} \times \sqrt{CM_{SSE} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}$$

La quantité différence moins significative est définie par :

$$LSD = t_{\alpha/2, N-a} \times \sqrt{CM_{SSE} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}$$

Si l'échantillon est de taille égale alors :

$$LSD = t_{\alpha/2, N-a} \times \sqrt{\frac{2CM_{SSE}}{n}}$$