

Économétrie avancée : Introduction à l'économétrie des données de panel

Pr. Mokhtar KOUKI

Université de Carthage (ESSAI)
mokhtar.kouki@essai.ucar.tn

Septembre - Octobre 2022



Contents

- 1 Le modèle à effet fixe
 - Représentation et Estimation
 - Propriétés et estimateur sans biais de σ_ε^2
- 2 Modèle à effet (individuel) aléatoire
 - Définition
 - Estimation par moindres carrés généralisée
- 3 Tests de spécification : Effet Fixe vs Effet Aléatoire
 - Test de Hausmann
 - Test de Breush-Pagan (BP)
- 4 Exercice 1
- 5 Données de panel et frontière de production
- 6 exercice 2
- 7 Exercice 3, library(plm),

Représentation et Estimation

On rappelle qu'un modèle de régression linéaire de données de panel standard et à effet fixe est défini comme suit :

$$Y_{it} = \alpha_i + \beta_1 X_{1it} + \beta_2 X_{2it} + \cdots + \beta_k X_{kit} + \varepsilon_{it}$$

pour $i = 1, 2, \dots, n$ et $t = 1, 2, \dots, T$

avec

Représentation et Estimation

On rappelle qu'un modèle de régression linéaire de données de panel standard et à effet fixe est défini comme suit :

$$Y_{it} = \alpha_i + \beta_1 X_{1it} + \beta_2 X_{2it} + \cdots + \beta_k X_{kit} + \varepsilon_{it}$$

pour $i = 1, 2, \dots, n$ et $t = 1, 2, \dots, T$

avec

- Y : La variable endogène (expliquée)
- X_1, X_2, \dots, X_k : k variables explicatives (exogènes)
- $\alpha_i, \beta_1, \dots, \beta_k$: des paramètres à estimer

Représentation et Estimation

On rappelle qu'un modèle de régression linéaire de données de panel standard et à effet fixe est défini comme suit :

$$Y_{it} = \alpha_i + \beta_1 X_{1it} + \beta_2 X_{2it} + \cdots + \beta_k X_{kit} + \varepsilon_{it}$$

pour $i = 1, 2, \dots, n$ et $t = 1, 2, \dots, T$

avec

- Y : La variable endogène (expliquée)
- X_1, X_2, \dots, X_k : k variables explicatives (exogènes)
- $\alpha_i, \beta_1, \dots, \beta_k$: des paramètres à estimer
- ε_{it} est un terme d'erreur qui vérifie les hypothèses suivantes :
 - $E(\varepsilon_{it}) = 0 \forall i, t,$
 - $E(\varepsilon_{it}^2) = \sigma_\varepsilon^2 \forall i, t$
 - $E(\varepsilon_{it}\varepsilon_{js}) = 0 \forall i \neq j \text{ ou } s \neq t,$
 - $cov(X_{lit}, \varepsilon_{js}) = 0 \forall l, i, j, t, s.$

On considère les variables indicatrices (dummy variables) D_{jit} définies comme suit :

$$D_{jit} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{sinon} \end{cases}$$

On considère les variables indicatrices (dummy variables) D_{jit} définies comme suit :

$$D_{jit} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{sinon} \end{cases}$$

Et on note par D et X respectivement les matrices des variables indicatrices D_j et des variables explicatives X_i :

$$D = (D_1 \quad D_2 \quad \cdots \quad D_n) \quad \text{et} \quad X = (X_1 \quad X_2 \quad \cdots \quad X_k)$$

On considère les variables indicatrices (dummy variables) D_{jit} définies comme suit :

$$D_{jit} = \begin{cases} 1 & \text{si } i = j \\ 0 & \text{sinon} \end{cases}$$

Et on note par D et X respectivement les matrices des variables indicatrices D_j et des variables explicatives X_l :

$$D = (D_1 \quad D_2 \quad \cdots \quad D_n) \text{ et } X = (X_1 \quad X_2 \quad \cdots \quad X_k)$$

Le modèle à effet fixe peut être écrit sous forme matricielle :

$$Y = D\alpha + X\beta + \varepsilon, \text{ avec } \alpha = \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{pmatrix} \text{ et } \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix}$$

On définit par M_D la matrice idempotente :

$$M_D = I - D (D' D)^{-1} D' \text{ avec } M_D D = 0$$

On définit par M_D la matrice idempotente :

$$M_D = I - D (D' D)^{-1} D' \text{ avec } M_D D = 0$$

L'estimateur du vecteur β est donné par :

$$\hat{\beta} = (X' M_D X)^{-1} X' M_D Y$$

et

$$\hat{\alpha}_i = \bar{Y}_i - \hat{\beta}_1 \bar{X}_{1i} - \hat{\beta}_2 \bar{X}_{2i} - \cdots - \hat{\beta}_k \bar{X}_{ki}$$

avec

$$\bar{Y}_i = \frac{\sum_{t=1}^T Y_{it}}{T} \text{ et } \bar{X}_{li} = \frac{\sum_{t=1}^T X_{lit}}{T} \text{ pour } l = 1, 2, \dots, k$$

On définit par M_D la matrice idempotente :

$$M_D = I - D(D'D)^{-1}D' \text{ avec } M_DD = 0$$

L'estimateur du vecteur β est donné par :

$$\hat{\beta} = (X'M_DX)^{-1}X'M_DY$$

et

$$\hat{\alpha}_i = \bar{Y}_i - \hat{\beta}_1\bar{X}_{1i} - \hat{\beta}_2\bar{X}_{2i} - \dots - \hat{\beta}_k\bar{X}_{ki}$$

avec

$$\bar{Y}_i = \frac{\sum_{t=1}^T Y_{it}}{T} \text{ et } \bar{X}_{li} = \frac{\sum_{t=1}^T X_{lit}}{T} \text{ pour } l = 1, 2, \dots, k$$

Observation : M_DY et M_DX fournissent les données centrées autour des moyennes individuelles. Et le modèle à effet fixe est appelé modèle within (intra) et l'estimateur de β noté $\hat{\beta}_W$.

Espérance mathématique et variance de β_W

L'estimateur β_W peut être écrit sous la forme :

$$\hat{\beta}_W = (X' M_D X)^{-1} X' M_D Y$$

Espérance mathématique et variance de β_W

L'estimateur β_W peut être écrit sous la forme :

$$\begin{aligned}\hat{\beta}_W &= (X' M_D X)^{-1} X' M_D Y \\ &= (X' M_D X)^{-1} X' M_D (D\alpha + X\beta + \varepsilon)\end{aligned}$$

Espérance mathématique et variance de β_W

L'estimateur β_W peut être écrit sous la forme :

$$\begin{aligned}\hat{\beta}_W &= (X' M_D X)^{-1} X' M_D Y \\ &= (X' M_D X)^{-1} X' M_D (D\alpha + X\beta + \varepsilon) \\ &= (X' M_D X)^{-1} X' (M_D D\alpha + M_D X\beta + M_D \varepsilon)\end{aligned}$$

Espérance mathématique et variance de β_W

L'estimateur β_W peut être écrit sous la forme :

$$\begin{aligned}\hat{\beta}_W &= (X' M_D X)^{-1} X' M_D Y \\ &= (X' M_D X)^{-1} X' M_D (D\alpha + X\beta + \varepsilon) \\ &= (X' M_D X)^{-1} X' (M_D D\alpha + M_D X\beta + M_D \varepsilon) \\ &= (X' M_D X)^{-1} X' (M_D X\beta + M_D \varepsilon)\end{aligned}$$

Espérance mathématique et variance de β_W

L'estimateur β_W peut être écrit sous la forme :

$$\begin{aligned}\hat{\beta}_W &= (X' M_D X)^{-1} X' M_D Y \\ &= (X' M_D X)^{-1} X' M_D (D\alpha + X\beta + \varepsilon) \\ &= (X' M_D X)^{-1} X' (M_D D\alpha + M_D X\beta + M_D \varepsilon) \\ &= (X' M_D X)^{-1} X' (M_D X\beta + M_D \varepsilon) \\ &= (X' M_D X)^{-1} X' M_D X\beta + (X' M_D X)^{-1} X' M_D \varepsilon\end{aligned}$$

Espérance mathématique et variance de β_W

L'estimateur β_W peut être écrit sous la forme :

$$\begin{aligned}\hat{\beta}_W &= (X' M_D X)^{-1} X' M_D Y \\ &= (X' M_D X)^{-1} X' M_D (D\alpha + X\beta + \varepsilon) \\ &= (X' M_D X)^{-1} X' (M_D D\alpha + M_D X\beta + M_D \varepsilon) \\ &= (X' M_D X)^{-1} X' (M_D X\beta + M_D \varepsilon) \\ &= (X' M_D X)^{-1} X' M_D X\beta + (X' M_D X)^{-1} X' M_D \varepsilon \\ &= \beta + (X' M_D X)^{-1} X' M_D \varepsilon\end{aligned}$$

Espérance mathématique et variance de β_W

L'estimateur β_W peut être écrit sous la forme :

$$\begin{aligned}\hat{\beta}_W &= (X' M_D X)^{-1} X' M_D Y \\ &= (X' M_D X)^{-1} X' M_D (D\alpha + X\beta + \varepsilon) \\ &= (X' M_D X)^{-1} X' (M_D D\alpha + M_D X\beta + M_D \varepsilon) \\ &= (X' M_D X)^{-1} X' (M_D X\beta + M_D \varepsilon) \\ &= (X' M_D X)^{-1} X' M_D X\beta + (X' M_D X)^{-1} X' M_D \varepsilon \\ &= \beta + (X' M_D X)^{-1} X' M_D \varepsilon\end{aligned}$$

$$E(\hat{\beta}_W) = \beta + (X' M_D X)^{-1} X' M_D E(\varepsilon) = \beta$$

Espérance mathématique et variance de β_W

L'estimateur β_W peut être écrit sous la forme :

$$\begin{aligned}
 \hat{\beta}_W &= (X' M_D X)^{-1} X' M_D Y \\
 &= (X' M_D X)^{-1} X' M_D (D\alpha + X\beta + \varepsilon) \\
 &= (X' M_D X)^{-1} X' (M_D D\alpha + M_D X\beta + M_D \varepsilon) \\
 &= (X' M_D X)^{-1} X' (M_D X\beta + M_D \varepsilon) \\
 &= (X' M_D X)^{-1} X' M_D X\beta + (X' M_D X)^{-1} X' M_D \varepsilon \\
 &= \beta + (X' M_D X)^{-1} X' M_D \varepsilon
 \end{aligned}$$

$$E(\hat{\beta}_W) = \beta + (X' M_D X)^{-1} X' M_D E(\varepsilon) = \beta$$

$$\begin{aligned}
 V(\hat{\beta}_W) &= (X' M_D X)^{-1} X' M_D V(\varepsilon) M_D X (X' M_D X)^{-1} \\
 &= \sigma^2 (X' M_D X)^{-1} X' M_D M_D X (X' M_D X)^{-1} = \sigma^2 (X' M_D X)^{-1}
 \end{aligned}$$

Estimateur sans biais de σ_ε^2

Faisons remarquer que :

$$\bar{Y} = \begin{pmatrix} \bar{Y}_1 \\ \bar{Y}_2 \\ \vdots \\ \bar{Y}_n \end{pmatrix} = (D'D)^{-1}D'Y \text{ et } \bar{X}_l = \begin{pmatrix} \bar{X}_{l1} \\ \bar{X}_{l2} \\ \vdots \\ \bar{X}_{ln} \end{pmatrix} = (D'D)^{-1}D'X_l$$

Estimateur sans biais de σ_ε^2

Faisons remarquer que :

$$\bar{Y} = \begin{pmatrix} \bar{Y}_1 \\ \bar{Y}_2 \\ \vdots \\ \bar{Y}_n \end{pmatrix} = (D'D)^{-1}D'Y \text{ et } \bar{X}_l = \begin{pmatrix} \bar{X}_{l1} \\ \bar{X}_{l2} \\ \vdots \\ \bar{X}_{ln} \end{pmatrix} = (D'D)^{-1}D'X_l$$

Ce qui permet d'écrire :

$$\hat{\alpha} = \bar{Y} - \bar{X}\hat{\beta} = (D'D)^{-1}D'Y - (D'D)^{-1}D'X\hat{\beta}$$

Estimateur sans biais de σ_ε^2

Faisons remarquer que :

$$\bar{Y} = \begin{pmatrix} \bar{Y}_1 \\ \bar{Y}_2 \\ \vdots \\ \bar{Y}_n \end{pmatrix} = (D'D)^{-1}D'Y \text{ et } \bar{X}_l = \begin{pmatrix} \bar{X}_{l1} \\ \bar{X}_{l2} \\ \vdots \\ \bar{X}_{ln} \end{pmatrix} = (D'D)^{-1}D'X_l$$

Ce qui permet d'écrire :

$$\hat{\alpha} = \bar{Y} - \bar{X}\hat{\beta} = (D'D)^{-1}D'Y - (D'D)^{-1}D'X\hat{\beta}$$

Le vecteur des résidus peut être écrit sous la forme :

$$\hat{\varepsilon} = Y - D\hat{\alpha} - X\hat{\beta}$$

Estimateur sans biais de σ_ε^2

Faisons remarquer que :

$$\bar{Y} = \begin{pmatrix} \bar{Y}_1 \\ \bar{Y}_2 \\ \vdots \\ \bar{Y}_n \end{pmatrix} = (D'D)^{-1}D'Y \text{ et } \bar{X}_l = \begin{pmatrix} \bar{X}_{l1} \\ \bar{X}_{l2} \\ \vdots \\ \bar{X}_{ln} \end{pmatrix} = (D'D)^{-1}D'X_l$$

Ce qui permet d'écrire :

$$\hat{\alpha} = \bar{Y} - \bar{X}\hat{\beta} = (D'D)^{-1}D'Y - (D'D)^{-1}D'X\hat{\beta}$$

Le vecteur des résidus peut être écrit sous la forme :

$$\begin{aligned} \hat{\varepsilon} &= Y - D\hat{\alpha} - X\hat{\beta} \\ &= Y - D\left((D'D)^{-1}D'Y - (D'D)^{-1}D'X\hat{\beta}\right) - X\hat{\beta} \end{aligned}$$

Estimateur sans biais de σ_ε^2

Faisons remarquer que :

$$\bar{Y} = \begin{pmatrix} \bar{Y}_1 \\ \bar{Y}_2 \\ \vdots \\ \bar{Y}_n \end{pmatrix} = (D'D)^{-1}D'Y \text{ et } \bar{X}_l = \begin{pmatrix} \bar{X}_{l1} \\ \bar{X}_{l2} \\ \vdots \\ \bar{X}_{ln} \end{pmatrix} = (D'D)^{-1}D'X_l$$

Ce qui permet d'écrire :

$$\hat{\alpha} = \bar{Y} - \bar{X}\hat{\beta} = (D'D)^{-1}D'Y - (D'D)^{-1}D'X\hat{\beta}$$

Le vecteur des résidus peut être écrit sous la forme :

$$\begin{aligned} \hat{\varepsilon} &= Y - D\hat{\alpha} - X\hat{\beta} \\ &= Y - D \left((D'D)^{-1}D'Y - (D'D)^{-1}D'X\hat{\beta} \right) - X\hat{\beta} \\ &= [I - D(D'D)^{-1}D'] Y - [I - D(D'D)^{-1}D'] X\hat{\beta} \end{aligned}$$

Estimateur sans biais de σ_ε^2

Faisons remarquer que :

$$\bar{Y} = \begin{pmatrix} \bar{Y}_1 \\ \bar{Y}_2 \\ \vdots \\ \bar{Y}_n \end{pmatrix} = (D'D)^{-1}D'Y \text{ et } \bar{X}_l = \begin{pmatrix} \bar{X}_{l1} \\ \bar{X}_{l2} \\ \vdots \\ \bar{X}_{ln} \end{pmatrix} = (D'D)^{-1}D'X_l$$

Ce qui permet d'écrire :

$$\hat{\alpha} = \bar{Y} - \bar{X}\hat{\beta} = (D'D)^{-1}D'Y - (D'D)^{-1}D'X\hat{\beta}$$

Le vecteur des résidus peut être écrit sous la forme :

$$\begin{aligned} \hat{\varepsilon} &= Y - D\hat{\alpha} - X\hat{\beta} \\ &= Y - D\left((D'D)^{-1}D'Y - (D'D)^{-1}D'X\hat{\beta}\right) - X\hat{\beta} \\ &= [I - D(D'D)^{-1}D']Y - [I - D(D'D)^{-1}D']X\hat{\beta} \end{aligned}$$

$$\hat{\varepsilon} = [I - D(D'D)^{-1}D'] Y - [I - D(D'D)^{-1}D'] X\hat{\beta}$$

$$\begin{aligned}\hat{\varepsilon} &= [I - D(D'D)^{-1}D'] Y - [I - D(D'D)^{-1}D'] X\hat{\beta} \\ &= M_D Y - M_D X\hat{\beta} = M_D Y - M_D X (X' M_D X)^{-1} X' M_D Y = WY\end{aligned}$$

$$\begin{aligned}\hat{\varepsilon} &= [I - D(D'D)^{-1}D'] Y - [I - D(D'D)^{-1}D'] X\hat{\beta} \\ &= M_D Y - M_D X\hat{\beta} = M_D Y - M_D X (X' M_D X)^{-1} X' M_D Y = WY\end{aligned}$$

Avec

$$W = M_D - M_D X (X' M_D X)^{-1} X' M_D$$

est une matrice symétrique, idempotente, $W \cdot D = 0$ et $W \cdot X = 0$.

En effet ;

$$W \cdot D = \left(M_D - M_D X (X' M_D X)^{-1} X' M_D \right) D$$

$$\begin{aligned}\hat{\varepsilon} &= [I - D(D'D)^{-1}D'] Y - [I - D(D'D)^{-1}D'] X\hat{\beta} \\ &= M_D Y - M_D X\hat{\beta} = M_D Y - M_D X (X' M_D X)^{-1} X' M_D Y = WY\end{aligned}$$

Avec

$$W = M_D - M_D X (X' M_D X)^{-1} X' M_D$$

est une matrice symétrique, idempotente, $W \cdot D = 0$ et $W \cdot X = 0$.

En effet ;

$$\begin{aligned}W \cdot D &= \left(M_D - M_D X (X' M_D X)^{-1} X' M_D \right) D \\ &= M_D D - M_D X (X' M_D X)^{-1} X' M_D D = 0 \\ W \cdot X &= \left(M_D - M_D X (X' M_D X)^{-1} X' M_D \right) X\end{aligned}$$

$$\begin{aligned}\hat{\varepsilon} &= [I - D(D'D)^{-1}D'] Y - [I - D(D'D)^{-1}D'] X\hat{\beta} \\ &= M_D Y - M_D X\hat{\beta} = M_D Y - M_D X (X' M_D X)^{-1} X' M_D Y = WY\end{aligned}$$

Avec

$$W = M_D - M_D X (X' M_D X)^{-1} X' M_D$$

est une matrice symétrique, idempotente, $W \cdot D = 0$ et $W \cdot X = 0$.

En effet ;

$$\begin{aligned}W \cdot D &= \left(M_D - M_D X (X' M_D X)^{-1} X' M_D \right) D \\ &= M_D D - M_D X (X' M_D X)^{-1} X' M_D D = 0 \\ W \cdot X &= \left(M_D - M_D X (X' M_D X)^{-1} X' M_D \right) X \\ &= M_D X - M_D X (X' M_D X)^{-1} X' M_D X = M_D X - M_D X = 0\end{aligned}$$

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) =$$

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) = W \cdot D\alpha + W \cdot X\beta + W\varepsilon =$$

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) = W \cdot D\alpha + W \cdot X\beta + W\varepsilon = W\varepsilon$$

Et la somme des carrés des résidus (SCR_W) est exprimée en fonction des termes d'erreur ε :

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) = W \cdot D\alpha + W \cdot X\beta + W\varepsilon = W\varepsilon$$

Et la somme des carrés des résidus (SCR_W) est exprimée en fonction des termes d'erreur ε :

$$SCR_W = \hat{\varepsilon}'\hat{\varepsilon} = (W\varepsilon)'(W\varepsilon) = \varepsilon'W\varepsilon$$

Et :

$$E(SCR_W) = E(\varepsilon'W\varepsilon) = E(\text{trace}(\varepsilon'W\varepsilon))$$

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) = W \cdot D\alpha + W \cdot X\beta + W\varepsilon = W\varepsilon$$

Et la somme des carrés des résidus (SCR_W) est exprimée en fonction des termes d'erreur ε :

$$SCR_W = \hat{\varepsilon}'\hat{\varepsilon} = (W\varepsilon)'(W\varepsilon) = \varepsilon'W\varepsilon$$

Et :

$$\begin{aligned} E(SCR_W) &= E(\varepsilon'W\varepsilon) = E(\text{trace}(\varepsilon'W\varepsilon)) \\ &= E(\text{trace}(W\varepsilon\varepsilon')) = (\text{trace}(W \cdot E(\varepsilon\varepsilon'))) \end{aligned}$$

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) = W \cdot D\alpha + W \cdot X\beta + W\varepsilon = W\varepsilon$$

Et la somme des carrés des résidus (SCR_W) est exprimée en fonction des termes d'erreur ε :

$$SCR_W = \hat{\varepsilon}'\hat{\varepsilon} = (W\varepsilon)'(W\varepsilon) = \varepsilon'W\varepsilon$$

Et :

$$\begin{aligned} E(SCR_W) &= E(\varepsilon'W\varepsilon) = E(\text{trace}(\varepsilon'W\varepsilon)) \\ &= E(\text{trace}(W\varepsilon\varepsilon')) = (\text{trace}(W \cdot E(\varepsilon\varepsilon'))) \\ &= \sigma_\varepsilon^2 \text{trace}(W) = \sigma_\varepsilon^2 \text{trace}(M_D - M_D X(X' M_D X)^{-1} X' M_D) \end{aligned}$$

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) = W \cdot D\alpha + W \cdot X\beta + W\varepsilon = W\varepsilon$$

Et la somme des carrés des résidus (SCR_W) est exprimée en fonction des termes d'erreur ε :

$$SCR_W = \hat{\varepsilon}'\hat{\varepsilon} = (W\varepsilon)'(W\varepsilon) = \varepsilon'W\varepsilon$$

Et :

$$\begin{aligned} E(SCR_W) &= E(\varepsilon'W\varepsilon) = E(\text{trace}(\varepsilon'W\varepsilon)) \\ &= E(\text{trace}(W\varepsilon\varepsilon')) = (\text{trace}(W \cdot E(\varepsilon\varepsilon'))) \\ &= \sigma_\varepsilon^2 \text{trace}(W) = \sigma_\varepsilon^2 \text{trace}(M_D - M_D X(X' M_D X)^{-1} X' M_D) \\ &= \sigma_\varepsilon^2 (\text{trace}(I) - \text{trace}(D(D'D)^{-1} D') - \text{trace}(M_D X(X' M_D X)^{-1} X' M_D)) \end{aligned}$$

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) = W \cdot D\alpha + W \cdot X\beta + W\varepsilon = W\varepsilon$$

Et la somme des carrés des résidus (SCR_W) est exprimée en fonction des termes d'erreur ε :

$$SCR_W = \hat{\varepsilon}'\hat{\varepsilon} = (W\varepsilon)'(W\varepsilon) = \varepsilon'W\varepsilon$$

Et :

$$\begin{aligned} E(SCR_W) &= E(\varepsilon'W\varepsilon) = E(\text{trace}(\varepsilon'W\varepsilon)) \\ &= E(\text{trace}(W\varepsilon\varepsilon')) = (\text{trace}(W \cdot E(\varepsilon\varepsilon'))) \\ &= \sigma_\varepsilon^2 \text{trace}(W) = \sigma_\varepsilon^2 \text{trace}(M_D - M_D X(X' M_D X)^{-1} X' M_D) \\ &= \sigma_\varepsilon^2 (\text{trace}(I) - \text{trace}(D(D'D)^{-1} D') - \text{trace}(M_D X(X' M_D X)^{-1} X' M_D)) \\ &= \sigma_\varepsilon^2 (\text{trace}(I) - \text{trace}((D'D)^{-1} (D'D)) - \text{trace}((X' M_D X)^{-1} (X' M_D X))) \end{aligned}$$

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) = W \cdot D\alpha + W \cdot X\beta + W\varepsilon = W\varepsilon$$

Et la somme des carrés des résidus (SCR_W) est exprimée en fonction des termes d'erreur ε :

$$SCR_W = \hat{\varepsilon}'\hat{\varepsilon} = (W\varepsilon)'(W\varepsilon) = \varepsilon'W\varepsilon$$

Et :

$$\begin{aligned} E(SCR_W) &= E(\varepsilon'W\varepsilon) = E(\text{trace}(\varepsilon'W\varepsilon)) \\ &= E(\text{trace}(W\varepsilon\varepsilon')) = (\text{trace}(W \cdot E(\varepsilon\varepsilon'))) \\ &= \sigma_\varepsilon^2 \text{trace}(W) = \sigma_\varepsilon^2 \text{trace}(M_D - M_D X(X' M_D X)^{-1} X' M_D) \\ &= \sigma_\varepsilon^2 (\text{trace}(I) - \text{trace}(D(D'D)^{-1} D') - \text{trace}(M_D X(X' M_D X)^{-1} X' M_D)) \\ &= \sigma_\varepsilon^2 (\text{trace}(I) - \text{trace}((D'D)^{-1} (D'D)) - \text{trace}((X' M_D X)^{-1} (X' M_D X))) \\ &= \sigma_\varepsilon^2 (\text{trace}(I_{n \cdot T}) - \text{Trace}(I_n) - \text{trace}(I_k)) = \sigma_\varepsilon^2 (n \cdot T - n - k) \end{aligned}$$

Ce qui permet d'écrire :

$$\hat{\varepsilon} = W \cdot Y = W(D\alpha + X\beta + \varepsilon) = W \cdot D\alpha + W \cdot X\beta + W\varepsilon = W\varepsilon$$

Et la somme des carrés des résidus (SCR_W) est exprimée en fonction des termes d'erreur ε :

$$SCR_W = \hat{\varepsilon}'\hat{\varepsilon} = (W\varepsilon)'(W\varepsilon) = \varepsilon'W\varepsilon$$

Et :

$$\begin{aligned} E(SCR_W) &= E(\varepsilon'W\varepsilon) = E(\text{trace}(\varepsilon'W\varepsilon)) \\ &= E(\text{trace}(W\varepsilon\varepsilon')) = (\text{trace}(W \cdot E(\varepsilon\varepsilon'))) \\ &= \sigma_\varepsilon^2 \text{trace}(W) = \sigma_\varepsilon^2 \text{trace}(M_D - M_D X(X' M_D X)^{-1} X' M_D) \\ &= \sigma_\varepsilon^2 (\text{trace}(I) - \text{trace}(D(D'D)^{-1} D') - \text{trace}(M_D X(X' M_D X)^{-1} X' M_D)) \\ &= \sigma_\varepsilon^2 (\text{trace}(I) - \text{trace}((D'D)^{-1} (D'D)) - \text{trace}((X' M_D X)^{-1} (X' M_D X))) \\ &= \sigma_\varepsilon^2 (\text{trace}(I_{n \cdot T}) - \text{Trace}(I_n) - \text{trace}(I_k)) = \sigma_\varepsilon^2 (n \cdot T - n - k) \end{aligned}$$

Conclusion : $\hat{\sigma}_\varepsilon^2 = \frac{SCR_W}{n \cdot T - n - k}$ est un estimateur sans biais de σ_ε^2 .

Un modèle à effet (individuel) aléatoire est défini comme suit :

$$Y_{it} = \alpha_i + \beta_1 X_{1it} + \beta_2 X_{2it} + \cdots + \beta_k X_{kit} + \varepsilon_{it}$$

pour $i = 1, 2, \dots, n$ et $t = 1, 2, \dots, T$

avec

- Y : La variable endogène (expliquée)
- X_1, X_2, \dots, X_k : k variables explicatives (exogènes)
- $\alpha_i, \beta_1, \dots, \beta_k$: des paramètres à estimer
- ε_{it} est un terme d'erreur qui vérifie les hypothèses suivantes :
 - $E(\varepsilon_{it}) = 0 \forall i, t,$
 - $E(\varepsilon_{it}^2) = \sigma_\varepsilon^2 \forall i, t$
 - $E(\varepsilon_{it}\varepsilon_{js}) = 0 \forall i \neq j \text{ ou } t \neq s,$
 - $cov(X_{lit}, \varepsilon_{js}) = 0 \forall l, i, j, t, s.$

Un modèle à effet (individuel) aléatoire est défini comme suit :

$$Y_{it} = \alpha_i + \beta_1 X_{1it} + \beta_2 X_{2it} + \cdots + \beta_k X_{kit} + \varepsilon_{it}$$

pour $i = 1, 2, \dots, n$ et $t = 1, 2, \dots, T$

avec

- Y : La variable endogène (expliquée)
- X_1, X_2, \dots, X_k : k variables explicatives (exogènes)
- $\alpha_i, \beta_1, \dots, \beta_k$: des paramètres à estimer
- ε_{it} est un terme d'erreur qui vérifie les hypothèses suivantes :
 - $E(\varepsilon_{it}) = 0 \forall i, t,$
 - $E(\varepsilon_{it}^2) = \sigma_\varepsilon^2 \forall i, t$
 - $E(\varepsilon_{it}\varepsilon_{js}) = 0 \forall i \neq j \text{ ou } s \neq t,$
 - $cov(X_{lit}, \varepsilon_{js}) = 0 \forall l, i, j, t, s.$
- $\alpha_i = \alpha + u_i$ où u_i est un terme aléatoire représentant l'effet individuel

Le terme d'erreur u_i vérifie les hypothèses suivantes :

- $E(u_i) = 0 \forall i$
- $E(u_i^2) = \sigma_u^2 \forall i$
- $E(u_i u_j) = 0$ pour $i \neq j$
- $E(u_i \varepsilon_{jt}) = 0 \forall i, j, t$
- $E(u_i X_{ljt}) = 0 \forall i, l, j, t$

Le terme d'erreur u_i vérifie les hypothèses suivantes :

- $E(u_i) = 0 \forall i$
- $E(u_i^2) = \sigma_u^2 \forall i$
- $E(u_i u_j) = 0$ pour $i \neq j$
- $E(u_i \varepsilon_{jt}) = 0 \forall i, j, t$
- $E(u_i X_{ljt}) = 0 \forall i, l, j, t$

Et le modèle peut être réécrit sous la forme :

$$Y_{it} = \alpha + \beta_1 X_{1it} + \beta_2 X_{2it} + \cdots + \beta_k X_{kit} + \varepsilon_{it} + u_i$$

pour $i = 1, 2, \dots, n$ et $t = 1, 2, \dots, T$

Le terme d'erreur u_i vérifie les hypothèses suivantes :

- $E(u_i) = 0 \forall i$
- $E(u_i^2) = \sigma_u^2 \forall i$
- $E(u_i u_j) = 0$ pour $i \neq j$
- $E(u_i \varepsilon_{jt}) = 0 \forall i, j, t$
- $E(u_i X_{ljt}) = 0 \forall i, l, j, t$

Et le modèle peut être réécrit sous la forme :

$$Y_{it} = \alpha + \beta_1 X_{1it} + \beta_2 X_{2it} + \cdots + \beta_k X_{kit} + \varepsilon_{it} + u_i$$

pour $i = 1, 2, \dots, n$ et $t = 1, 2, \dots, T$

Observation : Le modèle à effet aléatoire est appelé modèle à erreur composée :

$$\omega_{it} = \varepsilon_{it} + u_i$$

Considérons le vecteur du terme d'erreur pour un individu i donné :

$$\omega_i = \begin{pmatrix} \varepsilon_{i1} + u_i \\ \varepsilon_{i2} + u_i \\ \vdots \\ \varepsilon_{iT} + u_i \end{pmatrix} =$$

Considérons le vecteur du terme d'erreur pour un individu i donné :

$$\omega_i = \begin{pmatrix} \varepsilon_{i1} + u_i \\ \varepsilon_{i2} + u_i \\ \vdots \\ \varepsilon_{iT} + u_i \end{pmatrix} = \begin{pmatrix} \varepsilon_{i1} \\ \varepsilon_{i2} \\ \vdots \\ \varepsilon_{iT} \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} u_i$$

Considérons le vecteur du terme d'erreur pour un individu i donné :

$$\omega_i = \begin{pmatrix} \varepsilon_{i1} + u_i \\ \varepsilon_{i2} + u_i \\ \vdots \\ \varepsilon_{iT} + u_i \end{pmatrix} = \begin{pmatrix} \varepsilon_{i1} \\ \varepsilon_{i2} \\ \vdots \\ \varepsilon_{iT} \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} u_i = \varepsilon_i + e \cdot u_i$$

e étant le vecteur unitaire de dimension T Sous les hypothèse du modèle à erreur composée, $E(\omega_i) = 0$ et la variance de ω_i est définie par :

$$V(\omega_i) = V(\varepsilon_i) + e \cdot V(u_i)e'$$

Considérons le vecteur du terme d'erreur pour un individu i donné :

$$\omega_i = \begin{pmatrix} \varepsilon_{i1} + u_i \\ \varepsilon_{i2} + u_i \\ \vdots \\ \varepsilon_{iT} + u_i \end{pmatrix} = \begin{pmatrix} \varepsilon_{i1} \\ \varepsilon_{i2} \\ \vdots \\ \varepsilon_{iT} \end{pmatrix} + \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} u_i = \varepsilon_i + e \cdot u_i$$

e étant le vecteur unitaire de dimension T Sous les hypothèse du modèle à erreur composée, $E(\omega_i) = 0$ et la variance de ω_i est définie par :

$$V(\omega_i) = V(\varepsilon_i) + e \cdot V(u_i)e' = \sigma_\varepsilon^2 I + \sigma_u^2 ee'$$

Observation :

$$\text{var}(\omega_i) = \begin{pmatrix} \sigma_\varepsilon^2 + \sigma_u^2 & \sigma_u^2 & \cdots & \sigma_u^2 \\ \sigma_u^2 & \sigma_\varepsilon^2 + \sigma_u^2 & \cdots & \sigma_u^2 \\ \vdots & \vdots & \vdots & \vdots \\ \sigma_u^2 & \sigma_u^2 & \cdots & \sigma_\varepsilon^2 + \sigma_u^2 \end{pmatrix} \neq \sigma^2 I$$

La matrice de variance covariance de ω_i peut être écrite sous la forme :

$$V(\omega_i) = \sigma_\varepsilon^2 I + \sigma_u^2 ee' =$$

La matrice de variance covariance de ω_i peut être écrite sous la forme :

$$V(\omega_i) = \sigma_\varepsilon^2 I + \sigma_u^2 e e' = \sigma_\varepsilon^2 \left\{ I + \frac{T \sigma_u^2}{\sigma_\varepsilon^2} e (e' e)^{-1} e' \right\} ; (e' e = T)$$

La matrice de variance covariance de ω_i peut être écrite sous la forme :

$$V(\omega_i) = \sigma_\varepsilon^2 I + \sigma_u^2 e e' = \sigma_\varepsilon^2 \left\{ I + \frac{T \sigma_u^2}{\sigma_\varepsilon^2} e (e' e)^{-1} e' \right\} ; (e' e = T)$$

$$= \sigma_\varepsilon^2 \{ I + \lambda B \} = \sigma_\varepsilon^2 \Omega$$

. avec $\lambda = \frac{T \sigma_u^2}{\sigma_\varepsilon^2}$ et $B = e (e' e)^{-1} e'$ est une matrice idempotente

La matrice de variance covariance de ω_i peut être écrite sous la forme :

$$\begin{aligned} V(\omega_i) &= \sigma_\varepsilon^2 I + \sigma_u^2 e e' = \sigma_\varepsilon^2 \left\{ I + \frac{T \sigma_u^2}{\sigma_\varepsilon^2} e (e'e)^{-1} e' \right\} ; (e'e = T) \\ &= \sigma_\varepsilon^2 \{ I + \lambda B \} = \sigma_\varepsilon^2 \Omega \end{aligned}$$

. avec $\lambda = \frac{T \sigma_u^2}{\sigma_\varepsilon^2}$ et $B = e (e'e)^{-1} e'$ est une matrice idempotente Si on considère les observations pour tous les individus, la matrice de variance-covariance du terme d'erreur est égale à :

$$V(\omega) = V \begin{pmatrix} \omega_1 \\ \omega_2 \\ \vdots \\ \omega_n \end{pmatrix}$$

La matrice de variance covariance de ω_i peut être écrite sous la forme :

$$\begin{aligned} V(\omega_i) &= \sigma_\varepsilon^2 I + \sigma_u^2 e e' = \sigma_\varepsilon^2 \left\{ I + \frac{T \sigma_u^2}{\sigma_\varepsilon^2} e (e'e)^{-1} e' \right\} ; (e'e = T) \\ &= \sigma_\varepsilon^2 \{I + \lambda B\} = \sigma_\varepsilon^2 \Omega \end{aligned}$$

. avec $\lambda = \frac{T \sigma_u^2}{\sigma_\varepsilon^2}$ et $B = e (e'e)^{-1} e'$ est une matrice idempotente Si on considère les observations pour tous les individus, la matrice de variance-covariance du terme d'erreur est égale à :

$$V(\omega) = V \begin{pmatrix} \omega_1 \\ \omega_2 \\ \vdots \\ \omega_n \end{pmatrix} = \sigma_\varepsilon^2 \begin{pmatrix} \Omega & 0 & \cdots & 0 \\ 0 & \Omega & 0 & \cdots \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & \Omega \end{pmatrix} =$$

La matrice de variance covariance de ω_i peut être écrite sous la forme :

$$\begin{aligned} V(\omega_i) &= \sigma_\varepsilon^2 I + \sigma_u^2 e e' = \sigma_\varepsilon^2 \left\{ I + \frac{T \sigma_u^2}{\sigma_\varepsilon^2} e (e'e)^{-1} e' \right\} ; (e'e = T) \\ &= \sigma_\varepsilon^2 \{I + \lambda B\} = \sigma_\varepsilon^2 \Omega \end{aligned}$$

. avec $\lambda = \frac{T \sigma_u^2}{\sigma_\varepsilon^2}$ et $B = e (e'e)^{-1} e'$ est une matrice idempotente Si on considère les observations pour tous les individus, la matrice de variance-covariance du terme d'erreur est égale à :

$$V(\omega) = V \begin{pmatrix} \omega_1 \\ \omega_2 \\ \vdots \\ \omega_n \end{pmatrix} = \sigma_\varepsilon^2 \begin{pmatrix} \Omega & 0 & \cdots & 0 \\ 0 & \Omega & 0 & \cdots \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & \Omega \end{pmatrix} = \sigma_\varepsilon^2 \text{diag}(\Omega) = \sigma_\varepsilon^2 \Sigma$$

et

$$\Sigma = \text{diag}(\Omega)$$

et on montre que :

$$\Omega^{-1} =$$

La matrice de variance covariance de ω_i peut être écrite sous la forme :

$$\begin{aligned} V(\omega_i) &= \sigma_\varepsilon^2 I + \sigma_u^2 e e' = \sigma_\varepsilon^2 \left\{ I + \frac{T \sigma_u^2}{\sigma_\varepsilon^2} e (e'e)^{-1} e' \right\} ; (e'e = T) \\ &= \sigma_\varepsilon^2 \{I + \lambda B\} = \sigma_\varepsilon^2 \Omega \end{aligned}$$

. avec $\lambda = \frac{T \sigma_u^2}{\sigma_\varepsilon^2}$ et $B = e (e'e)^{-1} e'$ est une matrice idempotente Si on considère les observations pour tous les individus, la matrice de variance-covariance du terme d'erreur est égale à :

$$V(\omega) = V \begin{pmatrix} \omega_1 \\ \omega_2 \\ \vdots \\ \omega_n \end{pmatrix} = \sigma_\varepsilon^2 \begin{pmatrix} \Omega & 0 & \cdots & 0 \\ 0 & \Omega & 0 & \cdots \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & \Omega \end{pmatrix} = \sigma_\varepsilon^2 \text{diag}(\Omega) = \sigma_\varepsilon^2 \Sigma$$

et

$$\Sigma = \text{diag}(\Omega)$$

et on montre que :

$$\Omega^{-1} = I - \frac{\lambda}{1 + \lambda} B ; B \text{ étant idempotente}$$

L'estimateur par Moindres Carrés Généralisée est défini par :

$$\hat{\beta}_{mcg} = \{x' \Sigma^{-1} x\}^{-1} x' \Sigma^{-1} y = (x' \text{diag}(\Omega^{-1}) x)^{-1} x' \text{diag}(\Omega^{-1}) y$$

x et y variables centrées autour des moyennes générales.

En faisons les mêmes développement que pour le modèle à effet fixe :

$$\hat{\beta}_{mcg} = \beta + \{x' \Sigma^{-1} x\}^{-1} x' \Sigma^{-1} (\varepsilon + D \cdot u)$$

L'estimateur par Moindres Carrés Généralisée est défini par :

$$\hat{\beta}_{mcg} = \{x' \Sigma^{-1} x\}^{-1} x' \Sigma^{-1} y = (x' \text{diag}(\Omega^{-1}) x)^{-1} x' \text{diag}(\Omega^{-1}) y$$

x et y variables centrées autour des moyennes générales.

En faisons les mêmes développement que pour le modèle à effet fixe :

$$\begin{aligned}\hat{\beta}_{mcg} &= \beta + \{x' \Sigma^{-1} x\}^{-1} x' \Sigma^{-1} (\varepsilon + D \cdot u) \\ E(\hat{\beta}_{mcg}) &= \beta\end{aligned}$$

L'estimateur par Moindres Carrés Généralisée est défini par :

$$\hat{\beta}_{mcg} = \{x' \Sigma^{-1} x\}^{-1} x' \Sigma^{-1} y = (x' \text{diag}(\Omega^{-1}) x)^{-1} x' \text{diag}(\Omega^{-1}) y$$

x et y variables centrées autour des moyennes générales.

En faisons les mêmes développement que pour le modèle à effet fixe :

$$\hat{\beta}_{mcg} = \beta + \{x' \Sigma^{-1} x\}^{-1} x' \Sigma^{-1} (\varepsilon + D \cdot u)$$

$$E(\hat{\beta}_{mcg}) = \beta$$

$$V(\hat{\beta}_{mcg}) = \sigma_{\varepsilon}^2 \{x' \Sigma^{-1} x\}^{-1}$$

u le vecteur colonne des effets individuels.

$$u = \begin{pmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{pmatrix}$$

Observations



$$\Sigma^{-1} = \text{diag}(\Omega^{-1}) = \text{diag}(I) - \frac{\lambda}{1 + \lambda} \text{diag}(B)$$

Observations



$$\begin{aligned}\Sigma^{-1} = \text{diag}(\Omega^{-1}) &= \text{diag}(I) - \frac{\lambda}{1 + \lambda} \text{diag}(B) \\ &= \text{diag}(I) - \text{diag}(B) + \text{diag}(B) - \frac{\lambda}{1 + \lambda} \text{diag}(B)\end{aligned}$$

Observations



$$\begin{aligned}
 \Sigma^{-1} = \text{diag}(\Omega^{-1}) &= \text{diag}(I) - \frac{\lambda}{1+\lambda} \text{diag}(B) \\
 &= \text{diag}(I) - \text{diag}(B) + \text{diag}(B) - \frac{\lambda}{1+\lambda} \text{diag}(B) \\
 &= M_D + \frac{1}{1+\lambda} D (D'D)^{-1} D'
 \end{aligned}$$

- ✓ Sachant que pré-multiplier un vecteur par M_D fournit les données centrées autour des moyennes individuelles ; $M_D X = M_D \bar{X}$ et $M_D Y = M_D \bar{Y}$

Observations

✓

$$\begin{aligned}
 \Sigma^{-1} = \text{diag}(\Omega^{-1}) &= \text{diag}(I) - \frac{\lambda}{1+\lambda} \text{diag}(B) \\
 &= \text{diag}(I) - \text{diag}(B) + \text{diag}(B) - \frac{\lambda}{1+\lambda} \text{diag}(B) \\
 &= M_D + \frac{1}{1+\lambda} D (D'D)^{-1} D'
 \end{aligned}$$

- ✓ Sachant que pré-multiplier un vecteur par M_D fournit les données centrées autour des moyennes individuelles ; $M_D X = M_D X$ et $M_D Y = M_D Y$
- ✓ $D (D'D) D' x = [\bar{X}_{li} - \bar{X}_l]$ et $D (D'D) D' y = [\bar{Y}_i - \bar{Y}]$

On considère les deux estimateurs suivants :

$$\hat{\beta}_W = (X' M_D X)^{-1} X' M_D Y$$

On considère les deux estimateurs suivants :

$$\hat{\beta}_W = (X' M_D X)^{-1} X' M_D Y$$

$$\hat{\beta}_b = \left(X' D (D' D)^{-1} D' X \right)^{-1} X' D (D' D)^{-1} D' y$$

On considère les deux estimateurs suivants :

$$\hat{\beta}_W = (X' M_D X)^{-1} X' M_D Y$$

$$\begin{aligned}\hat{\beta}_b &= \left(x' D (D' D)^{-1} D' x \right)^{-1} x' D (D' D)^{-1} D' y \\ &= (x' D D' x)^{-1} x' D D' y\end{aligned}$$

L'estimateur par MCG peut être écrit sous la forme :

$$\begin{aligned}\hat{\beta}_{mcg} &= \left\{ x' \left(M_D + \frac{1}{1+\lambda} D (D' D)^{-1} D' \right) x \right\}^{-1} \\ &\quad \cdot (x' M_D x) \hat{\beta}_W + \frac{1}{1+\lambda} (x' D (D' D)^{-1} D' x) \hat{\beta}_b\end{aligned}$$

On considère les deux estimateurs suivants :

$$\hat{\beta}_W = (X' M_D X)^{-1} X' M_D Y$$

$$\begin{aligned}\hat{\beta}_b &= \left(x' D (D' D)^{-1} D' x \right)^{-1} x' D (D' D)^{-1} D' y \\ &= (x' D D' x)^{-1} x' D D' y\end{aligned}$$

L'estimateur par MCG peut être écrit sous la forme :

$$\begin{aligned}\hat{\beta}_{mcg} &= \left\{ x' \left(M_D + \frac{1}{1+\lambda} D (D' D)^{-1} D' \right) x \right\}^{-1} \\ &\quad \cdot (x' M_D x) \hat{\beta}_W + \frac{1}{1+\lambda} (x' D (D' D)^{-1} D' x) \hat{\beta}_b\end{aligned}$$

Remarque : L'estimateur $\hat{\beta}_b$ est obtenu en faisant cette régression :

$$\bar{Y}_i = \alpha + \beta_1 \bar{X}_{1i} + \beta_2 \bar{X}_{2i} + \cdots + \beta_k X_{ki} + \bar{\omega}_i \text{ pour } i = 1, 2, \dots, n$$

Et on l'appelle l'estimateur between (Inter)

Le Test de Hausmann consiste à tester l'Hypothèse $H_0 : \hat{\beta}_W = \hat{\beta}_{mcl}$

Le Test de Hausmann consiste à tester l'Hypothèse $H_0 : \hat{\beta}_W = \hat{\beta}_{mgl}$
Rappelons que :

$$\hat{\beta}_W = \beta + (X' M_D X)^{-1} X' M_D \varepsilon$$

Le Test de Hausmann consiste à tester l'Hypothèse $H_0 : \hat{\beta}_W = \hat{\beta}_{mcs}$

Rappelons que :

$$\hat{\beta}_W = \beta + (X' M_D X)^{-1} X' M_D \varepsilon$$

$$\hat{\beta}_{mcs} = \beta + \{x' \Omega^{-1} x\}^{-1} x' \Omega^{-1} (\varepsilon + D \cdot u)$$

Et $\text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcs})$ peut être obtenu par la relation :

$$\text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcs}) = E \left((\hat{\beta}_W - \beta)(\hat{\beta}_{mcs} - \beta)' \right)$$

Le Test de Hausmann consiste à tester l'Hypothèse $H_0 : \hat{\beta}_W = \hat{\beta}_{mcs}$

Rappelons que :

$$\hat{\beta}_W = \beta + (X' M_D X)^{-1} X' M_D \varepsilon$$

$$\hat{\beta}_{mcs} = \beta + \{x' \Omega^{-1} x\}^{-1} x' \Omega^{-1} (\varepsilon + D \cdot u)$$

Et $\text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcs})$ peut être obtenu par la relation :

$$\begin{aligned} \text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcs}) &= E \left((\hat{\beta}_W - \beta)(\hat{\beta}_{mcs} - \beta)' \right) \\ &= E \left((X' M_D X)^{-1} X' M_D \varepsilon (\varepsilon' + u' D') \Omega^{-1} x \{x' \Omega^{-1} x\}^{-1} \right) \end{aligned}$$

Le Test de Hausmann consiste à tester l'Hypothèse $H_0 : \hat{\beta}_W = \hat{\beta}_{mcg}$

Rappelons que :

$$\hat{\beta}_W = \beta + (X' M_D X)^{-1} X' M_D \varepsilon$$

$$\hat{\beta}_{mcg} = \beta + \{x' \Omega^{-1} x\}^{-1} x' \Omega^{-1} (\varepsilon + D \cdot u)$$

Et $\text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcg})$ peut être obtenu par la relation :

$$\begin{aligned} \text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcg}) &= E \left((\hat{\beta}_W - \beta)(\hat{\beta}_{mcg} - \beta)' \right) \\ &= E \left((X' M_D X)^{-1} X' M_D \varepsilon (\varepsilon' + u' D') \Omega^{-1} x \{x' \Omega^{-1} x\}^{-1} \right) \\ &= \sigma_\varepsilon^2 (X' M_D X)^{-1} X' M_D X \{x' \Omega^{-1} x\}^{-1} \end{aligned}$$

Le Test de Hausmann consiste à tester l'Hypothèse $H_0 : \hat{\beta}_W = \hat{\beta}_{mcg}$

Rappelons que :

$$\hat{\beta}_W = \beta + (X' M_D X)^{-1} X' M_D \varepsilon$$

$$\hat{\beta}_{mcg} = \beta + \{x' \Omega^{-1} x\}^{-1} x' \Omega^{-1} (\varepsilon + D \cdot u)$$

Et $\text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcg})$ peut être obtenu par la relation :

$$\begin{aligned} \text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcg}) &= E \left((\hat{\beta}_W - \beta)(\hat{\beta}_{mcg} - \beta)' \right) \\ &= E \left((X' M_D X)^{-1} X' M_D \varepsilon (\varepsilon' + u' D') \Omega^{-1} x \{x' \Omega^{-1} x\}^{-1} \right) \\ &= \sigma_\varepsilon^2 (X' M_D X)^{-1} X' M_D X \{x' \Omega^{-1} x\}^{-1} \\ &= \sigma_\varepsilon^2 \{x' \Omega^{-1} x\}^{-1} = \end{aligned}$$

Le Test de Hausmann consiste à tester l'Hypothèse $H_0 : \hat{\beta}_W = \hat{\beta}_{mcg}$

Rappelons que :

$$\hat{\beta}_W = \beta + (X' M_D X)^{-1} X' M_D \varepsilon$$

$$\hat{\beta}_{mcg} = \beta + \{x' \Omega^{-1} x\}^{-1} x' \Omega^{-1} (\varepsilon + D \cdot u)$$

Et $\text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcg})$ peut être obtenu par la relation :

$$\begin{aligned} \text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcg}) &= E \left((\hat{\beta}_W - \beta)(\hat{\beta}_{mcg} - \beta)' \right) \\ &= E \left((X' M_D X)^{-1} X' M_D \varepsilon (\varepsilon' + u' D') \Omega^{-1} x \{x' \Omega^{-1} x\}^{-1} \right) \\ &= \sigma_\varepsilon^2 (X' M_D X)^{-1} X' M_D X \{x' \Omega^{-1} x\}^{-1} \\ &= \sigma_\varepsilon^2 \{x' \Omega^{-1} x\}^{-1} = V(\hat{\beta}_{mcg}) \end{aligned}$$

Ainsi :

$$V(\hat{\beta}_W - \hat{\beta}_{mcg}) =$$

Ainsi :

$$V(\hat{\beta}_W - \hat{\beta}_{mcs}) = V(\hat{\beta}_W) + V(\hat{\beta}_{mcs}) - 2Cov(\hat{\beta}_W, \hat{\beta}_{mcs})$$

Ainsi :

$$V(\hat{\beta}_W - \hat{\beta}_{mcs}) = V(\hat{\beta}_W) + V(\hat{\beta}_{mcs}) - 2\text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcs}) = V(\hat{\beta}_W) - V(\hat{\beta}_{mcs})$$

Ainsi :

$$V(\hat{\beta}_W - \hat{\beta}_{mcs}) = V(\hat{\beta}_W) + V(\hat{\beta}_{mcs}) - 2\text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcs}) = V(\hat{\beta}_W) - V(\hat{\beta}_{mcs})$$

Et sous l'hypothèse de la normalité des deux termes ε_{it} et u_i :

$$\hat{\beta}_W - \hat{\beta}_{mcs} \rightsquigarrow N(0, V(\hat{\beta}_W) - V(\hat{\beta}_{mcs}))$$

Ainsi :

$$V(\hat{\beta}_W - \hat{\beta}_{mcs}) = V(\hat{\beta}_W) + V(\hat{\beta}_{mcs}) - 2Cov(\hat{\beta}_W, \hat{\beta}_{mcs}) = V(\hat{\beta}_W) - V(\hat{\beta}_{mcs})$$

Et sous l'hypothèse de la normalité des deux termes ε_{it} et u_i :

$$\hat{\beta}_W - \hat{\beta}_{mcs} \rightsquigarrow N(0, V(\hat{\beta}_W) - V(\hat{\beta}_{mcs}))$$

Et en utilisant les Formes Quadratiques des Loix Normales, la statistique du test de Hausmann est donnée par :

Ainsi :

$$V(\hat{\beta}_W - \hat{\beta}_{mcg}) = V(\hat{\beta}_W) + V(\hat{\beta}_{mcg}) - 2\text{Cov}(\hat{\beta}_W, \hat{\beta}_{mcg}) = V(\hat{\beta}_W) - V(\hat{\beta}_{mcg})$$

Et sous l'hypothèse de la normalité des deux termes ε_{it} et u_i :

$$\hat{\beta}_W - \hat{\beta}_{mcg} \rightsquigarrow N(0, V(\hat{\beta}_W) - V(\hat{\beta}_{mcg}))$$

Et en utilisant les Formes Quadratiques des Lois Normales, la statistique du test de Hausmann est donnée par :

$$H = (\hat{\beta}_W - \hat{\beta}_{mcg})' \{ V(\hat{\beta}_W) - V(\hat{\beta}_{mcg}) \}^{-1} (\hat{\beta}_W - \hat{\beta}_{mcg}) \rightsquigarrow \chi^2(k)$$

Observation : Si on accepte H_0 , le modèle est à effet aléatoire

Le test de Breush-Pagan consiste à tester l'hypothèse $H_0 : \sigma_u^2 = 0$

Le test de Breush-Pagan consiste à tester l'hypothèse $H_0 : \sigma_u^2 = 0$

Considérons le modèle between :

$$\bar{Y}_i = \alpha + \beta_1 \bar{X}_{1i} + \beta_2 \bar{X}_{2i} + \cdots + \beta_k \bar{X}_{ki} + \bar{\omega}_i \text{ pour } i = 1, 2, \dots, n$$

où $\bar{\omega}_i = \bar{\epsilon}_i + u_i$

Le test de Breush-Pagan consiste à tester l'hypothèse $H_0 : \sigma_u^2 = 0$

Considérons le modèle between :

$$\bar{Y}_i = \alpha + \beta_1 \bar{X}_{1i} + \beta_2 \bar{X}_{2i} + \cdots + \beta_k \bar{X}_{ki} + \bar{\omega}_i \text{ pour } i = 1, 2, \dots, n$$

où $\bar{\omega}_i = \bar{\epsilon}_i + u_i$

- $E(\bar{\omega}_i) = 0 \forall i$

Le test de Breush-Pagan consiste à tester l'hypothèse $H_0 : \sigma_u^2 = 0$

Considérons le modèle between :

$$\bar{Y}_i = \alpha + \beta_1 \bar{X}_{1i} + \beta_2 \bar{X}_{2i} + \cdots + \beta_k \bar{X}_{ki} + \bar{\omega}_i \text{ pour } i = 1, 2, \dots, n$$

où $\bar{\omega}_i = \bar{\epsilon}_i + u_i$

- $E(\bar{\omega}_i) = 0 \forall i$
- $V(\bar{\omega}_i) = \sigma_b^2 = \frac{\sigma_\epsilon^2}{T} + \sigma_u^2, \forall i$

Le test de Breush-Pagan consiste à tester l'hypothèse $H_0 : \sigma_u^2 = 0$

Considérons le modèle between :

$$\bar{Y}_i = \alpha + \beta_1 \bar{X}_{1i} + \beta_2 \bar{X}_{2i} + \cdots + \beta_k \bar{X}_{ki} + \bar{\omega}_i \text{ pour } i = 1, 2, \dots, n$$

où $\bar{\omega}_i = \bar{\epsilon}_i + u_i$

- $E(\bar{\omega}_i) = 0 \forall i$
- $V(\bar{\omega}_i) = \sigma_b^2 = \frac{\sigma_\epsilon^2}{T} + \sigma_u^2, \forall i$
- $E(\bar{\omega}_i \bar{\omega}_j) = 0 \forall i \neq j$

Le test de Breush-Pagan consiste à tester l'hypothèse $H_0 : \sigma_u^2 = 0$

Considérons le modèle between :

$$\bar{Y}_i = \alpha + \beta_1 \bar{X}_{1i} + \beta_2 \bar{X}_{2i} + \cdots + \beta_k \bar{X}_{ki} + \bar{\omega}_i \text{ pour } i = 1, 2, \dots, n$$

où $\bar{\omega}_i = \bar{\epsilon}_i + u_i$

- $E(\bar{\omega}_i) = 0 \forall i$
- $V(\bar{\omega}_i) = \sigma_b^2 = \frac{\sigma_\epsilon^2}{T} + \sigma_u^2, \forall i$
- $E(\bar{\omega}_i \bar{\omega}_j) = 0 \forall i \neq j$

Un estimateur sans biais de σ_b^2 est défini par :

$$\hat{\sigma}_b^2 = \frac{SCR_b}{n - (k + 1)} = \frac{\sum_{i=1}^n \hat{\bar{\omega}}_i^2}{n - (k + 1)}$$

Le test de Breush-Pagan consiste à tester l'hypothèse $H_0 : \sigma_u^2 = 0$

Considérons le modèle between :

$$\bar{Y}_i = \alpha + \beta_1 \bar{X}_{1i} + \beta_2 \bar{X}_{2i} + \cdots + \beta_k \bar{X}_{ki} + \bar{\omega}_i \text{ pour } i = 1, 2, \dots, n$$

où $\bar{\omega}_i = \bar{\epsilon}_i + u_i$

- $E(\bar{\omega}_i) = 0 \forall i$
- $V(\bar{\omega}_i) = \sigma_b^2 = \frac{\sigma_\epsilon^2}{T} + \sigma_u^2, \forall i$
- $E(\bar{\omega}_i \bar{\omega}_j) = 0 \forall i \neq j$

Un estimateur sans biais de σ_b^2 est défini par :

$$\hat{\sigma}_b^2 = \frac{SCR_b}{n - (k + 1)} = \frac{\sum_{i=1}^n \hat{\bar{\omega}}_i^2}{n - (k + 1)}$$

Et sous l'hypothèse de la normalité de ϵ_i et u_i :

$$\frac{SCR_b}{\sigma_b^2} \rightsquigarrow \chi^2(n - (k + 1))$$

On sait aussi que :

$$\frac{SCR_w}{\sigma_\varepsilon^2} \rightsquigarrow \chi^2(nT - (n + k))$$

On sait aussi que :

$$\frac{SCR_w}{\sigma_\varepsilon^2} \rightsquigarrow \chi^2(nT - (n + k))$$

Ainsi :

$$F = \frac{\frac{SCR_b}{\sigma_b^2} / n - (k + 1)}{\frac{SCR_w}{\sigma_\varepsilon^2} / nT - (n + k)}$$

On sait aussi que :

$$\frac{SCR_w}{\sigma_\varepsilon^2} \rightsquigarrow \chi^2(nT - (n + k))$$

Ainsi :

$$\begin{aligned} F &= \frac{\frac{SCR_b}{\sigma_b^2} / n - (k + 1)}{\frac{SCR_w}{\sigma_\varepsilon^2} / nT - (n + k)} \\ &= \frac{SCR_b}{SCR_w} \times \frac{\sigma_\varepsilon^2}{\sigma_b^2} \times \frac{nT - (n + k)}{n - (k + 1)} \rightsquigarrow F(n - (k + 1), nT - (n + k)) \end{aligned}$$

On sait aussi que :

$$\frac{SCR_w}{\sigma_\varepsilon^2} \rightsquigarrow \chi^2(nT - (n + k))$$

Ainsi :

$$\begin{aligned} F &= \frac{\frac{SCR_b}{\sigma_b^2} / n - (k + 1)}{\frac{SCR_w}{\sigma_\varepsilon^2} / nT - (n + k)} \\ &= \frac{SCR_b}{SCR_w} \times \frac{\sigma_\varepsilon^2}{\sigma_b^2} \times \frac{nT - (n + k)}{n - (k + 1)} \rightsquigarrow F(n - (k + 1), nT - (n + k)) \end{aligned}$$

Or Sous l'hypothèse H_0 , $\sigma_b^2 = \frac{\sigma_\varepsilon^2}{T}$. Ce qui permet d'écrire la statistique du test sous la forme :

$$F = T \frac{SCR_b}{SCR_w} \times \frac{nT - (n + k)}{n - (k + 1)} = T \frac{\hat{\sigma}_b^2}{\hat{\sigma}_\varepsilon^2} \rightsquigarrow F(n - (k + 1), nT - (n + k))$$

Observation : Si on accepte H_0 , le modèle est à effet fixe.

Exercice 1)

Un modèle à effet individuel reliant la demande d'un bien (D), à son prix (P) et le revenu du consommateur (R) est représenté comme suit :

$$\log(D_{it}) = \alpha_i + \beta_1 \log(P_{it}) + \beta_2 \log(R_{it}) + \varepsilon_{it}, i = 1, \dots, 18 \text{ et } t = 1, \dots, 19$$

Avec $E(\varepsilon_{it}) = 0 \forall i, t$, $E(\varepsilon_{it}^2) = \sigma_\varepsilon^2 \forall i, t$, $E(\varepsilon_{it}\varepsilon_{js}) = 0 \forall i \neq j \text{ ou } s \neq t$,
 $\text{cov}(R_{it}, \varepsilon_{js}) = 0 \forall i, j, t, s$. et $\text{cov}(P_{it}, \varepsilon_{js}) = 0 \forall i, j, t, s$.

1. L'estimation de ce modèle à donné les résultats suivants :

$$\hat{\beta}_w = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} -0.8277 \\ 0.2573 \end{pmatrix}, \hat{V}(\hat{\beta}_w) = \begin{pmatrix} 0.00151 & 0.00121 \\ 0.00121 & 0.00473 \end{pmatrix}$$

$$\text{et } SCR_w = 2022$$

- i Commenter les valeurs des estimateurs des paramètres des variables explicatives
- ii Tester l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.
- iii Donner une estimation sans biais de la variance des erreurs.

2 On considère à présent un modèle à effet aléatoire :

$$\log(D_{it}) = \alpha + \beta_1 \log(R_{it}) + \beta_2 \log(P_{it}) + w_{it}, i = 1, \dots, N \text{ et } t = 1, \dots, T$$

avec $w_{it} = u_i + \varepsilon_{it}$ et $E(u_i) = 0$, $E(u_i^2) = \sigma_u^2 \forall i$, $E(u_i u_j) = 0 \forall i \neq j$,

$E(\varepsilon_{it} u_j) = E(\varepsilon_{it} \varepsilon_{jt}) = 0 \forall i, j, t$. L'estimation de ce modèle a conduit aux résultats suivants :

$$\hat{\beta}_{mcg} = \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} -0.7895 \\ 0.17634 \end{pmatrix}, \text{ et } \hat{V}(\hat{\beta}_{mcg}) = \begin{pmatrix} 0.00144 & 0.0011 \\ 0.0011 & 0.00417 \end{pmatrix}$$

- i Tester l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.
- ii Tester, de deux façons différentes et au seuil de 5%, le modèle à effet fixe contre le modèle à effet aléatoire (préciser l'hypothèse, la statistique du test ainsi que sa distribution) sachant que la somme des carrés des résidus du modèle between est égale à 5.2

Solution

1. i Faisons remarquer que :

$$\beta_1 = \frac{\partial \log(D)}{\partial \log(P)} \text{ et } \beta_2 = \frac{\partial \log(D)}{\partial \log(R)}$$

Solution

1. i Faisons remarquer que :

$$\beta_1 = \frac{\partial \log(D)}{\partial \log(P)} \text{ et } \beta_2 = \frac{\partial \log(D)}{\partial \log(R)}$$

β_1 et β_2 représentent respectivement les élasticités prix et revenu (de la demande).

Solution

1. i Faisons remarquer que :

$$\beta_1 = \frac{\partial \log(D)}{\partial \log(P)} \text{ et } \beta_2 = \frac{\partial \log(D)}{\partial \log(R)}$$

β_1 et β_2 représentent respectivement les élasticités prix et revenu (de la demande). Ainsi, on estime que :

- Si le prix augmente de 1%, la demande diminue de 0.83%
- Si le revenu augmente de 1%, la demande augmente de 0.25%

Solution

1. i Faisons remarquer que :

$$\beta_1 = \frac{\partial \log(D)}{\partial \log(P)} \text{ et } \beta_2 = \frac{\partial \log(D)}{\partial \log(R)}$$

β_1 et β_2 représentent respectivement les élasticités prix et revenu (de la demande). Ainsi, on estime que :

- Si le prix augmente de 1%, la demande diminue de 0.83%
- Si le revenu augmente de 1%, la demande augmente de 0.25%

- ii Test de l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\hat{V}(\hat{\beta}_1) + \hat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-18-2 = 322)$$

Solution

1. i Faisons remarquer que :

$$\beta_1 = \frac{\partial \log(D)}{\partial \log(P)} \text{ et } \beta_2 = \frac{\partial \log(D)}{\partial \log(R)}$$

β_1 et β_2 représentent respectivement les élasticités prix et revenu (de la demande). Ainsi, on estime que :

- Si le prix augmente de 1%, la demande diminue de 0.83%
- Si le revenu augmente de 1%, la demande augmente de 0.25%

- ii Test de l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\hat{V}(\hat{\beta}_1) + \hat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-18-2 = 322) \approx N(0, 1)$$

Solution

1. i Faisons remarquer que :

$$\beta_1 = \frac{\partial \log(D)}{\partial \log(P)} \text{ et } \beta_2 = \frac{\partial \log(D)}{\partial \log(R)}$$

β_1 et β_2 représentent respectivement les élasticités prix et revenu (de la demande). Ainsi, on estime que :

- Si le prix augmente de 1%, la demande diminue de 0.83%
- Si le revenu augmente de 1%, la demande augmente de 0.25%

- ii Test de l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\hat{V}(\hat{\beta}_1) + \hat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-18-2 = 322) \approx N(0, 1)$$

Application numérique :

$$\hat{t} = \frac{-0.8277 + 0.2573 + 0.5}{\sqrt{0.00151 + 0.00473 + 2 * 0.00121}} = -0.75651$$

$$|\hat{t}| < 1.96 \text{ on accepte } H_0$$

Solution

1. i Faisons remarquer que :

$$\beta_1 = \frac{\partial \log(D)}{\partial \log(P)} \text{ et } \beta_2 = \frac{\partial \log(D)}{\partial \log(R)}$$

β_1 et β_2 représentent respectivement les élasticités prix et revenu (de la demande). Ainsi, on estime que :

- Si le prix augmente de 1%, la demande diminue de 0.83%
- Si le revenu augmente de 1%, la demande augmente de 0.25%

- ii Test de l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\hat{V}(\hat{\beta}_1) + \hat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-18-2 = 322) \approx N(0, 1)$$

Application numérique :

$$\hat{t} = \frac{-0.8277 + 0.2573 + 0.5}{\sqrt{0.00151 + 0.00473 + 2 * 0.00121}} = -0.75651$$

$|\hat{t}| < 1.96$ on accepte H_0

- iii Estimation sans biais de la variance des erreurs.

2. i Tester l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\hat{V}(\hat{\beta}_1) + \hat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-1-2 = 339)$$

2. i Tester l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\hat{V}(\hat{\beta}_1) + \hat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-1-2 = 339) \approx N(0, 1)$$

2. i Tester l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\widehat{V}(\hat{\beta}_1) + \widehat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-1-2 = 339) \approx N(0, 1)$$

$$\hat{t} = \frac{-0.7895 + 0.17634 + 0.5}{\sqrt{0.00144 + 0.00417 + 2 * 0.0011}} = -1.28$$

On accepte H_0

2. i Tester l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\hat{V}(\hat{\beta}_1) + \hat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-1-2 = 339) \approx N(0, 1)$$

$$\hat{t} = \frac{-0.7895 + 0.17634 + 0.5}{\sqrt{0.00144 + 0.00417 + 2 * 0.0011}} = -1.28$$

On accepte H_0

- ii a. Test de Hausman : $H_0 : \hat{\beta}_W = \hat{\beta}_{mcs}$.

2. i Tester l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\hat{V}(\hat{\beta}_1) + \hat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-1-2 = 339) \approx N(0, 1)$$

$$\hat{t} = \frac{-0.7895 + 0.17634 + 0.5}{\sqrt{0.00144 + 0.00417 + 2 * 0.0011}} = -1.28$$

On accepte H_0

- ii a. Test de Hausman : $H_0 : \hat{\beta}_W = \hat{\beta}_{mcs}$. La statistique du test est définie par :

$$H = \left(\hat{\beta}_W - \hat{\beta}_{mcs} \right)' \left\{ V(\hat{\beta}_W) - V(\hat{\beta}_{mcs}) \right\}^{-1} \left(\hat{\beta}_W - \hat{\beta}_{mcs} \right) \rightsquigarrow \chi^2(2)$$

2. i Tester l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\hat{V}(\hat{\beta}_1) + \hat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-1-2 = 339) \approx N(0, 1)$$

$$\hat{t} = \frac{-0.7895 + 0.17634 + 0.5}{\sqrt{0.00144 + 0.00417 + 2 * 0.0011}} = -1.28$$

On accepte H_0

- ii a. Test de Hausman : $H_0 : \hat{\beta}_W = \hat{\beta}_{mcs}$. La statistique du test est définie par :

$$H = \left(\hat{\beta}_W - \hat{\beta}_{mcs} \right)' \left\{ V(\hat{\beta}_W) - V(\hat{\beta}_{mcs}) \right\}^{-1} \left(\hat{\beta}_W - \hat{\beta}_{mcs} \right) \rightsquigarrow \chi^2(2)$$

Application numérique :

$$W = \begin{pmatrix} -0.0382 \\ 0.0810 \end{pmatrix}' \left\{ \begin{pmatrix} 0.00007 & 0.00011 \\ 0.00011 & 0.00056 \end{pmatrix} \right\}^{-1} \begin{pmatrix} -0.0382 \\ 0.0810 \end{pmatrix} = 167.516$$

2. i Tester l'hypothèse $H_0 : \beta_1 + \beta_2 = -0.5$ au seuil de 5%.

$$\hat{t} = \frac{\hat{\beta}_1 + \hat{\beta}_2 + 0.5}{\sqrt{\widehat{V}(\hat{\beta}_1) + \widehat{V}(\hat{\beta}_2) + 2\widehat{Cov}(\hat{\beta}_1, \hat{\beta}_2)}} \rightsquigarrow St(18*19-1-2 = 339) \approx N(0, 1)$$

$$\hat{t} = \frac{-0.7895 + 0.17634 + 0.5}{\sqrt{0.00144 + 0.00417 + 2 * 0.0011}} = -1.28$$

On accepte H_0

- ii a. Test de Hausman : $H_0 : \hat{\beta}_W = \hat{\beta}_{mcs}$. La statistique du test est définie par :

$$H = \left(\hat{\beta}_W - \hat{\beta}_{mcs} \right)' \left\{ V(\hat{\beta}_W) - V(\hat{\beta}_{mcs}) \right\}^{-1} \left(\hat{\beta}_W - \hat{\beta}_{mcs} \right) \rightsquigarrow \chi^2(2)$$

Application numérique :

$$W = \begin{pmatrix} -0.0382 \\ 0.0810 \end{pmatrix}' \left\{ \begin{pmatrix} 0.00007 & 0.00011 \\ 0.00011 & 0.00056 \end{pmatrix} \right\}^{-1} \begin{pmatrix} -0.0382 \\ 0.0810 \end{pmatrix} = 167.516$$

$W \gg 5.99$ ($\chi^2(2)^{5\%}$) On rejette H_0 , Le modèle est à effet fixe.

2. ii b Test de Breush-Pagan : test $H_0 : \sigma_u^2 = 0$.

2. ii b Test de Breush-Pagan : test $H_0 : \sigma_u^2 = 0$. La statistique du test est définie par :

$$F = \frac{T * \hat{\sigma}_b^2}{\hat{\sigma}_w^2}$$

2. ii b Test de Breush-Pagan : test $H_0 : \sigma_u^2 = 0$. La statistique du test est définie par :

$$F = \frac{T * \hat{\sigma}_b^2}{\hat{\sigma}_W^2} = T \frac{\frac{SCR_b}{N-(k+1)}}{\frac{SCR_W}{NT-(N+K)}}$$

2. ii b Test de Breush-Pagan : test $H_0 : \sigma_u^2 = 0$. La statistique du test est définie par :

$$F = \frac{T * \hat{\sigma}_b^2}{\hat{\sigma}_W^2} = T \frac{\frac{SCR_b}{N-(k+1)}}{\frac{SCR_W}{NT-(N+K)}} \rightsquigarrow F(N - (k + 1), NT - (N + K))$$

2. ii b Test de Breush-Pagan : test $H_0 : \sigma_u^2 = 0$. La statistique du test est définie par :

$$F = \frac{T * \hat{\sigma}_b^2}{\hat{\sigma}_W^2} = T \frac{\frac{SCR_b}{N-(k+1)}}{\frac{SCR_W}{NT-(N+K)}} \rightsquigarrow F(N - (k + 1), NT - (N + K))$$

Application numérique :

$$F = 19 * \frac{5.2}{2022} \frac{322}{15} = 1.05 < F^{5\%}(15, 322) = 1.698$$

2. ii b Test de Breush-Pagan : test $H_0 : \sigma_u^2 = 0$. La statistique du test est définie par :

$$F = \frac{T * \hat{\sigma}_b^2}{\hat{\sigma}_W^2} = T \frac{\frac{SCR_b}{N-(k+1)}}{\frac{SCR_W}{NT-(N+K)}} \rightsquigarrow F(N - (k + 1), NT - (N + K))$$

Application numérique :

$$F = 19 * \frac{5.2}{2022} \frac{322}{15} = 1.05 < F^{5\%}(15, 322) = 1.698$$

On accepte H_0 , Le modèle est à effet fixe.

On considère le cas particulier d'une frontière de production, avec :

$$\omega_{it} = \varepsilon_{it} - u_i$$

où $\varepsilon_{it} \rightsquigarrow N(0, \sigma_\varepsilon^2)$ et u_i suit la loi normale centrée et de variance σ_u^2 tronquée à zéro.

On considère le cas particulier d'une frontière de production, avec :

$$\omega_{it} = \varepsilon_{it} - u_i$$

où $\varepsilon_{it} \rightsquigarrow N(0, \sigma_\varepsilon^2)$ et u_i suit la loi normale centrée et de variance σ_u^2 tronquée à zéro. u_i renseigne sur la distance (**à priori**) par rapport à la frontière de production.

On considère le cas particulier d'une frontière de production, avec :

$$\omega_{it} = \varepsilon_{it} - u_i$$

où $\varepsilon_{it} \rightsquigarrow N(0, \sigma_\varepsilon^2)$ et u_i suit la loi normale centrée et de variance σ_u^2 tronquée à zéro. u_i renseigne sur la distance (**à priori**) par rapport à la frontière de production.

Notons que pour u_i donnée, $\varepsilon_{it} = \omega_{it} + u_i$ et la distribution à postériori de u_i sachant $\omega_{it} = 1, 2, \dots, T$ est obtenue par :

On considère le cas particulier d'une frontière de production, avec :

$$\omega_{it} = \varepsilon_{it} - u_i$$

où $\varepsilon_{it} \rightsquigarrow N(0, \sigma_\varepsilon^2)$ et u_i suit la loi normale centrée et de variance σ_u^2 tronquée à zéro. u_i renseigne sur la distance (**à priori**) par rapport à la frontière de production.

Notons que pour u_i donnée, $\varepsilon_{it} = \omega_{it} + u_i$ et la distribution à postériori de u_i sachant $\omega_{it} = 1, 2, \dots, T$ est obtenue par :

$$f(u_i / \omega_{it} = 1, 2, \dots, T) \propto f_u(u_i) \prod_{t=1}^T f_\varepsilon(\omega_{it} + u_i)$$

On considère le cas particulier d'une frontière de production, avec :

$$\omega_{it} = \varepsilon_{it} - u_i$$

où $\varepsilon_{it} \rightsquigarrow N(0, \sigma_\varepsilon^2)$ et u_i suit la loi normale centrée et de variance σ_u^2 tronquée à zéro. u_i renseigne sur la distance (**à priori**) par rapport à la frontière de production.

Notons que pour u_i donnée, $\varepsilon_{it} = \omega_{it} + u_i$ et la distribution à postériori de u_i sachant $\omega_{it} = 1, 2, \dots, T$ est obtenue par :

$$\begin{aligned} f(u_i / \omega_{it} = 1, 2, \dots, T) &\propto f_u(u_i) \prod_{t=1}^T f_\varepsilon(\omega_{it} + u_i) \\ &\propto \frac{1}{\sqrt{2\pi}\sigma_u} \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \prod_{t=1}^T \frac{1}{\sqrt{2\pi}\sigma_\varepsilon} \exp\left(-\frac{1}{2\sigma_\varepsilon^2} (\omega_{it} + u_i)^2\right) \end{aligned}$$

On considère le cas particulier d'une frontière de production, avec :

$$\omega_{it} = \varepsilon_{it} - u_i$$

où $\varepsilon_{it} \rightsquigarrow N(0, \sigma_\varepsilon^2)$ et u_i suit la loi normale centrée et de variance σ_u^2 tronquée à zéro. u_i renseigne sur la distance (**à priori**) par rapport à la frontière de production.

Notons que pour u_i donnée, $\varepsilon_{it} = \omega_{it} + u_i$ et la distribution à postériori de u_i sachant $\omega_{it} = 1, 2, \dots, T$ est obtenue par :

$$\begin{aligned} f(u_i / \omega_{it} = 1, 2, \dots, T) &\propto f_u(u_i) \prod_{t=1}^T f_\varepsilon(\omega_{it} + u_i) \\ &\propto \frac{1}{\sqrt{2\pi}\sigma_u} \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \prod_{t=1}^T \frac{1}{\sqrt{2\pi}\sigma_\varepsilon} \exp\left(-\frac{1}{2\sigma_\varepsilon^2} (\omega_{it} + u_i)^2\right) \\ &\propto \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \exp\left(-\frac{1}{2\sigma_\varepsilon^2} \sum_{t=1}^T (\omega_{it} + u_i)^2\right) \end{aligned}$$

On considère le cas particulier d'une frontière de production, avec :

$$\omega_{it} = \varepsilon_{it} - u_i$$

où $\varepsilon_{it} \rightsquigarrow N(0, \sigma_\varepsilon^2)$ et u_i suit la loi normale centrée et de variance σ_u^2 tronquée à zéro. u_i renseigne sur la distance (**à priori**) par rapport à la frontière de production.

Notons que pour u_i donnée, $\varepsilon_{it} = \omega_{it} + u_i$ et la distribution à postériori de u_i sachant $\omega_{it} = 1, 2, \dots, T$ est obtenue par :

$$\begin{aligned} f(u_i / \omega_{it} = 1, 2, \dots, T) &\propto f_u(u_i) \prod_{t=1}^T f_\varepsilon(\omega_{it} + u_i) \\ &\propto \frac{1}{\sqrt{2\pi}\sigma_u} \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \prod_{t=1}^T \frac{1}{\sqrt{2\pi}\sigma_\varepsilon} \exp\left(-\frac{1}{2\sigma_\varepsilon^2} (\omega_{it} + u_i)^2\right) \\ &\propto \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \exp\left(-\frac{1}{2\sigma_\varepsilon^2} \sum_{t=1}^T (\omega_{it} + u_i)^2\right) \end{aligned}$$

$$\propto \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \exp\left(-\frac{1}{2\sigma_\varepsilon^2} [Tu_i^2 + 2T\bar{\omega}_i]\right)$$

$$\begin{aligned} &\propto \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \exp\left(-\frac{1}{2\sigma_\varepsilon^2} [Tu_i^2 + 2T\bar{\omega}_i]\right) \\ &\propto \exp\left(-\frac{1}{2} \left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right) \left\{ u_i^2 + 2\frac{T\bar{\omega}_i}{\sigma_\varepsilon^2} \frac{1}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)} \right\}\right) \end{aligned}$$

$$\begin{aligned}
&\propto \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \exp\left(-\frac{1}{2\sigma_\varepsilon^2} [Tu_i^2 + 2T\bar{\omega}_i]\right) \\
&\propto \exp\left(-\frac{1}{2} \left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right) \left\{ u_i^2 + 2\frac{T\bar{\omega}_i}{\sigma_\varepsilon^2} \frac{1}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)} \right\}\right)
\end{aligned}$$

On pose :

$$\sigma^2 = \frac{1}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)} \quad \text{et} \quad \lambda = \frac{\frac{T}{\sigma_\varepsilon^2}}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)}$$

$$\begin{aligned}
&\propto \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \exp\left(-\frac{1}{2\sigma_\varepsilon^2} [Tu_i^2 + 2T\bar{\omega}_i]\right) \\
&\propto \exp\left(-\frac{1}{2} \left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right) \left\{ u_i^2 + 2\frac{T\bar{\omega}_i}{\sigma_\varepsilon^2} \frac{1}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)} \right\}\right)
\end{aligned}$$

On pose :

$$\sigma^2 = \frac{1}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)} \text{ et } \lambda = \frac{\frac{T}{\sigma_\varepsilon^2}}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)}$$

$$f(u_i / \omega_{it} = 1, 2, \dots, T) \propto \exp\left(-\frac{1}{2\sigma^2} (u_i^2 + 2\lambda\bar{\omega}_i)\right) \propto \exp\left(-\frac{1}{2\sigma^2} (u_i + \lambda\bar{\omega}_i)^2\right)$$

$$\propto \exp\left(-\frac{1}{2\sigma_u^2} u_i^2\right) \exp\left(-\frac{1}{2\sigma_\varepsilon^2} [Tu_i^2 + 2T\bar{\omega}_i]\right)$$

$$\propto \exp\left(-\frac{1}{2} \left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right) \left\{ u_i^2 + 2\frac{T\bar{\omega}_i}{\sigma_\varepsilon^2} \frac{1}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)} \right\}\right)$$

On pose :

$$\sigma^2 = \frac{1}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)} \text{ et } \lambda = \frac{\frac{T}{\sigma_\varepsilon^2}}{\left(\frac{1}{\sigma_u^2} + \frac{T}{\sigma_\varepsilon^2}\right)}$$

$$f(u_i/\omega_{it} = 1, 2, \dots, T) \propto \exp\left(-\frac{1}{2\sigma^2} (u_i^2 + 2\lambda\bar{\omega}_i)\right) \propto \exp\left(-\frac{1}{2\sigma^2} (u_i + \lambda\bar{\omega}_i)^2\right)$$

Il s'agit de la distribution d'une loi normale d'espérance mathématique $-\lambda\bar{\omega}_i$ et de variance σ^2 , tronquée à zéro de densité :

$$f(u_i/\omega_{it} = 1, 2, \dots, T) = \frac{1}{\sqrt{2\pi}\sigma} \frac{1}{\Phi\left(-\frac{\lambda\bar{\omega}_i}{\sigma}\right)} \exp\left(-\frac{1}{2\sigma^2} (u_i + \lambda\bar{\omega}_i)^2\right)$$

Exercice 2

- ① Soit $\varepsilon \rightsquigarrow N(m, \sigma^2)$. Et considérons la variable normale tronquée à zéro définie par $u = \varepsilon/\varepsilon > 0$.
 - a. Donner la densité de u
 - b. Calculer $E(e^{au})$ en fonction de m , σ et a .
- ② Reprenez le modèle de données de panel avec frontière de production ; calculer $E(\exp(a * u_i)/\omega_{it} = 1, 2, \dots, T)$
- ③ On considère l'indicateur d'efficacité d'une entreprise $TE_i = \exp(-u_i)$ donner un estimateur de TE_i , noté \widehat{TE}_i .
- ④ Calculer la valeur de \widehat{TE} , sachant que $T = 15$, $\widehat{\omega}_i = 0.5$, $\widehat{\sigma}_\varepsilon^2 = 2$, et $\widehat{\sigma}_u^2 = 0.75$

❶ Soit $\varepsilon \rightsquigarrow N(m, \sigma^2)$. Et considérons la variable normale tronquée à zéro définie par $u = \varepsilon/\varepsilon > 0$.

$$f(u) = \frac{f_\varepsilon(u)}{P(\varepsilon > 0)}$$

Corrigé

- ① Soit $\varepsilon \rightsquigarrow N(m, \sigma^2)$. Et considérons la variable normale tronquée à zéro définie par $u = \varepsilon / \varepsilon > 0$.

a. La densité de u est définie par

$$\begin{aligned} f(u) &= \frac{f_{\varepsilon}(u)}{P(\varepsilon > 0)} \\ &= \frac{1}{\Phi(\frac{m}{\sigma})} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(u - m)^2\right) \text{ pour } u > 0 \end{aligned}$$

b. Calculer $E(e^{au})$ en fonction de m , σ et a .

$$E(e^{au}) = \int_0^\infty e^{au} f(u) du$$

b. Calculer $E(e^{au})$ en fonction de m , σ et a .

$$E(e^{au}) = \int_0^\infty e^{au} f(u) du = \frac{1}{\Phi\left(\frac{m}{\sigma}\right)} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{au} e^{-\frac{1}{2\sigma^2}(u-m)^2} du$$

b. Calculer $E(e^{au})$ en fonction de m , σ et a .

$$\begin{aligned} E(e^{au}) &= \int_0^\infty e^{au} f(u) du = \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{au} e^{-\frac{1}{2\sigma^2}(u-m)^2} du \\ &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u-m)^2 - 2\sigma^2 au]} du \end{aligned}$$

b. Calculer $E(e^{au})$ en fonction de m , σ et a .

$$\begin{aligned} E(e^{au}) &= \int_0^{\infty} e^{au} f(u) du = \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{au} e^{-\frac{1}{2\sigma^2}(u-m)^2} du \\ &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u-m)^2 - 2\sigma^2 au]} du \\ &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[u^2 - 2mu + m^2 - 2\sigma^2 au]} du \end{aligned}$$

b. Calculer $E(e^{au})$ en fonction de m , σ et a .

$$\begin{aligned} E(e^{au}) &= \int_0^{\infty} e^{au} f(u) du = \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{au} e^{-\frac{1}{2\sigma^2}(u-m)^2} du \\ &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u-m)^2 - 2\sigma^2 au]} du \\ &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[u^2 - 2mu + m^2 - 2\sigma^2 au]} du \\ &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[u^2 - 2u(m + \sigma^2 a) + m^2]} du \end{aligned}$$

b. Calculer $E(e^{au})$ en fonction de m , σ et a .

$$\begin{aligned}
 E(e^{au}) &= \int_0^\infty e^{au} f(u) du = \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{au} e^{-\frac{1}{2\sigma^2}(u-m)^2} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u-m)^2 - 2\sigma^2 au]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[u^2 - 2mu + m^2 - 2\sigma^2 au]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[u^2 - 2u(m + \sigma^2 a) + m^2]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u - (m + \sigma^2 a))^2 + m^2 - (m + \sigma^2 a)^2]} du
 \end{aligned}$$

b. Calculer $E(e^{au})$ en fonction de m , σ et a .

$$\begin{aligned}
 E(e^{au}) &= \int_0^\infty e^{au} f(u) du = \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{au} e^{-\frac{1}{2\sigma^2}(u-m)^2} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u-m)^2 - 2\sigma^2 au]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[u^2 - 2mu + m^2 - 2\sigma^2 au]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[u^2 - 2u(m + \sigma^2 a) + m^2]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u - (m + \sigma^2 a))^2 + m^2 - (m + \sigma^2 a)^2]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} e^{am + \frac{\sigma^2 a^2}{2}} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u - (m + \sigma^2 a))^2]} du
 \end{aligned}$$

b. Calculer $E(e^{au})$ en fonction de m , σ et a .

$$\begin{aligned}
 E(e^{au}) &= \int_0^\infty e^{au} f(u) du = \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{au} e^{-\frac{1}{2\sigma^2}(u-m)^2} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u-m)^2 - 2\sigma^2 au]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[u^2 - 2mu + m^2 - 2\sigma^2 au]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[u^2 - 2u(m + \sigma^2 a) + m^2]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u - (m + \sigma^2 a))^2 + m^2 - (m + \sigma^2 a)^2]} du \\
 &= \frac{1}{\Phi(\frac{m}{\sigma})} e^{am + \frac{\sigma^2 a^2}{2}} \int_0^\infty \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}[(u - (m + \sigma^2 a))^2]} du \\
 &= \frac{\Phi(\frac{m}{\sigma} + \sigma a)}{\Phi(\frac{m}{\sigma})} e^{am + \frac{1}{2}\sigma^2 a^2}
 \end{aligned}$$

- 2 Reprenez le modèle de données de panel avec frontière de production ; calculer $E(\exp(a * u_i) / \omega_{it} = 1, 2, \dots, T)$. On sait que :

$$f(u_i / \omega_{it} = 1, 2, \dots, T) = \frac{1}{\sqrt{2\pi}\sigma} \frac{1}{\Phi\left(-\frac{\lambda\bar{\omega}_i}{\sigma}\right)} \exp\left(-\frac{1}{2\sigma^2} (u_i + \lambda\bar{\omega}_i)^2\right)$$

Ainsi

$$E(\exp(a * u_i) / \omega_{it} = 1, 2, \dots, T) = \frac{\Phi\left(\frac{-\lambda\bar{\omega}_i}{\sigma} + \sigma a\right)}{\Phi\left(-\frac{\lambda\bar{\omega}_i}{\sigma}\right)} e^{-a\lambda\bar{\omega}_i + \frac{1}{2}\sigma^2 a^2}$$

- 3 On considère l'indicateur d'efficacité d'une entreprise $TE_i = \exp(-u_i)$ donner un estimateur de TE_i , noté \widehat{TE}_i .

$$\widehat{TE}_i = \frac{\Phi\left(\frac{-\widehat{\lambda}\widehat{\omega}_i}{\widehat{\sigma}} - \widehat{\sigma}\right)}{\Phi\left(-\frac{\widehat{\lambda}\widehat{\omega}_i}{\widehat{\sigma}}\right)} e^{\widehat{\lambda}\widehat{\omega}_i + \frac{1}{2}\widehat{\sigma}^2}$$

- 4 Calculer la valeur de \widehat{TE} , sachant que $T = 15$, $\widehat{\omega}_i = 0.5$, $\widehat{\sigma}_\varepsilon^2 = 2$, et $\widehat{\sigma}_u^2 = 0.75$

$$\widehat{\sigma}^2 = \frac{1}{\left(\frac{1}{\widehat{\sigma}_u^2} + \frac{T}{\widehat{\sigma}_\varepsilon^2}\right)} = \frac{1}{\frac{1}{0.75} + \frac{15}{2}} = ?$$

$$\widehat{\lambda} = \frac{\frac{T}{\widehat{\sigma}_\varepsilon^2}}{\left(\frac{1}{\widehat{\sigma}_u^2} + \frac{T}{\widehat{\sigma}_\varepsilon^2}\right)} = \frac{15}{2} \frac{1}{\frac{1}{0.75} + \frac{15}{2}} = ?$$

$$\widehat{TE}_i =$$

Extrait de "W. Greene, Econometrics Analysis, 8th edition". On considère pour 500 Banques, l'observation du logarithme des coûts de productions (C), les logarithmes des prix relatifs (W_1 , W_2 , W_3 , W_4 , et les logarithmes des quantités produites pour 5 produits Q_1 , Q_2 , Q_3 , Q_4 et Q_5 . Et on adopte le modèle suivant :

$$C_{it} = \alpha_i + \beta_1 Q_{1it} + \beta_2 Q_{2it} + \beta_3 Q_{3it} + \beta_4 Q_{4it} + \beta_5 Q_{5it} \\ + \theta_1 W_{1it} + \theta_2 W_{2it} + \theta_3 W_{3it} + \theta_4 W_{4it} + \epsilon_{it}, \\ \text{pour } i = 1, 2, \dots, 500 \text{ et } t = 1, 2, 3, 4, 5$$

Les données sont fournies en annexe (Panel exo3.xls). A l'aide de la librairie plm du logiciel R :

- ① Estimer le modèle à effet fixe
- ② Estimer le modèle à effet aléatoire
- ③ Calculer l'indicateur d'économies d'échelle pour les deux modèles précédents. Commenter.
- ④ Tester de deux façons différentes le modèle à effet fixe contre le modèle à effet aléatoire

MERCI POUR VOTRE ATTENTION