

# Économétrie avancée : Introduction aux modèles de durée

Pr. Mokhtar KOUKI

Université de Carthage (ESSAI)  
*mokhtar.kouki@essai.u-carthage.tn*

Décembre 2020



# Contents

- 1 Introduction
- 2 Concepts de base
- 3 distributions usuelles
  - Loi de Weibull
  - Loi lognormale
  - Exemple : Fonction de survie empirique
- 4 Courbe de Survie : Estimateur de Kaplan-Meier
- 5 Comparaison de courbes de survies : test de log-rank
- 6 Modèle à hasard proportionnel : Modèle de Cox

On considère une expérience dans laquelle on observe des patients pour lesquels on administre un traitement et on observe la "**durée jusqu'à ce que un événement survienne**" (décès, guérison, rechute, ...). On parle ainsi de "**temps de survie**".

On considère une expérience dans laquelle on observe des patients pour lesquels on administre un traitement et on observe la **"durée jusqu'à ce que un événement survienne"** (décès, guérison, rechute, ...). On parle ainsi de **"temps de survie"**. Quatre (04) éléments sont à considérer :

- $T$  : le temps de survie (variable aléatoire)
- $t$  : une réalisation de  $T$
- $F$  : la période de suivie (follow-up)
- $\delta$  : un évènement (Oui/Non) (variable aléatoire)

On considère une expérience dans laquelle on observe des patients pour lesquels on administre un traitement et on observe la **"durée jusqu'à ce que un événement survienne"** (décès, guérison, rechute, ...). On parle ainsi de **"temps de survie"**. Quatre (04) éléments sont à considérer :

- $T$  : le temps de survie (variable aléatoire)
- $t$  : une réalisation de  $T$
- $F$  : la période de suivie (follow-up)
- $\delta$  : un événement (Oui/Non) (variable aléatoire)

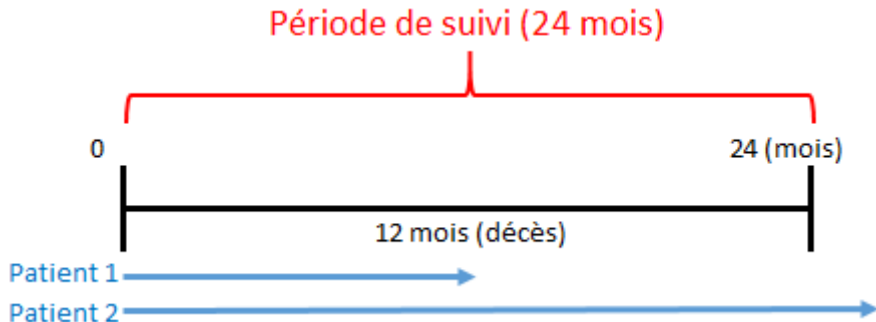
## Exemples :

- Emploi : Délai d'insertion des diplômés
- Téléphonie mobile : Délai avant changement

En observant des durées, 2 configurations sont envisageables :

En observant des durées, 2 configurations sont envisageables :  
Considérons, le suivie de patients sur une période de 24 mois. On observe le temps de survie avant décès :

En observant des durées, 2 configurations sont envisageables :  
Considérons, le suivi de patients sur une période de 24 mois. On observe le temps de survie avant décès :



**Remarque :** Pour le "Patient 2" on observe pas le temps de survie avant décès. On parle ainsi de **censure**.



**"Censure à gauche" et "Censure à droite"** : Considérons l'exemple de suivi d'individus sur **12 mois** et on observe la durée jusqu'à la réalisation d'un événement donné ( $\delta$  1 si oui, 0 sinon) :

$i$	$t_i$	$\delta_i$	
1	7	1	
2	12	0	Censure à droite
3	10	0	
4	7	1	
5	5	0	Censure à gauche

**Censure à gauche : Perte de suivi, Retrait, ...**

## Définition

**Fonction de survie :** La fonction de survie correspond à la probabilité qu'un individu survive au delà d'une date  $t$  :

$$S(t) = P(T \geq t) = 1 - P(T < t) = 1 - F(t),$$

avec  $S(0) = 1$  et  $S(\infty) = 0$

## Définition

**Fonction de survie** : La fonction de survie correspond à la probabilité qu'un individu survive au delà d'une date  $t$  :

$$S(t) = P(T \geq t) = 1 - P(T < t) = 1 - F(t),$$

avec  $S(0) = 1$  et  $S(\infty) = 0$

**Exemple** :  $T \rightsquigarrow \text{Exp}(\lambda)$

$$S(t) = \int_t^{\infty} f(x) dx = 1 - \int_0^t f(x) dx$$

## Définition

**Fonction de survie** : La fonction de survie correspond à la probabilité qu'un individu survive au delà d'une date  $t$  :

$$S(t) = P(T \geq t) = 1 - P(T < t) = 1 - F(t),$$

avec  $S(0) = 1$  et  $S(\infty) = 0$

**Exemple** :  $T \rightsquigarrow \text{Exp}(\lambda)$

$$\begin{aligned} S(t) &= \int_t^{\infty} f(x) dx = 1 - \int_0^t f(x) dx \\ &= 1 - \int_0^t \lambda \exp(-\lambda x) dx \end{aligned}$$

## Définition

**Fonction de survie** : La fonction de survie correspond à la probabilité qu'un individu survive au delà d'une date  $t$  :

$$S(t) = P(T \geq t) = 1 - P(T < t) = 1 - F(t),$$

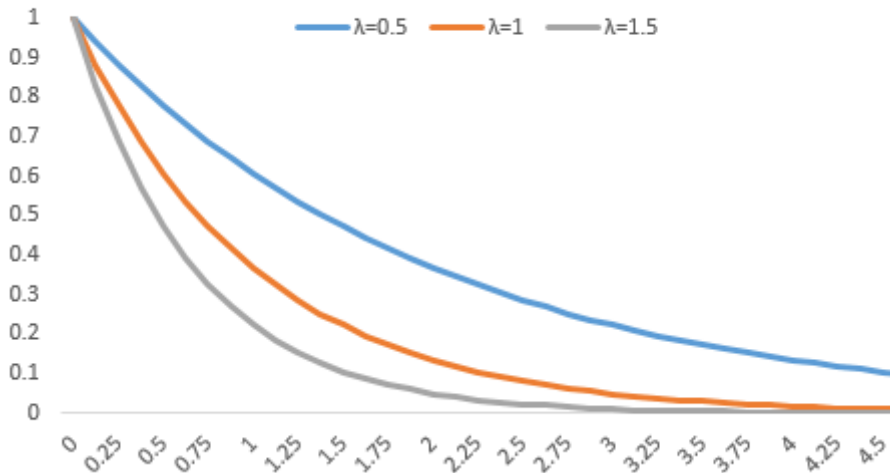
avec  $S(0) = 1$  et  $S(\infty) = 0$

**Exemple** :  $T \rightsquigarrow \text{Exp}(\lambda)$

$$\begin{aligned} S(t) &= \int_t^{\infty} f(x) dx = 1 - \int_0^t f(x) dx \\ &= 1 - \int_0^t \lambda \exp(-\lambda x) dx \\ &= 1 - [-\exp(-\lambda x)]_0^t = \exp(-\lambda t) \end{aligned}$$

## Fonctions de survie exponentielles

Fonction de survie d'une loi exponentielle



## Définition

**Fonction de hasard** : La fonction de hasard correspond au risque, par unité de temps, pour que l'événement survienne sachant que l'individu a survécu jusqu'à la date  $t$  :

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t / T \geq t)}{\Delta t}$$

## Définition

**Fonction de hasard** : La fonction de hasard correspond au risque, par unité de temps, pour que l'événement survienne sachant que l'individu a survécu jusqu'à la date  $t$  :

$$\begin{aligned} h(t) &= \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t / T \geq t)}{\Delta t} \\ &= \frac{1}{P(T \geq t)} \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t)}{\Delta t} \end{aligned}$$



## Définition

**Fonction de hasard** : La fonction de hasard correspond au risque, par unité de temps, pour que l'événement survienne sachant que l'individu a survécu jusqu'à la date  $t$  :

$$\begin{aligned}
 h(t) &= \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t / T \geq t)}{\Delta t} \\
 &= \frac{1}{P(T \geq t)} \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t)}{\Delta t} \\
 &= \frac{f(t)}{P(T \geq t)}
 \end{aligned}$$

## Définition

**Fonction de hasard** : La fonction de hasard correspond au risque, par unité de temps, pour que l'événement survienne sachant que l'individu a survécu jusqu'à la date  $t$  :

$$\begin{aligned}
 h(t) &= \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t / T \geq t)}{\Delta t} \\
 &= \frac{1}{P(T \geq t)} \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t)}{\Delta t} \\
 &= \frac{f(t)}{P(T \geq t)}
 \end{aligned}$$

Observation :  $h(t) \in ]0, +\infty[$

Pour une loi exponentielle de paramètre  $\lambda$  ( $Exp(\lambda)$ ) :

$$h(t) = \frac{f(t)}{S(t)} = \lambda$$

**Exemple : Unité de temps.**

Considérons deux individus ayant la même probabilité

$P(t \leq T < t + \Delta t / T \geq t) = 0.25$  avec  $\Delta t_1 = \Delta t_2 = 12h$ . Pour le premier individu l'unité de temps le jour alors que pour le deuxième individu l'unité de temps la semaine :

$$\Delta t_1 = \frac{1}{2}j \text{ et } \Delta t_2 = \frac{1}{14} \text{ semaine}$$

**Exemple : Unité de temps.**

Considérons deux individus ayant la même probabilité

$P(t \leq T < t + \Delta t / T \geq t) = 0.25$  avec  $\Delta t_1 = \Delta t_2 = 12h$ . Pour le premier individu l'unité de temps le jour alors que pour le deuxième individu l'unité de temps la semaine :

$$\Delta t_1 = \frac{1}{2}j \text{ et } \Delta t_2 = \frac{1}{14} \text{ semaine}$$

$$h_1(t) = \frac{0.25}{\frac{1}{2}} = 0.5/jour$$

**Exemple : Unité de temps.**

Considérons deux individus ayant la même probabilité

$P(t \leq T < t + \Delta t / T \geq t) = 0.25$  avec  $\Delta t_1 = \Delta t_2 = 12h$ . Pour le premier individu l'unité de temps le jour alors que pour le deuxième individu l'unité de temps la semaine :

$$\Delta t_1 = \frac{1}{2}j \text{ et } \Delta t_2 = \frac{1}{14} \text{ semaine}$$

$$h_1(t) = \frac{0.25}{\frac{1}{2}} = 0.5/jour \text{ et } h_2(t) = \frac{0.25}{\frac{1}{14}} = 3.5/semaine$$

**Exemple : Unité de temps.**

Considérons deux individus ayant la même probabilité

$P(t \leq T < t + \Delta t / T \geq t) = 0.25$  avec  $\Delta t_1 = \Delta t_2 = 12h$ . Pour le premier individu l'unité de temps le jour alors que pour le deuxième individu l'unité de temps la semaine :

$$\Delta t_1 = \frac{1}{2}j \text{ et } \Delta t_2 = \frac{1}{14} \text{ semaine}$$

$$h_1(t) = \frac{0.25}{\frac{1}{2}} = 0.5/jour \text{ et } h_2(t) = \frac{0.25}{\frac{1}{14}} = 3.5/semaine$$

## Relation entre fonction de survie et fonction de hasard

$$S(t) = P(T \geq t) = 1 - F(t) \Rightarrow$$

## Relation entre fonction de survie et fonction de hasard

$$S(t) = P(T \geq t) = 1 - F(t) \Rightarrow S'(t) = -f(t)$$



## Relation entre fonction de survie et fonction de hasard

$$S(t) = P(T \geq t) = 1 - F(t) \Rightarrow S'(t) = -f(t)$$

$$h(t) = \frac{f(t)}{S(t)} =$$

## Relation entre fonction de survie et fonction de hasard

$$S(t) = P(T \geq t) = 1 - F(t) \Rightarrow S'(t) = -f(t)$$

$$h(t) = \frac{f(t)}{S(t)} = -\frac{S'(t)}{S(t)} =$$

## Relation entre fonction de survie et fonction de hasard

$$S(t) = P(T \geq t) = 1 - F(t) \Rightarrow S'(t) = -f(t)$$

$$h(t) = \frac{f(t)}{S(t)} = -\frac{S'(t)}{S(t)} = -\ln(S(t))'$$

En conclusion :

$$S(t) = \exp\left(-\int_0^t h(x)dx\right)$$

$X$  suit une loi de Weibull ssi :

$$f(x, \beta, \lambda) = \frac{\beta}{\lambda} \left(\frac{x}{\lambda}\right)^{\beta-1} \exp - \left(\frac{x}{\lambda}\right)^{\beta}$$

$x > 0$ ,  $\beta > 0$ , paramètre de forme et  $\lambda > 0$ , paramètre d'échelle.

$X$  suit une loi de Weibull ssi :

$$f(x, \beta, \lambda) = \frac{\beta}{\lambda} \left(\frac{x}{\lambda}\right)^{\beta-1} \exp - \left(\frac{x}{\lambda}\right)^{\beta}$$

$x > 0$ ,  $\beta > 0$ , paramètre de forme et  $\lambda > 0$ , paramètre d'échelle.

**Fonction de survie et fonction de hasard**

$$S(t) = P(T \geq t) = \int_t^{\infty} \frac{\beta}{\lambda} \left(\frac{x}{\lambda}\right)^{\beta-1} \exp - \left(\frac{x}{\lambda}\right)^{\beta} dx$$

$X$  suit une loi de Weibull ssi :

$$f(x, \beta, \lambda) = \frac{\beta}{\lambda} \left(\frac{x}{\lambda}\right)^{\beta-1} \exp - \left(\frac{x}{\lambda}\right)^{\beta}$$

$x > 0$ ,  $\beta > 0$ , paramètre de forme et  $\lambda > 0$ , paramètre d'échelle.

**Fonction de survie et fonction de hasard**

$$\begin{aligned} S(t) = P(T \geq t) &= \int_t^{\infty} \frac{\beta}{\lambda} \left(\frac{x}{\lambda}\right)^{\beta-1} \exp - \left(\frac{x}{\lambda}\right)^{\beta} dx \\ &= \left[ -\exp - \left(\frac{x}{\lambda}\right)^{\beta} \right]_t^{\infty} \end{aligned}$$

$X$  suit une loi de Weibull ssi :

$$f(x, \beta, \lambda) = \frac{\beta}{\lambda} \left(\frac{x}{\lambda}\right)^{\beta-1} \exp - \left(\frac{x}{\lambda}\right)^{\beta}$$

$x > 0$ ,  $\beta > 0$ , paramètre de forme et  $\lambda > 0$ , paramètre d'échelle.

**Fonction de survie et fonction de hasard**

$$\begin{aligned} S(t) = P(T \geq t) &= \int_t^{\infty} \frac{\beta}{\lambda} \left(\frac{x}{\lambda}\right)^{\beta-1} \exp - \left(\frac{x}{\lambda}\right)^{\beta} dx \\ &= \left[ -\exp - \left(\frac{x}{\lambda}\right)^{\beta} \right]_t^{\infty} \\ &= \exp - \left(\frac{t}{\lambda}\right)^{\beta} \end{aligned}$$

$X$  suit une loi de Weibull ssi :

$$f(x, \beta, \lambda) = \frac{\beta}{\lambda} \left(\frac{x}{\lambda}\right)^{\beta-1} \exp - \left(\frac{x}{\lambda}\right)^{\beta}$$


$x > 0$ ,  $\beta > 0$ , paramètre de forme et  $\lambda > 0$ , paramètre d'échelle.

**Fonction de survie et fonction de hasard**

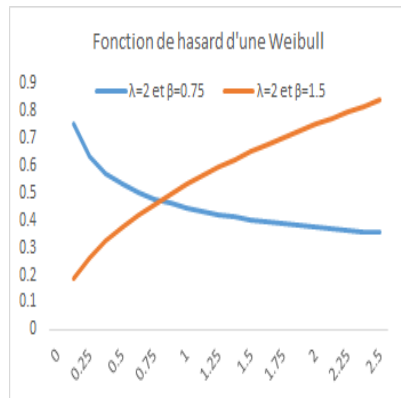

$$\begin{aligned} S(t) = P(T \geq t) &= \int_t^{\infty} \frac{\beta}{\lambda} \left(\frac{x}{\lambda}\right)^{\beta-1} \exp - \left(\frac{x}{\lambda}\right)^{\beta} dx \\ &= \left[ -\exp - \left(\frac{x}{\lambda}\right)^{\beta} \right]_t^{\infty} \\ &= \exp - \left(\frac{t}{\lambda}\right)^{\beta} \\ h(t) = \frac{f(t)}{S(t)} &= \frac{\beta}{\lambda} \left(\frac{t}{\lambda}\right)^{\beta-1} \end{aligned}$$



## Fonction de survie et fonction de hazard d'une Weibull



## Fonction de survie et fonction de hazard d'une Weibull



$X$  suit une loi log-normale de paramètre  $m$  et  $\sigma^2$  ssi :

$X$  suit une loi log-normale de paramètre  $m$  et  $\sigma^2$  ssi :

$$f(x) = \frac{1}{x\sqrt{2\pi}\sigma} \exp -\frac{1}{2} \frac{(\ln(x) - m)^2}{\sigma^2}, x > 0$$

$X$  suit une loi log-normale de paramètre  $m$  et  $\sigma^2$  ssi :

$$\begin{aligned}f(x) &= \frac{1}{x\sqrt{2\pi}\sigma} \exp -\frac{1}{2} \frac{(\ln(x) - m)^2}{\sigma^2}, x > 0 \\&= \frac{1}{x} \phi\left(\frac{\ln(x) - m}{\sigma}\right)\end{aligned}$$

$X$  suit une loi log-normale de paramètre  $m$  et  $\sigma^2$  ssi :

$$f(x) = \frac{1}{x\sqrt{2\pi}\sigma} \exp -\frac{1}{2} \frac{(\ln(x) - m)^2}{\sigma^2}, x > 0$$

$$= \frac{1}{x} \phi\left(\frac{\ln(x) - m}{\sigma}\right)$$

$$S(t) = \int_t^{\infty} \frac{1}{x\sqrt{2\pi}\sigma} \exp -\frac{1}{2} \frac{(\ln(x) - m)^2}{\sigma^2} dx$$

$X$  suit une loi log-normale de paramètre  $m$  et  $\sigma^2$  ssi :

$$\begin{aligned}f(x) &= \frac{1}{x\sqrt{2\pi}\sigma} \exp -\frac{1}{2} \frac{(\ln(x) - m)^2}{\sigma^2}, x > 0 \\&= \frac{1}{x} \phi\left(\frac{\ln(x) - m}{\sigma}\right)\end{aligned}$$

$$S(t) = \int_t^{\infty} \frac{1}{x\sqrt{2\pi}\sigma} \exp -\frac{1}{2} \frac{(\ln(x) - m)^2}{\sigma^2} dx$$

On adopte le changement de variable :

$$U = \frac{\ln(x) - m}{\sigma} \Rightarrow du = \frac{dx}{\sigma x}$$

$X$  suit une loi log-normale de paramètre  $m$  et  $\sigma^2$  ssi :

$$\begin{aligned} f(x) &= \frac{1}{x\sqrt{2\pi}\sigma} \exp -\frac{1}{2} \frac{(\ln(x) - m)^2}{\sigma^2}, x > 0 \\ &= \frac{1}{x} \phi\left(\frac{\ln(x) - m}{\sigma}\right) \\ S(t) &= \int_t^\infty \frac{1}{x\sqrt{2\pi}\sigma} \exp -\frac{1}{2} \frac{(\ln(x) - m)^2}{\sigma^2} dx \end{aligned}$$

On adopte le changement de variable :

$$U = \frac{\ln(x) - m}{\sigma} \Rightarrow du = \frac{dx}{\sigma x}$$



Ce qui donne comme fonction de survie et fonction de hasard :

$$S(t) = \int_{\frac{\ln(t)-m}{\sigma}}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right) du$$


Ce qui donne comme fonction de survie et fonction de hasard :

$$\begin{aligned} S(t) &= \int_{\frac{\ln(t)-m}{\sigma}}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right) du \\ &= 1 - \Phi\left(\frac{\ln(t) - m}{\sigma}\right) \end{aligned}$$

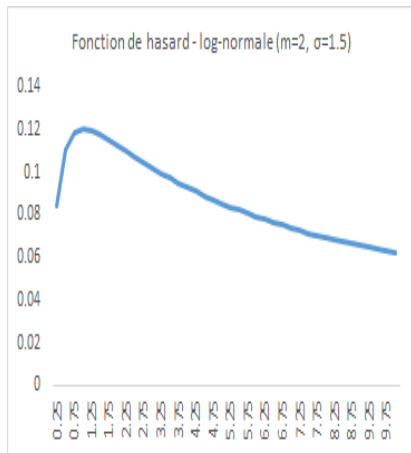
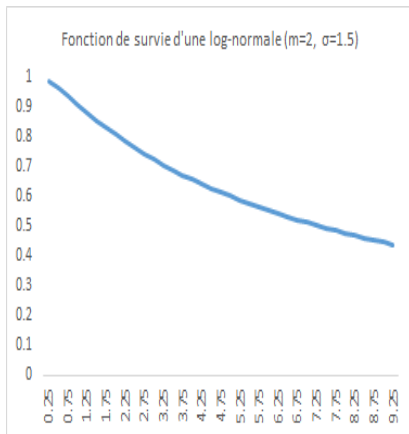
Ce qui donne comme fonction de survie et fonction de hasard :

$$\begin{aligned} S(t) &= \int_{\frac{\ln(t)-m}{\sigma}}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right) du \\ &= 1 - \Phi\left(\frac{\ln(t) - m}{\sigma}\right) \\ h(t) &= \frac{f(t)}{S(t)} = \frac{\phi\left(\frac{\ln(t)-m}{\sigma}\right)}{t \left[1 - \Phi\left(\frac{\ln(t)-m}{\sigma}\right)\right]} \end{aligned}$$

## Fonction de survie et fonction de hasard d'une log-normale



## Fonction de survie et fonction de hasard d'une log-normale



On considère les données d'une l'expérience sur deux traitements sur 100 patients (50 dans chaque groupe) (fichier Excel).

- classer, par ordre croissant, les données selon les durées de survie
- enlever les durées correspondant à une censure
- pour chaque groupe, calculer les colonnes suivantes
  - i.  $a = \#(\delta_i = 1)$  à la date  $t_{[j]}$
  - ii.  $b = \#(\delta_i = 0)$  à la date  $t_{[j]}$
  - iii.  $c = \#$  survivants à la date  $t_{[j]} = N - a - b$
  - iv  $S(t_{[j]}) = c/N$

### Exemple : Fonction de survie empirique

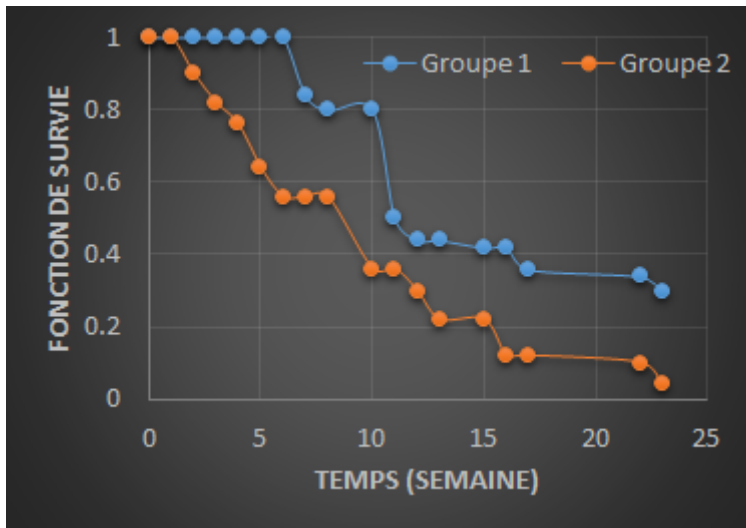


Figure – Fonction de survie

On considère les durées ordonnées par ordre croissant,  $t_1, t_2, \dots, T_{max}$ . L'estimateur de la probabilité de survie à l'instant  $t_i$  est défini par :

$$\hat{S}(t_i) = \prod_{j=1}^i \hat{P}(T > t_j / T \geq t_j) = \prod_{j=1}^i \left( \frac{N(t_j) - D(t_j)}{N(t_j)} \right)$$

avec :

- $N(t_j)$  : Nombre d'individus à risque avant  $t_j$
- $D(t_j)$  : Nombre d'événements (i.e. Décès) survenus à la date  $t_j$
- $S(t) = 1$  si  $t < t_1$

**Exemple sous R : Package survival : leucémie** : temps de survie (semaines), groupe, censure, âge, sexe.

```
> surv1j-survfit(Surv(time, event) 1, data=survie)
> plot(surv1)
```



On considère 2 groupes d'individus (patients). A chaque date  $t_j$  on observe les quantités suivantes :

- $N_g(t_j)$  : Nombre d'individus à risque avant  $t_j$  du groupe  $g$ , ( $g = 1, 2$ )
- $D_g(t_j)$  : Nombre d'événements (i.e. Décès) à la date  $t_j$  du groupe  $g$ , ( $g = 1, 2$ )
- Le nombre d'événements estimés à la date  $t_j$  est donné par :

$$e_g(t_j) = \frac{N_g(t_j)}{N_1(t_j) + N_2(t_j)} \times (D_1(t_j) + D_2(t_j))$$

La statistique de comparaison des deux courbe de survies (Statistique de Log-Rank) est définie par :

$$\log - rank = \frac{(O_1 - E_1)^2}{E_1} + \frac{(O_2 - E_2)^2}{E_2} \rightsquigarrow \chi^2(1)$$

avec  $O_g$  le nombre total d'événements dans le groupe  $g$  et  $E_g = \sum_{t_i} e_g(t_i)$

### instructions R

- > `survfit(Surv(time, cure) ~ Group, data = survie)`
- > `plot(survfit(Surv(time, cure) ~ Group, data = survie))`
- > `survdiff(Surv(time, cure) ~ Group, data = survie)`

Le modèle de Cox est défini la fonction de hasard comme suit :

$$h(t) = h_0(t) \exp \left( \sum_{l=1}^k \beta_l X_l \right)$$

avec  $X_1, X_2, \dots, X_k$  les variables explicatives et  $h_0(t)$  une fonction qui ne dépend que du temps (risque de base).

**Ratio de hasard : Hazard ratio** : Considérons deux groupes d'individus pour lesquels on observe les  $X_{gl}$ ,  $g = 1, 2$ . Le ratio de hasard (risque) est défini par :

$$HR = \exp \left( \sum_{l=1}^k \beta_l (X_{1l} - X_{2l}) \right)$$

## Instructions R

```
> coxph(Surv(time, censorship) ~ Group + Log_wbc + sexe + age,
data = survie)
```

MERCI POUR VOTRE ATTENTION